

CESAR SCHOOL

FABRICIO TORQUATO LEITE

**SISTEMA DE CONTROLE VEICULAR UTILIZANDO BRAIN
COMPUTER INTERFACE PARA AJUDAR NA QUALIDADE DE
VIDA DE PESSOAS COM DEFICIÊNCIA MOTORA NOS
MEMBROS INFERIORES**

RECIFE

2023

FABRICIO TORQUATO LEITE

**SISTEMA DE CONTROLE VEICULAR UTILIZANDO
BRAIN COMPUTER INTERFACE PARA AJUDAR NA
QUALIDADE DE VIDA DE PESSOAS COM DEFICIÊNCIA
MOTORA NOS MEMBROS INFERIORES**

Dissertação apresentada ao programa de Mestrado em Engenharia de Software do Centro de Estudos e Sistemas Avançados do Recife – CESAR School, como requisito para a obtenção do título de Mestre em Engenharia de Software.

Orientação: Dr. Walter Charles Sousa Seiffert Simões

RECIFE

2023

Catalogação da Publicação na Fonte (CIP)
Centro de Estudos e Sistemas Avançados do Recife - CESAR School

L533s Leite, Fabrício Torquato

Sistema de controle veicular utilizando *brain computer interface* para ajudar na qualidade de vida de pessoas com deficiência motora nos membros inferiors / Fabrício Torquato Leite. – Recife: O autor, 2023.

96 p.: il.

Dissertação (Mestrado) - Centro de Estudos e Sistemas Avançados do Recife - CESAR School. Programa de Pós-Graduação em Engenharia de Software.

Orientação: Prof. Walter Charles Sousa Seiffert Simões.

1. Aprendizado de máquina. 2. *Brain computer interface*. 3. *Robot operating system*. 4. Engenharia de software. I. Simões, Walter Charles Sousa Seiffert (Orientador). II.Título.

CDD 005.1



FABRICIO TORQUATO LEITE

**SISTEMA DE CONTROLE VEICULAR UTILIZANDO BRAIN COMPUTER INTERFACE PARA
AJUDAR NA QUALIDADE DE VIDA DE PESSOAS COM DEFICIÊNCIA MOTORA NOS
MEMBROS INFERIORES**

Trabalho aprovado em Recife: **11/08/2023**

Professor: Walter Charles Sousa Seiffert Simoes
(CESAR SCHOOL)
Orientador

Professor: Erico Souza Teixeira
(CESAR SCHOOL)
Avaliador Interno

Professor: Vandermi João da Silva
(UFAM)
Avaliador Externo

RECIFE
2023

Dedicatória

Dedico esta dissertação de mestrado à memória da minha amada mãe, Rosalina Bueno da Silva Leite. Ela foi uma fonte constante de amor, apoio e inspiração ao longo de toda a minha jornada acadêmica. Sua presença e incentivo nos momentos mais difíceis foram fundamentais para minha perseverança e sucesso. Seu legado permanecerá vivo em meu coração e em cada linha escrita desta dissertação. Espero que, onde quer que você esteja, sinta-se orgulhosa de minhas conquistas e saiba que sua influência continua a moldar meu percurso acadêmico e pessoal.

Agradecimentos

Quero expressar minha profunda gratidão a Deus por abençoar minha vida com saúde, uma família amorosa, amigos leais e a força necessária para superar os obstáculos. Também desejo agradecer ao CESAR, incluindo seu corpo docente, diretores e equipe administrativa, por me proporcionarem a oportunidade de vislumbrar um futuro promissor, baseado na confiança firme no mérito e na ética presentes nesta instituição. Ao meu orientador, Dr. Walter Charles Sousa Seiffert Simões, pelo suporte, pelas suas correções e incentivos. Agradeço a todos os professores por me proporcionar o conhecimento não apenas racional, mas a manifestação do caráter e afetividade da educação no processo de formação profissional, por tanto que se dedicaram a mim, não somente por terem me ensinado, mas por terem me feito aprender. A palavra gratidão, nunca fará justiça aos atos de meus professores dedicados aos quais sem nominar terão os meus eternos agradecimentos. Quero agradecer meu pai, meu irmão, minha madrinha e minha namorada, que foram fontes de fortalecimento e apoio durante todas as dificuldades que enfrentei. Sua presença foi extremamente importante para mim. Em memória, expresso minha gratidão à minha mãe, Rosalina Bueno da Silva Leite, uma verdadeira heroína que me apoiou e incentivou nos momentos difíceis, e que me auxiliou em minha jornada acadêmica. Também gostaria de agradecer aos meus amigos, colegas de trabalho e irmãos na amizade que fizeram parte do meu processo de formação e que continuarão a ser uma parte importante da minha vida no futuro. Por fim, expresso meu sincero agradecimento a todos aqueles que, direta ou indiretamente, contribuíram para a minha formação. Seu apoio e influência foram inestimáveis, e por isso digo: muito obrigado a todos.

Epígrafe

"Não vos amoldeis às estruturas deste mundo, mas transformai-vos pela renovação da mente, a fim de distinguir qual é a vontade de Deus: o que é bom, o que lhe é agradável, o que é perfeito." (Bíblia Sagrada, Romanos 12, 2)

Resumo

A tecnologia está em constante evolução disponibilizando novas horizontes para serem estudados. Ao observar os estudos de novas tecnologias, uma das áreas que merece atenção das pesquisas é a inclusão social, isso devido ao número expressivo de Pessoas Com Deficiência (PCD). Ter uma boa qualidade de vida é de grande valia para todas as pessoas, de modo que nessa dissertação é trabalhado como melhorar este aspecto para pessoas que se enquadram com complicações nas ações motoras inferiores. O desenvolvimento de melhorias contínuas nesse tipo de recurso está fortemente ligada na tentativa de neutralizar as barreiras causadas pelas complicações. Sendo assim, se o campo de tecnologia assistiva ficar defasado, pessoas que utilizam desses meios tecnológicos para melhorar sua qualidade de vida estarão diretamente afetados. Este trabalho propõe utilizar um Eletroencefalograma (EEG), um sensor de monitoramento não invasivo que analisa a atividade elétrica cerebral, com estudos na área de *Brain Computer Interface (BCI)* para criar uma fluxo de treinamento e avaliação de algoritmos de inteligência artificial para um sistema de controle de um carrinho movido a uma *raspberry pi* interfaceado com o *framework Robot Operating System (ROS)*, onde os algoritmos preditivos fazem a interpretação das atividades cerebrais do usuário para identificar comandos motores voluntários, em questão, movimentos das mãos/braços esquerda e direita, tais ações se corresponde à rotacionar as rodas do carrinho para esquerda ou para direita, além disso, a ausência de ações motoras das mãos são interpretados como seguir em frente. A fim de contribuir para o avanço da área do *BCI*, este trabalho realizou ciclos de experimentos com usuários em teste prático com 3 algoritmos de redes neurais diferentes, de modo que resultados encontrados possibilitaram a comparação da atuação das redes de aprendizado profundo. Além disso, esse trabalho utilizou de estudo de casos para avaliar o comportamento dos algoritmos na prática com ciclos de experimentos e entrevistas, a fim de obter não somente resultados estatísticos dos modelos em questão mas também uma comparação de como eles se comportam em exemplos práticos. Mesmo a ChrnoNet possuindo resultados superiores, tanto nos cálculos estatísticos quanto nos experimentos práticos quando comparado a *Convolutional Neural Network (CNN)* simples e *Long Short-Term Memory (LSTM)*, os *feedbacks* coletados dos voluntários do experimento permitiram compreender quais as desvantagens em arquiteturas do estilo recorrente, de modo que devido sua características de propagação de erro as previsões erradas dos modelos acabavam frustrando o usuário causando diversas previsões aleatórias na sequência, e isso é comprovado pelo fato de que para melhorar os resultados o usuário utiliza de uma adaptação momentânea relaxando, fechando os olhos, e momentos após essa ação o modelo volta a responder com alta assertividade seus movimentos, sem precisar do retreinamento da rede. Com isso, essa dissertação é dedicado a contribuir com a qualidade de vida de pessoas que possuem alguma complicações nas ações motoras dos membros inferiores, isso pelo fato da possibilidade da reutilização do princípio de movimentação das rodas do carrinho para outros meios de interação motora como caso de uma cadeira de rodas elétrica.

Palavras-chaves: aprendizado de máquina; *brain computer interface*; *robot operating system*.

Abstract

Technology is constantly evolving, providing new horizons to be studied. When observing the studies of new technologies, one of the areas that deserves research attention is social inclusion, due to the expressive number of PCD. Having a good quality of life is of great value to everyone, so this project works on how to improve this aspect for people who have complications in their lower motor movements. The development of continuous improvements in this type of resource is strongly linked in the attempt to neutralize the barriers caused by complications. Therefore, if the field of assistive technology lags, people who use these technological means to improve their quality of life will be directly affected. This work proposes to use a EEG, a non-invasive monitoring sensor that analyzes the brain electrical activity, with studies in the area of BCI to create a flow of training and evaluation of algorithms of artificial intelligence for a cart control system powered by a raspberry pi interfaced with the framework ROS, where predictive algorithms interpret the user's brain activities to identify voluntary motor commands , in question, movements of the hands/arms left and right, such actions correspond to rotating the wheels of the cart to the left or to the right, in addition, the absence of motor actions of the hands are interpreted as moving forward. In order to contribute to the advancement of the BCI area, this work carried out cycles of experiments with users in a practical test with 3 different neural network algorithms, so that the results found made it possible to compare the performance of the deep learning networks. In addition, this work used case studies to evaluate the behavior of algorithms in practice with cycles of experiments and interviews, in order to obtain not only statistical results of the models in question but also a comparison of how they behave in practical examples. Even though ChrnoNet had superior results, both in statistical calculations and in practical experiments when compared to simple CNN and LSTM, the feedbacks collected from the experiment's volunteers allowed us to understand the disadvantages in recurrent style architectures, so that due to their error propagation characteristics, the wrong predictions of the models ended up frustrating the user, causing several random predictions in the sequence, and this is proven by the fact that to improve the results the The user makes a momentary adaptation by relaxing, closing his eyes, and moments after this action the model returns to respond with high assertiveness to his movements, without needing to retrain the network. With this, this project is dedicated to contributing to the quality of life of people who have some complication in the motor movements of the lower limbs, because of the possibility of reusing the principle of movement of the cart wheels for other means of motor interaction as a case of an electric wheelchair.

Keywords: machine learning; brain-machine interface; robot operating system.

SUMÁRIO

1	INTRODUÇÃO	18
1.1	CONTEXTO	18
1.2	JUSTIFICATIVA	18
1.3	PROBLEMA	19
1.4	PROPOSTA	19
2	TRABALHOS RELACIONADOS	23
3	METODOLOGIA	38
3.1	AQUISIÇÃO DE DADOS	38
3.2	PRÉ-PROCESSAMENTO DE DADOS	45
3.3	TOMADA DE DECISÃO	47
3.4	PROCESSO E ESTRATÉGIA	53
4	DESENVOLVIMENTO	57
5	RESULTADOS E AVALIAÇÕES	64
5.1	TESTE E AVALIAÇÃO	64
5.2	MEDIDA DE DESEMPENHO	65
5.2.1	Número de Comandos Corretos	68
5.2.2	Taxa de Acertos	69
5.2.3	Tempo Médio Entre Detecções	69
5.2.4	Tempo Médio Entre Acertos	69
5.2.5	<i>Information Transfer Rate</i>	70
5.3	RESULTADOS	72
5.3.1	CNN	72
5.3.2	RNN	73
5.3.3	Chronet	74
5.3.4	Comparativo Entre as Técnicas	74
5.3.5	Comparativo Com a Literatura	79
5.4	DISCUSSÃO	82
6	CONCLUSÃO	85
REFERÊNCIAS		88
APÊNDICE A – FORMULÁRIO DE CONVITE DE PESQUISA		93

APÊNDICE B	-	TCLE	95
APÊNDICE C	-	QUESTIONÁRIO	97

Lista de ilustrações

Figura 1	Sistema BCI baseados em realimentação incorporada e não incorporada	21
Figura 2	Fluxograma de forma específica da metodologia de trabalho	38
Figura 3	Diagrama de um ciclo de aquisição de dados	39
Figura 4	Mão em formato de pinça	40
Figura 5	Palma da mão para cima e para baixo	41
Figura 6	Apertando bola estimuladora com polegar para cima rotacionando para dentro	41
Figura 7	Estalando os dedos	42
Figura 8	Apertando a bola estimuladora	42
Figura 9	Abrindo e fechando a mão.	42
Figura 10	Direções mostradas durante os ciclos de aquisição	43
Figura 11	Diagrama de um ciclo de aquisição de dados	44
Figura 12	Fluxograma da fase de pré-processamento dos dados	45
Figura 13	A esquerda composição espacial de uma amostra do dataset sem janelamento e a direita com janelamento.	47
Figura 14	Fluxograma da fase de tomada de decisão	48
Figura 15	Arquitetura do algoritmo de CNN utilizado	49
Figura 16	Do lado esquerdo arquitetura da RNN utilizado por (DJAMAL <i>et al.</i> , 2020) e do lado direito arquitetura da RNN utilizado neste trabalho. Em vermelho elementos retirados da arquitetura de Esmeralda Contessa Djamal e em amarelo elementos adicionados	50
Figura 17	Do lado esquerdo arquitetura da ChronoNet utilizado por (ROY; KIRAL-KORNEK; HARRER, 2019) e do lado direito arquitetura da ChronoNet utilizado neste trabalho. Em vermelho elementos retirados da arquitetura de Subhrajit Roy e em amarelo elementos adicionados	51
Figura 18	Fluxograma de forma específica da metodologia de trabalho	54
Figura 19	Fluxograma de BCI utilizado	56
Figura 20	Local de realização da aquisição de dados.	57
Figura 21	Eletroencefalograma Emotiv Insight 2.0, da empresa EMOTIV	58
Figura 22	SunFounder PiCAR-S	60

Figura 23	Módulos do PiCAR-S	60
Figura 24	Esquema de conexões do motor DC e dos servos motores do Picar-S	61
Figura 25	Imagen da infraestrutura da aplicação	62
Figura 26	Diagrama de representação da tarefa	66
Figura 27	Local do experimento quantitativo	66
Figura 28	Local do experimento quantitativo	67
Figura 29	Diagrama de representação do teste	68
Figura 30	Relação entre o aumento da taxa de bit (B) e a variação do número de comandos N e da taxa de acertos.	71
Figura 31	Histograma de taxa de acertos.	75
Figura 32	Histograma de Information Transfer Rate.	75
Figura 33	Curva de Erro de Treinamento, coluna da esquerda ChronoNet, coluna central CNN, clouna da direita RNN	76
Figura 34	Matriz de Confusão, coluna da esquerda ChronoNet, coluna central CNN, clouna da direita RNN	78

Lista de quadros

Quadro 1	Referencia Cruzada	33
Quadro 2	Protocolo de Coleta	40

Lista de tabelas

Tabela 1	NCC, acurácia, TMD, TMA e ITR para CNN.	73
Tabela 2	NCC, acurácia, TMD, TMA e ITR para RNN.	73
Tabela 3	NCC, acurácia, TMD, TMA e ITR para Chronet.	74
Tabela 4	Comparativo Entre BCI Encontradas na Literatura.	82

Abreviaturas

Sigla	Significado
AF3	Antero Frontal 3
AF4	Antero Frontal 4
ANFIS	Adaptive Neural Fuzzy Detection System
API	Application Programming Interface
BCI	Brain Computer Interface
Bi-LSTM	Bidirectional Long-Short Term Memory
BLDA	Bayesian Linear Discriminant Analysis
C4	Cortex 4
C-RNN	Convolutional Gated Recurrent Neural Networks
CNN	Convolutional Neural Network
DET	Detecção
EEG	Eletroencefalograma
F4	Frontal 4
GB	Gigabyte
GHz	Giga Hertz
GRU	Gated Recurrent Unit
Hz	Hertz
IC-DRNN	Inception Convolutional Densely Connected Gated Recurrent Neural Network
IC-RNN	Inception Convolutional Gated Recurrent Neural Network
ICM	Interface Cérebro-Máquina
IQR	Interquartile Range
ITR	Information Transfer Rate
LDA	Linear Discriminant Analysis

Sigla	Significado
LSTM	Long Short-Term Memory
MCU	Microcontroller Unit
MLP	Multilayer Perceptron
NCC	Número de Comandos Corretos
O1	Occipital 1
PCD	Pessoas Com Deficiência
PEV-RP	Potencial Evocado Visual em Regime Permanente
PNS	Pesquisa Nacional de Saúde
PSD	Densidade Espectral de Potência
RAM	random-access memory
ReLU	Rectified Linear Unit
RNN	Recurrent Neural Network
ROS	Robot Operating System
SDK	Software Development Kit
SMR	Ritmos Sensório-Motores
SMS	Short Message Service
SSD	Solid-State Drive
SVM	Support Vector Machine
T5	Temporal 5
T7	Temporal 7
T8	Temporal 8
TA	Tecnologia Assistiva
TCLE	Termo de Consentimento Livre e Esclarecidos
TFN	Taxa de Falso Negativo
TFP	Taxa de Falso Positivo
TMA	Tempo Médio Entre Acertos

Sigla	Significado
TMD	Tempo Médio Entre Detecções
TVN	Taxa de Verdadeiro Negativo
TVP	Taxa de Verdadeiro Positivo
UGV	Unmanned Ground Vehicle

1 INTRODUÇÃO

1.1 CONTEXTO

A inclusão social é um tema cada vez mais relevante na sociedade atual, sendo objeto de estudos e discussões em diversas áreas do conhecimento (MAZZOTTA; D'ANTINO, 2011). Nesse sentido, a tecnologia tem desempenhado um papel importante ao oferecer soluções que possibilitam a inclusão de pessoas com deficiência. Com o advento de novas tecnologias, tem sido possível desenvolver ferramentas que ajudam as pessoas com deficiência a superar as barreiras impostas pela limitação física ou mental. Ainda assim, é necessário avançar ainda mais nessa área, a fim de tornar a inclusão social uma realidade para todos.

Conforme informações divulgadas pela Pesquisa Nacional de Saúde (PNS) (PNS, 2019), cerca de 8,4% (17,3 milhões) da população brasileira declarou possuir algum tipo de deficiência, sendo que a PNS avaliou as deficiências visuais, auditivas, motoras e mentais/intelectuais.

A prevalência de deficiências motoras no Brasil é significativa, visto que dos 8,4% dos participantes da pesquisa do PNS, cerca de 3,8% (7,8 milhões) das pessoas de 2 anos ou mais tem deficiência física nos membros inferiores e 2,7% (5,5 milhões), nos membros superiores, o que os torna o maior grupo da pesquisa.

1.2 JUSTIFICATIVA

Essa dissertação foi desenvolvida com base em três pilares fundamentais. O primeiro deles é uma justificativa técnica, que visa a construção de um sistema mais simples de geração de modelos de redes neurais que extraia um conjunto menor e mais confiável para ser utilizado.

O segundo pilar é uma justificativa acadêmica, que busca contribuir com o avanço dos estudos na área de inteligência artificial, demonstrando o uso de redes neurais em contexto de previsão de ação motora. Essa abordagem pode ser aplicada em diferentes contextos, como no desenvolvimento de sistemas de reconhecimento de ação motora ou no controle de uma cadeira de rodas.

Por fim, o terceiro pilar é uma justificativa social, que tem como objetivo contribuir com a qualidade de vida de pessoas que possuem alguma complicação nas ações motoras dos membros inferiores. Com o avanço das tecnologias assistivas, é possível desenvolver soluções que ajudem essas pessoas a terem mais autonomia e independência em suas atividades cotidianas.

Essa é uma área em constante crescimento e que demanda soluções cada vez mais inovadoras e eficientes.

Em suma dos três pilares, o presente trabalho busca contribuir para a melhoria da qualidade de vida dessas pessoas e proporcionando avanços no campo da engenharia de software. Além disso, a possibilidade de reutilização desse trabalho para outros meios de interação motora, como em uma cadeira de rodas, aumenta ainda mais seu potencial impacto.

1.3 PROBLEMA

A engenharia de software tem demonstrado um grande potencial para resolver problemas complexos, especialmente no que diz respeito à melhoria da qualidade de vida das pessoas. O principal objetivo das novas Tecnologia Assistiva (TA) é beneficiar os indivíduos. No entanto, para aplicar efetivamente essas TA em usuários reais, é crucial prestar uma atenção especial aos aspectos técnicos.

Dentro desse contexto, este trabalho busca solucionar o seguinte problema: qual é o algoritmo de aprendizagem de máquina adequado para interpretar as atividades cerebrais e os movimentos das mãos/braços em um sistema de controle veicular, utilizando TA, como o EEG e a BCI, com o objetivo de melhorar a qualidade de vida de pessoas com complicações nas ações motoras inferiores? O estudo considera a aplicação desses princípios em meios de interação motora, como cadeiras de rodas elétricas, mas, para fins de segurança, o desenvolvimento foi realizado utilizando um carro robótico.

1.4 PROPOSTA

Ao analisar os estudos e publicações mais atuais sobre inclusão social, é comum encontrarmos o conceito de TA. Esse termo se refere a um conjunto de ferramentas e recursos que podem prover assistência ou reabilitação para pessoas com algum tipo de deficiência, proporcionando às mesmas autonomia e independência na realização de atividades diárias (NAZARI; NAZARI; GOMES, 2017).

Dahlhausen e Radabaugh exploram o seguinte conceito para compreender o propósito dos estudos na área de TA: Para as pessoas sem deficiência a tecnologia torna as coisas mais fáceis. Para as pessoas com deficiência, a tecnologia torna as coisas possíveis (DAHLHAUSEN; RADABAUGH, 1993 apud CANDIDO; CARNEIRO, 2018).

Pode-se dizer que o objetivo maior da TA é proporcionar à pessoa com deficiência maior independência, qualidade de vida e inclusão social, por meio da ampliação de sua comunicação, mobilidade, controle de seu ambiente, habilidades de seu aprendizado e trabalho (NAZARI; NAZARI; GOMES, 2017).

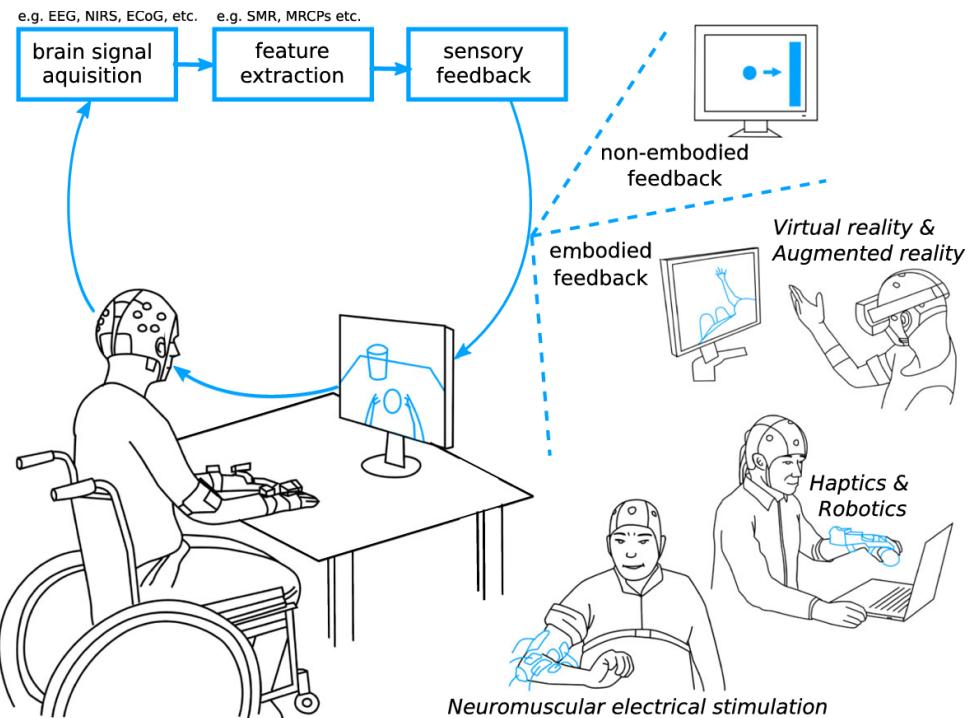
Dado o grande número de áreas de atuação da TA, é imprescindível categorizá-las e dividí-las em classes de estudo. Para este fim, várias classificações de TA têm sido desenvolvidas com objetivos diversos, incluindo a ISO 9999/2002 (FEDERATION, 2002), bem como a classificação EUSTAT (EUSTAT, 1999), entre outras. Neste contexto, é importante ressaltar que o presente trabalho enfoca a classificação elaborada em 1998 por José Tonolli e Rita Bersch, tendo uma atualização em 2017, conforme Sartoretto e Bersch (SARTORETTO; BERSCH, 2017).

De acordo com Sartoretto e Bersch (SARTORETTO; BERSCH, 2017), uma das áreas da TA é a de sistemas de controle de ambiente, que consiste em um sistema de controle projetado para pessoas com limitações motoras. Esse sistema possibilita aos usuários ligar, desligar e ajustar aparelhos eletroeletrônicos, tais como luzes, televisores, computadores, próteses e até mesmo equipamentos de locomoção.

Além disso, vale mencionar que apareceu na computação uma vertente de estudo denominada (BCI), que se desenvolveu de forma assíncrona aos avanços da TA. A BCI se concentra em investigar a habilidade humana de utilizar a atividade cerebral para manipular ambientes e dispositivos. Conforme McFarland e Wolpaw (MCFARLAND; WOLPAW, 2017), essa área de pesquisa analisa atributos específicos da atividade cerebral e busca traduzi-los em sinais que permitam o controle de dispositivos.

O BCI transforma um padrão de atividade cerebral em um comando externo. São necessários quatro blocos básicos, Figura 1: aquisição de sinais, extração de características, classificação e comando de dispositivo (HONG; KHAN; HONG, 2018).

Figura 1 – Sistema BCI baseados em realimentação incorporada e não incorporada



Fonte: (CERVERA *et al.*, 2018)

O objetivo deste trabalho é avaliar a eficácia de algoritmos de aprendizado de máquina em BCI para o controle de um carro robótico de motores elétricos. Para alcançar esse objetivo, a pesquisa tem como objetivos específicos definir algoritmos de aprendizado de máquina que melhor atendam a sistemas com baixa latência, desenvolver um fluxo de treinamento para um sistema de controle baseado em BCI, analisar os resultados dos experimentos em ambientes controlados e estabelecer correlações entre os resultados obtidos dos experimentos e os algoritmos de aprendizado de máquina utilizados.

A fim de atingir tais objetivos, este trabalho realizou uma prova de conceito que será descrita no Capítulo 4, na qual utiliza um eletroencefalograma com estudos na área de BCI para criar um sistema de controle de um carro robótico. Serão analisadas as atividades cerebrais do usuário para identificar comandos de ações motoras voluntárias como movimento dos braços esquerdo e direito, tais ações serão correspondentes à rotacionar para esquerda ou para direita as rodas do carro robótico, sendo que qualquer comando diferente será interpretado para o veículo seguir em frente.

Neste estudo, busca-se identificar os comandos realizados pelo usuário por meio de algoritmos de inteligência artificial, mais especificamente, redes neurais. Para isso, o trabalho propõe três arquiteturas baseadas em técnicas distintas de aprendizagem de máquina, que geram seus

próprios modelos preditivos. O objetivo é encontrar as melhores abordagens para o problema em questão e, assim, obter dados para ajudar a contribuir e evoluir a área de BCI com redes neurais.

Este trabalho está estruturado da seguinte forma: o Capítulo 2 apresenta o referencial teórico que contextualiza os estudos desenvolvidos na área, o Capítulo 3 descreve a proposta de tratamento, pré-processamento e classificação de dados para prever ações motoras, o Capítulo 4 relata a implementação da prova de conceito deste estudo, o Capítulo 5 apresenta as métricas quantitativas e qualitativas utilizadas nesta dissertação, bem como os dados obtidos nos experimentos e uma comparação dos resultados com os encontrados na literatura, por fim, o Capítulo 6 discute os resultados e junto aos trabalhos futuros.

2 TRABALHOS RELACIONADOS

A área da inteligência artificial pode ser estudada em colaboração com diversas áreas, destacando-se como um dos principais recursos de inovações atuais. Uma das áreas de grande colaboração é a área da saúde, onde se encontra a interface cérebro-máquina (Interface Cérebro-Máquina (ICM) em inglês BCI), estudo na qual possui como objetivo interpretar a informação codificada na atividade elétrica de grupos neuronais associados a um processo motor. Estes sinais devem ser analisados em tempo real e posteriormente traduzidos em comandos para controlar um dispositivo artifício (MEDEIROS *et al.*, 2009 apud FRAGA, 2017).

Para esse trabalho a metodologia de pesquisa teve como foco aplicações de BCI, entretanto dentro desta área foi notado uma divisão entre dois tipos de pesquisas, sendo elas: trabalhos de cunho apenas estatístico, voltado para técnicas, arquiteturas e métricas de redes neurais e trabalhos de cunho experimental prático, voltado para construção física ou virtual de meios de controle.

A técnica empregada durante a construção dos trabalhos relacionados é a revisão sistemática, onde os principais pontos de critérios adotados na primeira busca foi, o ano da pesquisa sendo acima de 2015, visto que antes disso os hardware de sensores EEG eram de domínio de precisão muito inferiores dos que existem atualmente e o uso de palavras chaves como: BCI, EEG, eletroencefalograma, *deep learning*, *neural network*, CNN, ConvNet, CNN, *recurrent neural network*, Recurrent Neural Network (RNN), *long short-term memory* e LSTM.

Após a realização da busca em largura para encontrar a primeira base de dados de trabalhos, foi utilizado uma variação da técnica de revisão descrita por Yannick Roy em seu trabalho *Deep learning-based electroencephalography analysis: a systematic review* (ROY *et al.*, 2019), onde nessa fase o foco foi, buscar e relacionar de forma mais eficaz e otimizada quais dos trabalhos encontrados até o momento possuem maior correlação entre o tema pesquisado e este trabalho. Deste modo a técnica se caracteriza em, primeiramente, ler os resumos e seções de resultados, a fim de descobrir quais as práticas de design de BCI utilizadas, em segundo lugar, consultar as metodologias e desenvolvimentos, a fim de encontrar quais foram os dados utilizados, técnicas de pré-processamentos, metodologias de extração de recursos e software utilizados/implementados, por final, seria lido de um modo geral procurando informações referentes a domínio empregado, arquitetura utilizada, arranjos experimentais e métricas empregadas para sua avaliação.

Após esse procedimento, foram mapeados no total, 16 trabalhos que possuíam relacionamento entre a área de pesquisa. Vale destacar que durante a primeira busca dos trabalhos foi utilizado termos em português, entretanto o resultado da busca se mostrou escasso, na qual é possível notar esse fato na quantidade de trabalhos selecionados que serão apresentados a seguir.

Em Insight2OSC de Andrés Aparicio (LEVICÁN *et al.*, 2017) tinham o objetivo de utilizar um EEG para controlar a síntese de som pelo MaxMSP, onde usaram o *Emotiv Insight* como forma de aquisição de dados e processamento de sinal. Os dados obtidos via *bluetooth*, são coletados por uma máquina que envia o resultado da rede neural treinada com o software do fornecedor para uma segunda máquina via protocolo OSC, onde existe um software que faz o mapeamento do resultado da rede para o software de áudio, de modo que o usuário seja capaz de controlar a mesa de mixagem virtual a partir do EEG. Como pontos de contribuição dos autores, o trabalho conta com um bom detalhamento do sistema de montagem do hardware e também com o desenvolvimento de quatro aplicações musicais usando o processamento de som MaxMSP.

No trabalho *Generation of Bengali Voice Notifications Using Brain Machine Interface for Motor Disabled Patients* o autor Afaz UI Hoq (HOQ *et al.*, 2018), propõe uma interface de controle onde os sinais cerebrais coletados pelo EEG da *Emotiv Insight* são transferidos via *bluetooth* para um *smartphone Android*, que são coletados pelo aplicativo desenvolvido pelo autor chamado “*Chinta*” que atua como interface entre o usuário e o *smartphone*. O aplicativo móvel é treinado com um classificador que foi usado neste aplicativo e permite ao *smartphone* interpretar e entender a intenção dos usuários, onde a ação final está representada em poder enviar um Short Message Service (SMS) para pessoas designadas cujos contatos estão configurados no aplicativo. Segundo o autor, foram realizados em torno de 20 experimentos com indivíduos saudáveis com idade entre 21 e 45 anos, separados em dez mulheres e dez homens, sendo todos os vinte indivíduos destros.

Um dos pontos fortes do trabalho de Afaz UI Hoq (HOQ *et al.*, 2018) é a boa descrição do seu protocolo de avaliação experimental, na qual ajuda na colaboração de futuras pesquisas na área, onde, no período de treinamento da rede neural, os indivíduos tiveram que realizar cinco tarefas, a primeira foi feita pelos condutores do experimento onde eles colocaram o fone de ouvido na cabeça do indivíduo garantindo o melhor contato (82% de contato foi alcançado em média), a qualidade do contato foi verificada usando um aplicativo do fornecedor do hardware. uma vez que o contato foi alcançado com sucesso, foi dado um minuto de pausa

para relaxar. A segunda tarefa envolveu os indivíduos se acalmarem conforme instruído pelo nosso aplicativo móvel, "Chinta". A terceira tarefa envolveu o indivíduo pensar em mover um cubo que estava sendo exibido na tela do aplicativo, "Chinta", após a execução da tarefa, o indivíduo teve um minuto de pausa para relaxar. A quarta tarefa envolveu o indivíduo pensar em empurrar o cubo exibido na tela do aplicativo móvel, "Chinta", após a execução da tarefa, foi dado um minuto de pausa para relaxar, marcando o final da sessão de treinamento. Após o processo de treinamento, o usuário era instruído a ir para tela inicial do aplicativo "Chinta", onde que a partir deste momento ele conseguia controlar o device através das ações mapeadas anteriormente, sendo que objetivo do experimento é o usuário enviar um SMS sem auxílio externo.

Uma das conclusões que o autor Afaz Ul Hoq chegou foi no uso de pausa de um minuto entre cada tarefa, de modo a permitir que o usuário possa relaxar e manter a calma para obter dados mais precisos, segundo o autor é importante para manter os resultados sem interferência de cenários passados.

No trabalho de Negri, chamado Interface Ceérebro Máquina de Baixo Custo como Tecnologia Assistiva (GRANDINI *et al.*, 2017), foi desenvolvido uma interface de controle utilizando um teclado virtual com um EEG da *Emotiv Insight 2*, no intuito de ajudar pessoas com dificuldades motoras. Segundo o autor, uma das desvantagens de utilizar o pré-processamento e algoritmo de treinamento fornecido pela fabricante do hardware, se dá pelo fato de que a ação executada para ativar o BCI não demonstrou ser válido para ser utilizado por longa duração, embora em alguns testes o usuário tenha sido capaz de controlar os comandos mentais com uma precisão adequada, em alguns minutos ou horas depois o usuário já não era mais capaz de repetir com o mesmo êxito. Segundo Negri, seu trabalho encontrou um desafio que ele chama de analfabetismo de BCIs, sendo que um de seus indivíduos de teste, não conseguiu controlar sua interface em nenhum momento, mesmo após passar por um treinamento exaustivo, de mais de 20 horas. Em conclusão do autor, ele não chegou em uma resposta do motivo do problema, entretanto ele levanta um alerta para futuras pesquisas na área, sobre a compreensão desse analfabetismo, já que é necessário entender porque apenas uma porcentagem da população é capaz de controlar estas interfaces.

No trabalho Desenvolvimento de Um Simulador Controlado por Interface Cérebro- Computador Não Invasiva para Treinamento na Utilização de Cadeira de Rodas do autor Ânderson Schuh (SCHUH *et al.*, 2013), foi desenvolvido um simulador de cadeira de rodas comandada por um BCI não invasivo, utilizando um EEG de baixo custo da *Neurosky*. O simulador foi utilizado

para realizar o treinamento de pessoas com necessidades especiais para que, no momento de uso da cadeira, consigam controlá-la facilmente, evitando acidentes. Segundo o autor, sua interface de controle possui 3 comandos que representam a ordem: rotacionar a esquerda, ir em frente e rotacionar a direita. Cada comando é destacado automaticamente na tela do simulador, este destaque dura o intervalo de 2 segundos, quando então, é alterado o destaque para o próximo, quando o usuário deseja selecionar o comando destacado, ele deve piscar os olhos, ao selecionar o comando, este irá começar imediatamente a ser executado, para parar a execução, o usuário deve piscar novamente, neste momento, todo o fluxo descrito acima volta a ser executado. O trabalho de Ânderson Schuh possui como pontos fortes, seu alto grau de detalhismo na construção virtual da cadeira de rodas, descrevendo os níveis de velocidade, torque, adição de sensores para detectar possíveis colisões e realizar a parada automatizada, funcionalidade já utilizada atualmente em carros modernos. Segundo o autor, a aplicação foi testada exaustivamente pelos desenvolvedores, e ainda, por mais cinco pessoas, sendo que nenhuma delas possui algum tipo de deficiência, estes testes tiveram o foco principal de relacionar se os movimentos da cadeira, o funcionamento do sistema de sensores, a diferenciação de piscar voluntariamente ou involuntariamente estavam em bom funcionamento, de maneira a deixar preparado o sistema para o usuário final em um trabalho futuro.

O trabalho *Brain-Bot* do autor Vishal Chaurasia (CHAURASIA; MISHRA; JAIN, 2016), teve como objetivo apresentar uma metodologia por meio da qual pessoas com deficiência motora possam interagir com dispositivos físicos utilizando a Interface Cérebro-Computador. Foi construído um carro robótico que o autor chama de Unmanned Ground Vehicle (UGV), onde o usuário ao utilizar o EEG da *Neurosky* controla o veículo através do piscar dos olhos e a força de atenção coletados pelo software do fornecedor do EEG, o controle se baseia no UGV andando automaticamente na direção para frente e se ocorrer algum evento de piscar de olhos o sistema irá mudar a direção no sentido horário e voltará a andar para frente nessa mesma direção após a rotação.

Durante o trabalho *Development of Brain-Controlled Wheelchair Supported by Raspicam Image Processing based Raspberry pi* do autor Arjon Turnip (TURNIP; HIDAYAT; KUSUMANDARI, 2017), foi desenvolvido um protótipo de uma cadeira de rodas inteligente, onde o objetivo é melhorar a qualidade de vida de pessoas que possuem dificuldades de mobilidade e que ao mesmo tempo proporcionam uma fácil manobrabilidade e segurança ao conduzir o equipamento. Neste artigo o autor propõe uma abordagem de bio sinais e não bio sinais como construção de seu sistema onde, temos comandos cerebrais sendo traduzidos para ações de

movimento do microcontrolador arduino, sensores ultrassônicos para auxiliar evitar colisões, uma raspicam para detecção de obstáculos com visão computacional e uma unidade de medição inercial para controlar a velocidade em rampas. Segundo o autor, a cadeira de rodas inteligente é controlada pelo cérebro usando o Mitsar-EEG systems, como hardware de aquisição de dados, e então o sinal adquirido é pré processado usando o domínio da frequência e então enviado para o algoritmo de classificação que no caso é utilizado o método adaptativo de neuro fuzzy (do inglês Adaptive Neural Fuzzy Detection System (ANFIS)), sendo que os sinais são classificados em quatro classes: menos de 7 Hz, 7 - 12 Hz, 12,1 - 13 Hz e maior que 17 Hz para indicar parada, esquerda, frente, e direita, respectivamente.

No trabalho *Emotiv EPOC BCI with Python on a Raspberry pi* do autor José Salgado Patrón (PATRÓN; MONJE, 2016), na qual foi proposto um fluxo de controle utilizando um Support Vector Machine (SVM) classificador para controlar um braço robótico, onde o equipamento de coleta de sinais cerebrais foi utilizado o EEG *Emotiv EPOC+* e após o recebimento dos dados, o autor faz dois procedimentos no pré-processamento, sendo o primeiro a conversão dos dados para o domínio da frequência, e a segunda a padronização específica é aplicada devido à necessidade das amostras estarem dentro da mesma variância unitária e gaussianas com média zero, vale ressaltar que a biblioteca utilizada foi a *StandardScaler* (SKLEARN, 2022), após esse processamento os dados são enviados ao SVM para treinamento. Para o BCI proposto o autor criou 4 SVM distintos um para cada movimento do braço robótico mapeado com a ação do usuário, para sinais de relaxamento e concentração o braço abre e fecha respectivamente, para esquerda e direita utilizou a piscar dos olhos esquerdo e direito e com o balançar da cabeça o braço gira sobre a base seguindo o sentido da cabeça. O trabalho de José Salgado Patrón descreve o processo de avaliação do experimento sendo um experimento simples realizado para testar o BCI. Neste teste, o usuário teve que mover duas peças de formas específicas em caixas de diferentes formas, assim, testando a veracidade das ações, foi concluído que a melhora no sistema de controle aumenta após a segunda sessão de 10 tentativas na média dos usuários do experimento, sem precisar de nenhuma alteração nos modelos preditivos, de modo a reconhecer de que o usuário que está se adaptando ao sistema de controle.

No trabalho *Implementation of Brain Controlled Robotic Car to Assist Paralytic and physically Challenged People by Analyzing EEG Signals* o autor Sankar (SANKAR, 2020) desenvolveu um sistema na qual ajuda a controlar o carro robótico para o local desejado por meio de um piscar de olhos utilizando o EEG da *Neurosky*. Como fluxo da interface de controle foi proposto um sistema na qual quando começa a funcionar, o carro robótico se move aleatoriamente e

sempre que uma piscada de olhos é detectada o carro vira para a frente se duas piscadas são detectadas o carro vira para trás se três piscadas são detectadas carro vira à esquerda, se quatro piscadas forem detectadas, o carro vira à direita. Se algum sinal anormal ou nenhum piscar for detectado, o carro robótico para. O trabalho de Sankar traz uma contribuição interessante no quesito de meios avaliativos do BCI, na qual o usuário tinha como objetivo locomover o carro robótico até um alvo, e desse modo foi possível validar que mesmo o experimento sendo realizado por pessoas com e sem deficiência motora era possível executar o experimento com sucesso, validando o uso do BCI para se locomover sem a ajuda de dependências externas, segundo o autor mesmo quando ocorria algum erro no trajeto ele era corrigido rapidamente pelo usuário.

No trabalho *Cognitive Efficiency in Robot Control by Emotiv* o autor Pritom Chowdhury (CHOWDHURY *et al.*, 2014) desenvolveu um robô de duas rodas com intuito de ajudar pessoas com incapacidade motoras, o protótipo é controlado utilizando o EEG *Emotiv EPOC*, a proposta de BCI é composta de uma interface de controle com 4 comandos: frente, atrás, esquerda e direita, onde era representado por ações que o próprio usuário escolhia, podendo ser ação das mãos voluntárias ou imaginárias ou força de atenção. O autor utilizou do algoritmo de treinamento da rede neural do fornecedor do hardware para desenvolver seu fluxo de controle, mesmo não tendo acesso às métricas de treinamento ou ao algoritmo o autor descreve como funciona seu fluxo de treinamento e seus resultados, onde cada ciclo de coleta de dados de treinamento leva 8 segundos e cada comando foi executado 5 vezes, e para suprir a falta de não possuir a resposta da rede, devido ser um algoritmo do fornecedor, eles executaram uma bateria de testes antes do experimento prático e após o treinamento da rede, na qual o aplicador do experimento falava ao usuário algum comando aleatório, entre os 4 possíveis, e nisso validaram visualmente se ação foi predita corretamente ou não, sendo 250 comandos aleatórios por usuário, além disso o autor utiliza do método de tally para calcular a eficiência da faixa etária.

Segundo Pritom Chowdhury, seu trabalho contemplou dez usuários, sendo que foi utilizado uma entrevista semi-estruturada ao final do experimento para entender melhor como foi a experiência da interface de controle proposta, desse modo chegou-se a algumas conclusões, como a maior dominância de alguns comandos, e pior desempenho em outras, outro caso que ocorreu em todas usuários do experimento era que o comando da direita estava dominando o comando esquerdo. Outra conclusão notada pelo autor foi que não houve diferença notável nos resultados do experimento com base no gênero.

Como no trabalho de Pritom Chowdhury a ação de controle não era fixa para todos usuários, o autor coletou alguns relatos durante a entrevista, onde 5% dos usuários sentiram que o dispositivo funciona bem quando movem as mãos e 2% sentiram que o dispositivo funciona melhor logo após um comando ter sido treinado. Segundo o autor, foi relatado que alguns usuários pensavam em uma determinada direção e o robô movia em outras direções, além disso 75% dos usuários sentiram que funciona melhor quando imaginam qualquer coisa em vez de ficar imaginando um objeto se mover para esquerda, direita, frente ou trás mostrando que esse tipo de comando mental acaba sendo muito abstrato e confuso para o usuário.

No trabalho *ChronoNet: A Deep Recurrent Neural Network for Abnormal EEG Identification* do autor Subhrajit Roy (ROY; KIRAL-KORNEK; HARRER, 2019), foi proposta uma nova arquitetura de rede neural inspirado em trabalhos de classificação de imagem utilizando uma rede neural recorrente, onde o autor a denomina ChronoNet. O objetivo do trabalho é classificar se os dados vindo de um EEG eram normais ou anormais, a fim de acelerar o processo de identificação de estado clínico de um paciente. Para o estudo foi utilizado como dados de entrada o *dataset* TUH Abnormal EEG Corpus, onde é fornecido dados puros de um EEG onde possui o mapeamento de quais amostras são dados anômalos, o autor não utiliza de nenhum método de pré processamento sendo os dados puros de série temporal do EEG como forma de entrada, de modo que a partir desses dados a rede ela consegue aprender a reparaçao significativa de padrões de atividades cerebrais.

Segundo o autor, o trabalho usa como inspiração as redes de Convolutional Gated Recurrent Neural Networks (C-RNN), onde possuem uma sequência de uso de blocos de convolução antes de chegar nas unidades de Gated Recurrent Unit (GRU) ou LSTM. Desse modo, o que chega para os portais de entrada das redes recorrentes são mapas de características melhores adaptados para o contexto, fazendo com que a RNN aprenda de forma mais otimizada na medida do tempo, da série temporal. Para facilitar a reutilização da rede em outros equipamentos de EEG que possuem os dados enviados em maiores ou menores volumes por segundo, foi usado a *inception* inclusa na C-RNN a Inception Convolutional Gated Recurrent Neural Network (IC-RNN). Além disso, inspirado nos modelos de *denseNet* utilizados em problemas de segmentação de imagem que vem com o propósito de melhorar o mapeamento de característica, os autores incorporaram às skip connection nas camadas GRU empilhadas de IC-RNN para formar a arquitetura Inception Convolutional Densely Connected Gated Recurrent Neural Network (IC-DRNN), onde cada GRU é conectada a todas as outras camadas GRU de forma feed-forward, intuitivamente, a *skip connection* fará com que as camadas GRU sejam ignoradas

quando os dados exigirem uma complexidade de modelo menor do que a oferecida por toda a rede, desse modo segundo o autor inspirando na IC-DRNN surge a *ChronoNet*.

Como conclusão do trabalho Subhrajit Roy, o autor chegou que a rede *ChronoNet* se torna um nível bem complexo de redes, desse modo necessita de um volume grande de dados para ser treinada, em seu trabalho utilizou de *dataset* que possui uma taxa de frequência de dados de 250 Hz, 15000 pontos por segundo. Outra conclusão, é que o autor não vê diferença para o problema em questão de utilizar LSTM ou GRU, entretanto o tempo de treinamento aumenta devido a LSTM ter mais parâmetros. Além disso, vale pontuar, que o autor relata em seu trabalho, que é necessário alterar tamanhos dos blocos de *inception* e de unidades GRU a medida que tem mais ou menos volumes de dados por segundo, a fim de evitar o *overfit* sobre um modelo com maior complexidade do que necessário.

No trabalho Consistency of Feature Importance Algorithms for Interpretable EEG Abnormality Detection do autor Felix Knispel (KNISPEL *et al.*, 2022), foi construído uma rede neural com bandas de frequência EEG multicanal como entrada, vale pontuar que esse trabalho foi uma continuação do trabalho anterior (MORTAGA; BRENNER; KUTAFINA, 2021) do mesmo autor, sendo que sua contribuição para área está no fato de ter substituído a forma de entrada dos dados na rede neural, de dados puros que segundo o autor são difíceis de compreender, por bandas de frequência clinicamente relevantes. Para avaliação da rede foi utilizado o *dataset TUH Abnormal EEG Corpus v2.0.0*, onde é fornecido dados puros de um EEG com o mapeamento das amostras anômalas, durante o pré processamento o autor filtrou por banda (1-50 Hz) e depois divididos em 11 janelas deslizantes, cada uma com 10 segundos de duração com uma sobreposição de 5 segundos, onde cada segmento foi verificado em relação a um limiar de amplitude máxima, se mais de 50% de todos os eletrodos excederam esse limite, o segmento foi removido. Por fim, em cada segmento restante, calculamos a densidade espectral de potência (Densidade Espectral de Potência (PSD)) para as cinco faixas de frequência clinicamente relevantes (*delta*: 1-3 Hz, *theta*: 4-7 Hz, *alpha*: 8-13 Hz, *beta*: 14-30 Hz, *gamma*: >30 Hz) usando o método de Welch com janela de Hann e 50% de sobreposição, e cada segmento foi transformado em uma matriz 5x5x7 que pode ser interpretada como uma imagem 5x7 com cinco canais correspondentes às cinco bandas de frequência. Para o estudo, foi construído um modelo de redes neurais que usa características baseadas em frequência interpretáveis extraídas dos dados brutos de EEG, o uso de uma CNN preserva as informações sobre a posição espacial dos eletrodos, além disso devido à divisão de cada registro de EEG em 11 segmentos, foi entendido pelo autor que nem todos os segmentos de um EEG anormal exibem morfologias

anormais, isso pode resultar em uma precisão de classificação diminuída, pois possivelmente segmentos de aparência normal são rotulados como anormais, para mitigar este problema, foi implementado um mecanismo de votação como em (BRENNER; KUTAFINA; JONAS, 2018).

No trabalho *EEG-based emotion recognition using LSTM-RNN machine learning algorithm* do autor Reddy Koya Jeevan (JEEVAN et al., 2019), foi proposto uma nova arquitetura de rede neural para realizar a predição das emoções, segundo o autor foi utilizado como hardware de aquisição de dados o EEG de 32 canais Virgo, os sinais coletados são processados usando a transformada discreta de *wavelet*, em seguida, dada ao algoritmo proposto para reconhecimento de emoções.

No trabalho *Classification of P300 based brain computer interface systems* de Ali Osman Selvi (SELVI; FERIKOĞLU; GÜZEL, 2021), é apresentado uma proposta de uma rede neural para um sistema de BCI para fazer a classificação de estímulos de imagens usando redes neurais Bidirectional Long-Short Term Memory (Bi-LSTM). Segundo o autor do estudo, os dados foram coletados através de um EEG da *Emotiv EPOC+*, e durante a sua utilização, foi apresentado na tela de um monitor um estímulo visual podendo ser médico, polícia, bombeiro e família, como protocolo de coleta de dados, foram utilizados 200 ms de tempo de estímulo e 300 ms de intervalo entre estímulos.

No artigo *emotion brain-computer interface using wavelet and recurrent neural network* o autor Esmeralda Contessa Djamal (DJAMAL et al., 2020), propôs um BCI para controlar um simulador de robô baseado em três emoções. O autor utiliza o domínio da frequência separado nas ondas *theta*, *alpha* e *beta* como dados de entrada da rede e como algoritmo de treinamento uma neural de treinamento uma RNN composta por duas LSTM em sequência junto a uma camada densa como camada de saída. Vale pontuar que a conclusão do trabalho de Esmeralda Contessa Djamal é muito pertinente pois demonstra que para análise de emoção quando não se utiliza o pré processamento com faixas de ondas, a acurácia cai de 70% para 39%, onde segundo o autor isso demonstra que quando tentamos analisar informações como emoção que é uma informação complexa e abstrata de forma neuro clínica o uso das ondas ao invés de dado puro acaba fazendo com que a rede aprenda melhor.

No trabalho *Brain Controlled Car using Deep Neural Network* do autor Amit Kumar (KUMAR et al., 2019), o objetivo principal era controlar um carro robótico utilizando um EEG *Neurosky Mind*, o objetivo do trabalho era ajudar pessoas que sofrem de deficiência e síndrome do movimento. A rede neural utilizada durante o treinamento da BCI foi uma Multilayer Perceptron (MLP) com 3 camadas, como o hardware já possui como *output* dos dados no domínio

da frequência *alpha*, *beta*, *gamma*, *theta* e *delta*, desse modo o pré-processamento dos dados brutos ficava como responsabilidade o próprio software do fabricante, após esse processamento os dados eram enviados para rede neural onde a saída resultará na direção do carro para avançar, retroceder, esquerda, direita ou parar. Mesmo o autor não especificamente de modo claro, quais foram as ações envolvidas no processo de treinamento, ou uma avaliação de seu modelo estatístico ou do BCI, seu trabalho traz uma proposta de fluxo de dados interessante e que faz bastante sentido ao ser utilizado em uma interface de controle de um carro robótico, ou estendido para uma cadeira de rodas elétrica.

No trabalho *Automated EEG pathology detection based on different convolutional neural network models: Deep learning approach* de Rishabh Bajpai (BAJPAI; YUVARAJ; PRINCE, 2021), foram utilizadas 3 arquiteturas distintas de CNN para geração do mapa de característica junto ao SVM para classificar, desse modo comparar qual o desempenho das redes para o problema de detecção de patologias em sinais de EEG no *dataset TUH Abnormal EEG Corpus* (HARATI *et al.*, 2014), sendo elas a *DenseNet*, *Inception-ResNet v2* e *SeizureNet*, como o *dataset* é composto pelo dado puro de um EEG, o autor utiliza da transformada rápida de *fourier* para converter os 22 canais para o domínio da frequência, sendo que após essa conversão foi escolhido dois canais Temporal 5 (T5)-Occipital 1 (O1) e o Frontal 4 (F4)-Cortex 4 (C4) para serem os dois tipos de *dataset* diferentes para treino, teste e validação, isso preciso ser feito devido a conclusão que o autor chegou na qual este estudo é limitado pela utilização apenas de gravação de EEG de canal único, onde o atual pipeline de treinamento e teste, quando estendido a todos os canais foi experimentalmente ineficaz devido à falta de informações úteis nos outros canais, e na falta de interpretabilidade que essa ocorrência faz com que as redes não conseguissem aprender.

No Quadro 1 é possível ver de forma resumida um comparativo entre esse trabalho e os 16 trabalhos encontrados durante a revisão sistemática através de uma reverencia cruzada. Além disso, vale destacar que na última linha do Quadro 1 encontra-se a referência a este trabalho, demonstrando uma comparação entre os demais trabalhos e este.

Quadro 1 – Referencia Cruzada

Trabalho	Dados	Extração de Características	Algoritmo	BCI	Ação
(LEVICÁN <i>et al.</i> , 2017)	<i>Emotiv Insight 2</i>	Própria do fabricante	Própria do fabricante	controlar a síntese de som pelo MaxMSP	bandas de frequência, expressões faciais, estados mentais
(HOQ <i>et al.</i> , 2018)	<i>Emotiv Insight</i>	Própria do fabricante	Própria do fabricante	controlar um aplicativo de celular	força da atenção
(GRANDINI <i>et al.</i> , 2017)	<i>Emotiv Insight 2</i>	Própria do fabricante	Própria do fabricante	controlar um teclado virtual	força da atenção
(SCHUH <i>et al.</i> , 2013)	EEG da <i>Neurosky</i>	Própria do fabricante	Própria do fabricante	controlar um simulador de cadeira de rodas	Piscar dos olhos
(CHAURASIA; MISHRA; JAIN, 2016)	EEG da <i>Neurosky</i>	Própria do fabricante	Própria do fabricante	Controle de um carro robótico	Piscar dos olhos e o estado mental

Continua na próxima página

Quadro 1 – Continuação do quadro

Trabalho	Dados	Extração de Características	Algoritmo	BCI	Ação
(TURNIP; HIDAYAT; KUSUMAN-DARI, 2017)	Mitsar-EEG systems	Domínio da frequência	Adaptive neuro fuzzy inference system (ANFIS)	Controle de um cadeira de rodas	Os sinais são classificados em quatro classes: menos de 7 Hz, 7 - 12 Hz, 12,1 - 13 Hz e maior que 17 Hz para indicar parada, esquerda, frente, e direita.
(PATRÓN; MONJE, 2016)	EEG Emotiv Epoch+	Domínio da frequência	SVM	Controle de um braço robótico	Piscar dos olhos, estado mental e balanço da cabeça
(SANKAR, 2020)	EEG da Neurosky	Não especificado	Não especificado	Controle de um carro robótico	Piscar dos olhos
(CHOWDHURY <i>et al.</i> , 2014)	EEG Emotiv Epoch+	Própria do fabricante	Própria do fabricante	Controle de um carro robótico	força da atenção

Continua na próxima página

Quadro 1 – Continuação do quadro

Trabalho	Dados	Extração de Características	Algoritmo	BCI	Ação
(ROY; KIRAL-KORNEK; HARRER, 2019)	Dataset TUH Abnormal EEG Corpus	Dados de EEG puros	ChronoNet	Não utilizado	Não utilizado
(KNISPEL <i>et al.</i> , 2022)	Dataset TUH Abnormal EEG Corpus v2.0.0	Domínio da frequência	CNN	Não utilizado	Não utilizado
(JEEVAN <i>et al.</i> , 2019)	32-channel EEG system Virgo	Domínio da frequência	LSTM, CNN, MLP e LSTM + CNN	Não utilizado	Não utilizado
(SELVI; FERI-KOĞLU; GÜZEL, 2021)	EEG Emotiv Epoch+	Domínio da frequência	Bi-LSTM, 1DCNN e SVM	Não utilizado	Não utilizado
(DJAMAL <i>et al.</i> , 2020)	<i>Emotiv Insight</i>	Combinados	LSTM	Não utilizado	Não utilizado
(KUMAR <i>et al.</i> , 2019)	EEG Neurosky Mind	Domínio da frequência	MLP	Controle de um carro robótico	Não especificado

Continua na próxima página

Quadro 1 – Continuação do quadro

Trabalho	Dados	Extração de Características	Algoritmo	BCI	Ação
(BAJPAI; YUVARAJ; PRINCE, 2021)	Dataset TUH Abnormal EEG Corpus	Domínio da frequência	DenseNet, Inception-ResNet v2 e Seizure-Net	Não utilizado	Não utilizado
FTL	EEG Emotiv Insight 2.0	Domínio da frequência	Variação da ChronoNet, CNN e LSTM	Controle de um carro robótico	Ação motora dos membros superiores

Fim do quadro

Fonte: Elaborado pelo autor.

Como citado no início deste capítulo, os trabalhos apresentados anteriormente se dividem em dois grupos de pesquisa, sendo eles o que possuem estudos de arquiteturas de redes neurais próprias, mas não possuem um BCI implementado e aqueles que possuem um BCI mas utilizam do algoritmo de aprendizado de máquina disponibilizado pelos fabricantes dos EEG. Como o objetivo desse trabalho é avaliar algoritmos de aprendizado de máquina em interface cérebro máquina para controlar objetos com motores elétricos, então foi utilizado abordagens encontradas nos dois grupos de estudo, sendo elas: O uso do EEG *Emotiv Insight 2.0* devido sua boa referência em trabalho que utilizam BCI modernos, como é o caso dos trabalho (LEVICÁN *et al.*, 2017),(HOQ *et al.*, 2018),(GRANDINI *et al.*, 2017) e (DJAMAL *et al.*, 2020). A utilização do domínio da frequência como entrada das redes, devido ter uma menor abstração do que os dados puros e possuir melhor resultados como é possível notar pelo trabalho (DJAMAL *et al.*, 2020).

Vale pontuar, na qual a escolha da ação utilizada para execução do BCI, foi escolhida uma diferente das demais, justamente pois foi notado nos trabalhos apresentados que utilizam o piscar dos olhos, força de atenção ou até mesmo o balançar da cabeça, não possuíam uma boa

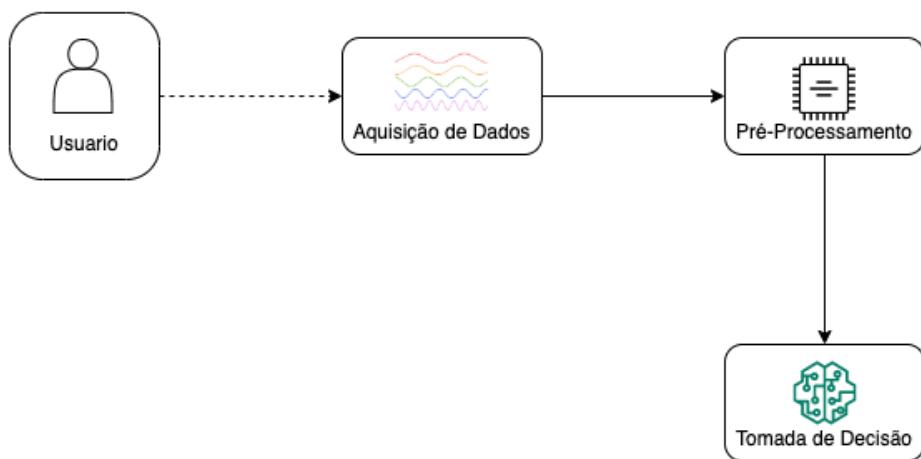
controlabilidade, sendo que alguns autores como é o exemplo de (CHOWDHURY *et al.*, 2014) e (GRANDINI *et al.*, 2017), registram em seus trabalhos que essas ações não são boas para compor uma interface de controle, até porque o uso dessas ações como interface não torna o sistema intuitivo, muito menos simples para um usuário leigo. Além do mais, é possível dizer que elas ferem três das heurísticas de Nielsen: facilidade de navegação, simplicidade e foco no usuário (NIELSEN, 1994), uma vez que ficar piscando o olho ou ter que lembrar o que significa força de atenção acaba sendo muito complicado para o usuário interagir, e fazendo com que ele aprenda a controlar um sistema que ele não possuía nenhum tipo de memória afetiva anterior com aquela interface. Por essa razão esse trabalho, adotou o uso de ações motoras dos membros superiores, para fazer o controle do carro robótico, sendo que movimentar o membro superior esquerdo seja correspondente com rotacionar o robô para esquerda, movimentar o membro superior direito seja correspondente com rotacionar o robô para direita e a ausência de movimentos de membros superiores o robô irá seguir em frente.

No que diz respeito à utilização do algoritmo de aprendizado de máquina junto à arquitetura empregada no trabalho, será apresentado no capítulo de metodologia.

3 METODOLOGIA

Com o intuito de validar a proposta deste trabalho e tornar os experimentos reprodutíveis, nas subseções a seguir são descritas as etapas para construir o *dataset* e a metodologia utilizada para realizar o treinamento dos algoritmos de redes neurais utilizados por esse trabalho, veja de forma geral o fluxo de dados na Figura 2.

Figura 2 – Fluxograma de forma específica da metodologia de trabalho



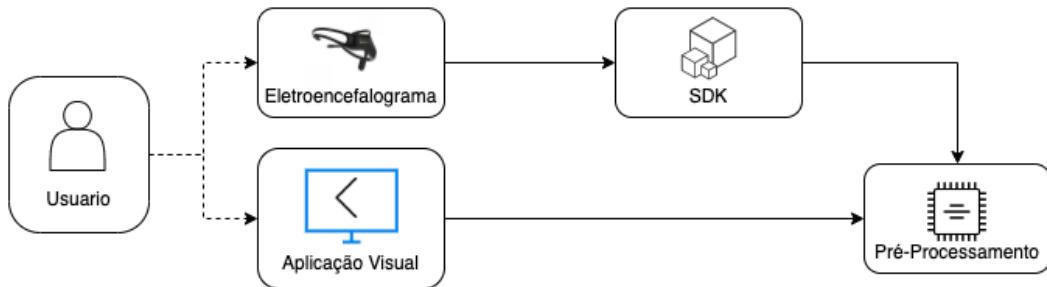
Fonte: Elaborado pelo autor.

3.1 AQUISIÇÃO DE DADOS

Partindo da primeira e segunda caixa do diagrama apresentado na Figura 3, temos os dois principais agentes desta fase da metodologia, sendo eles o usuário do sistema e o meio de aquisição de dados. No quesito aquisição de dados podemos utilizar como referência os trabalhos (LEVICÁN *et al.*, 2017), (HOQ *et al.*, 2018) e (GRANDINI *et al.*, 2017), isso devido a semelhança nos objetivos de trabalho, criar um sistema de controle baseado em ondas cerebrais, esses autores utilizaram um eletroencefalograma (EEG) de 5 canais, Antero Frontal 3 (AF3), Antero Frontal 4 (AF4), Temporal 7 (T7), Temporal 8 (T8), Pz, vale mencionar que esse tipo de EEG mesmo possuindo menos canais do que outros sensores encontrados em mercado, os autores tiveram bons resultados em seus trabalhos e por se tratar de um projeto voltado a tecnologia assistiva, a relação custo/benefício se torna um requisito importante, visto que quanto mais barato e de boa qualidade o projeto ser, melhor será sua aceitação pela comunidade. Vale mencionar que atualmente os sensores encontrados no mercado estão sendo

vendidos juntamente com os seus *Software Development Kit (SDK)*, onde por sua vez toda a interface de comunicação entre o sensor e a máquina conectada acaba se tornando abstrata para o desenvolvedor.

Figura 3 – Diagrama de um ciclo de aquisição de dados



Fonte: Elaborado pelo autor.

Para um usuário utilizar os algoritmos de redes neurais desse trabalho, é necessário que seus impulsos cerebrais sejam coletados e pré-processados para a geração do *dataset*, além disso vale pontuar que as BCI para a reabilitação de deficiências motoras exploram os Ritmos Sensório-Motores (SMR). No entanto, os processos neurofisiológicos que sustentam o SMR geralmente variam ao longo do tempo e entre os indivíduos. A variabilidade intra e interindividual inerente causa mudanças de co-variáveis nas distribuições de dados que impedem a transferibilidade dos parâmetros do modelo entre sessões/sujeitos segundo Simanto Saha (SAHA; BAUMERT, 2020), na qual demonstra que devido a natureza do SMR junto às diferenças existentes entre cada pessoa quando se compara o comportamento das ondas cerebrais, cada usuário realizava apenas uma vez o protocolo de coleta de dados com EEG, e seus dados não são misturados nem intra ou inter-sujeitos como visto no trabalho (SAHA; BAUMERT, 2020).

Segundo Felix Knispel (KNISPEL *et al.*, 2022) as condições de olhos fechados/abertos manifestam-se no lobo occipital, fazendo com que ocorra grande flutuação da onda alfa nessa região do cérebro, em razão disso e a fim de evitar a especialização dos modelos e garantir uma generalização da rede neural em cima dos dados coletados, esse trabalho utiliza um protocolo de coleta composto por doze ciclos de aquisição, ver Quadro 2, na qual combina atividades motoras dos membros superiores junto a eventos de olhos abertos ou fechados, sentado ou em pé:

Quadro 2 – Protocolo de Coleta

Ciclo de Aquisição	Detalhamento da Ação de Coleta	Referencial da Ação
1	Participante sentado com os olhos abertos, apertando uma bola estimuladora sensorial em formato de pinça	Figura 4
2	Participante sentado com os olhos abertos, movimentando a palma da outra mão para cima e para baixo	Figura 5
3	Participante sentado com os olhos fechados, apertando uma bola estimuladora sensorial em formato de pinça	Figura 4
4	Participante sentado com os olhos fechados, movimentando a palma da outra mão para cima e para baixo	Figura 5
5	Participante em pé com os olhos abertos, apertando uma bola estimuladora sensorial, com o polegar para fora apontando para cima e rotacionando a mão para dentro	Figura 6
6	Participante em pé com os olhos abertos, estalando os dedos	Figura 7
7	Participante sentado com os olhos abertos, apertando uma bola estimuladora sensorial	Figura 8
8	Participante sentado com os olhos abertos, abrindo e fechando a mão	Figura 9
9	Participante em pé com os olhos fechados, apertando uma bola estimuladora sensorial	Figura 8
10	Participante em pé com os olhos fechados, abrindo e fechando a mão	Figura 9
11	Participante sentado com os olhos fechados, apertando uma bola estimuladora sensorial, com o polegar para fora apontando para cima e rotacionando a mão para dentro	Figura 6
12	Participante sentado com os olhos fechados, estalando os dedos	Figura 7

Fonte: Elaborado pelo autor.

Figura 4 – Mão em formato de pinça



Fonte: Elaborado pelo autor.

Figura 5 – Palma da mão para cima e para baixo



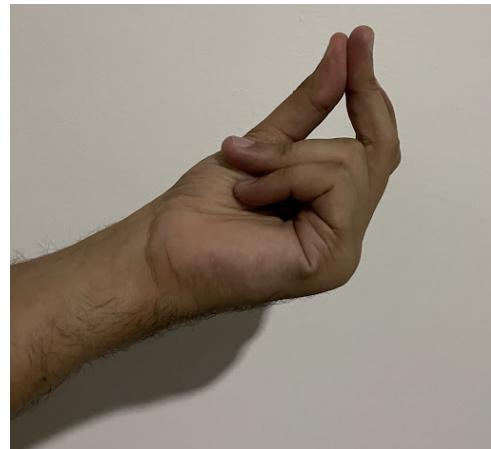
Fonte: Elaborado pelo autor.

Figura 6 – Apertando bola estimuladora com polegar para cima rotacionando para dentro



Fonte: Elaborado pelo autor.

Figura 7 – Estalando os dedos



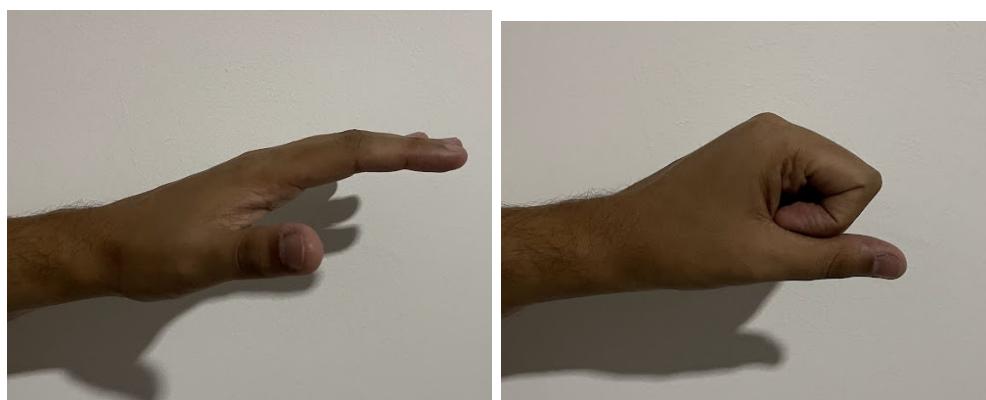
Fonte: Elaborado pelo autor.

Figura 8 – Apertando a bola estimuladora



Fonte: Elaborado pelo autor.

Figura 9 – Abrindo e fechando a mão.



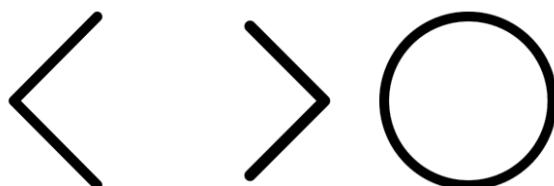
Fonte: Elaborado pelo autor.

Os movimentos utilizados no protocolo, com exceção do estalar de dedos, foram escolhidos com o intuito de estimular o cérebro no momento da coleta e assim registrando os impulsos

cerebrais durante os eventos, já que esses exercícios são de terapia para as mãos, o estalar de dedos foi arbitrariamente escolhido por apresentar bons resultados no início da dissertação.

Durante cada um dos ciclos, o usuário visualiza três imagens pelo período de 60 segundos cada uma delas, onde cada uma delas se correlaciona com uma ação motora voluntária: uma seta para a direita que representa ação motora da mão direita, uma seta para a esquerda que representa ação motora da mão esquerda e um círculo que representa nenhuma ação motora, Figura 10.

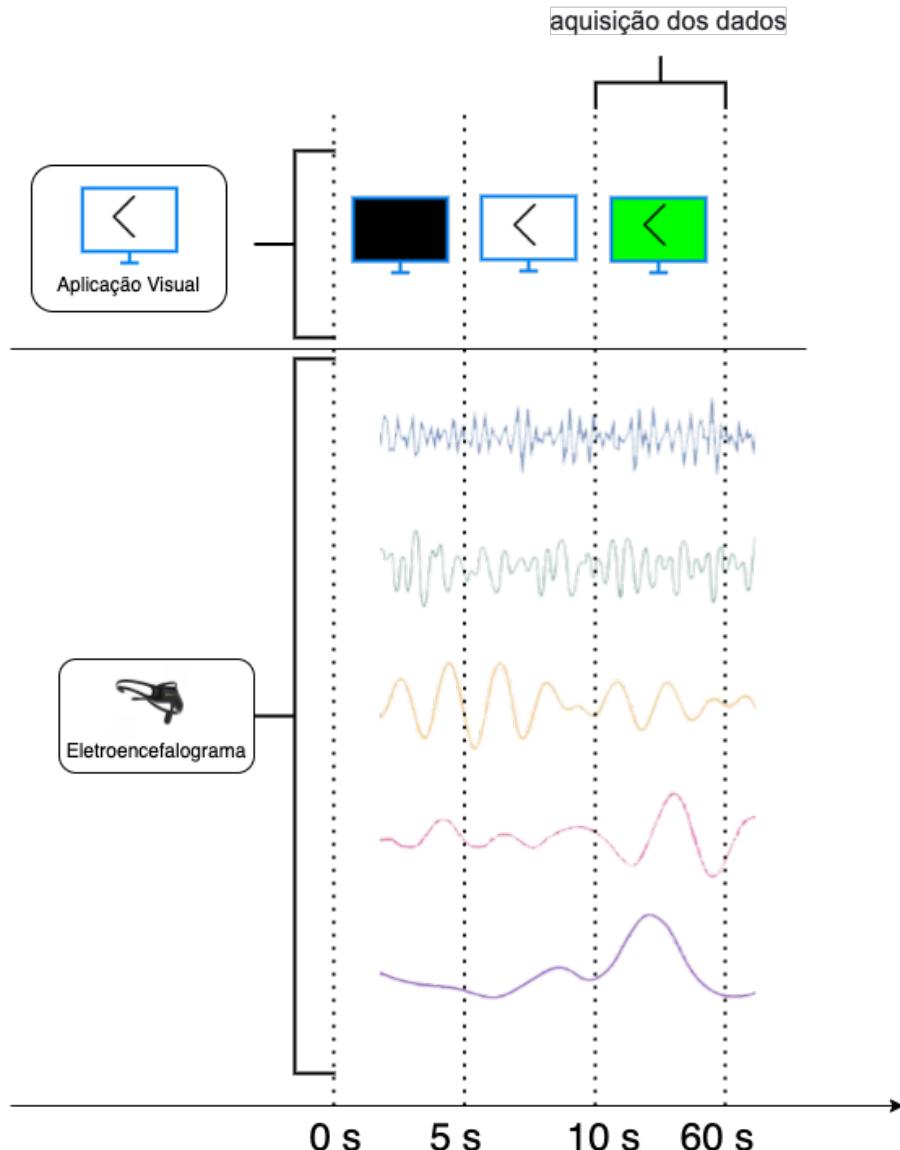
Figura 10 – Direções mostradas durante os ciclos de aquisição



Fonte: Elaborado pelo autor.

Um ciclo de aquisição é composto pela visualização das três imagens em três fases distintas cada, ver Figura 11, sendo a primeira fase uma imagem preta pelo período de 5 segundos, na qual representa o momento em que o participante pode relaxar, em um segundo momento a exposição de uma das três imagens citadas anteriormente com o fundo branco por um período de 5 segundos, esse momento serve como uma preparação para o participante saber qual a ação que ele irá tomar, sendo que durante essa fase os dados ainda não estão sendo coletados, e como última fase é apresentado a imagem com um fundo verde por 50 segundos, onde o usuário deve executar a ação proposta, sendo que somente nesse momento os dados coletados do EEG estão sendo salvos para futuramente serem pré-processados.

Figura 11 – Diagrama de um ciclo de aquisição de dados



Fonte: Elaborado pelo autor.

De modo a utilizar o mesmo sistema de aquisição nos ciclos que ocorrem com os olhos fechados, foi colocado um sinal sonoro no início de cada fase, desse modo o usuário sabe qual momento ele pode abrir os olhos para verificar qual ação deve tomar para só então fechar os olhos novamente para os dados coletados serem com ele de olhos fechado.

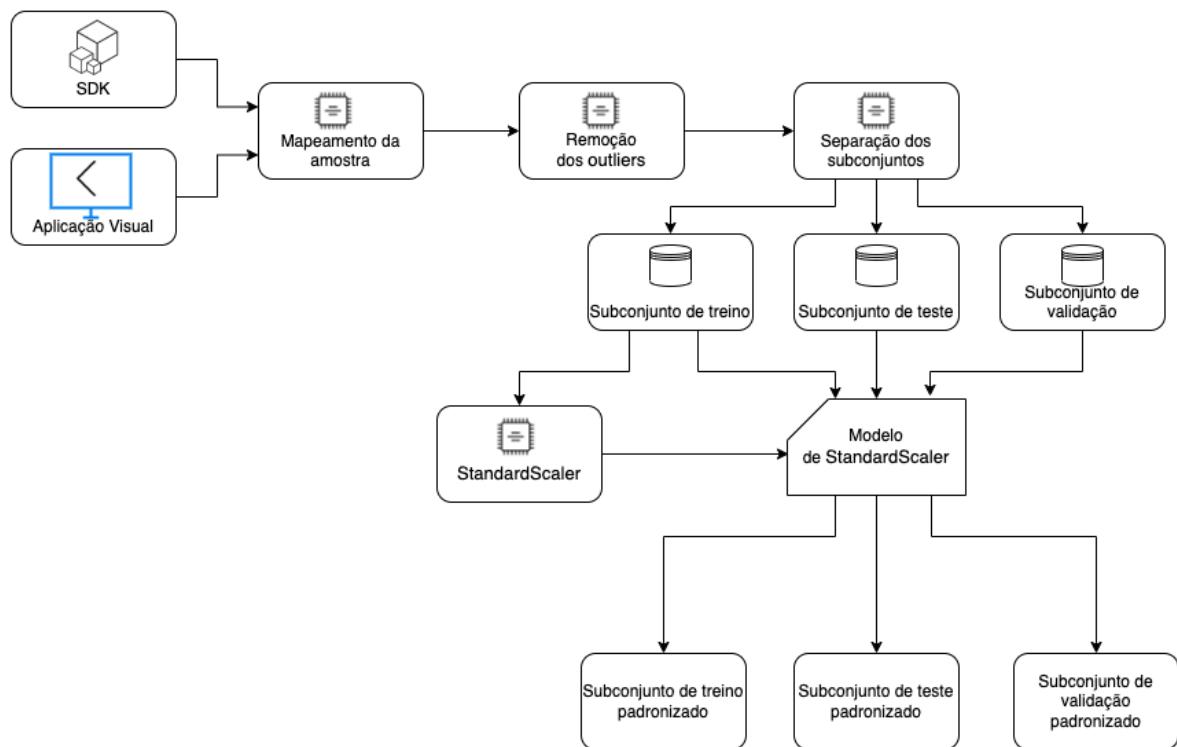
O protocolo de aquisição na qual é composto por tempos de relaxamento de 5 segundos junto a fase de pré coletas de 5 segundos foi baseado no trabalho de Afaz UI Hoq (HOQ *et al.*, 2018), onde o autor cita que esses momentos são de grande valia para obter um conjunto de sinais cerebrais mais puros sobre a ação desejada, consequentemente aumentando a qualidade

e pureza dos dados que serão futuramente pré-processamento.

3.2 PRÉ-PROCESSAMENTO DE DADOS

Durante essa seção será descrito de forma detalhada o pré-processamento, mas de forma sucinta a estratégia adotada por esse trabalho é dividido em quatro momentos, na qual a primeira etapa é realizada durante o mapeamento de cada amostra do *dataset*, onde será combinado os dados vindos do EEG via SDK mais a ação executada pelo usuário durante o momento de aquisição, podendo ser: movimentar membros superior esquerdo, direito ou nenhuma ação motora com membros superiores. Já em uma segunda fase é realizada a remoção das amostras que possuem algum *outlier*. Na terceira fase é quando ocorre a separação entre subconjuntos de treino, teste e validação. E por último, na quarta fase é quando ocorre o processo de padronização das amostras, sendo que somente após todos esses processos é possível ter um *dataset* válido para se utilizar no processo de tomada de decisão, veja Figura 12.

Figura 12 – Fluxograma da fase de pré-processamento dos dados



Fonte: Elaborado pelo autor.

Antes de apresentar a composição de uma amostra do *dataset*, é necessário relacionar qual o conteúdo dessa sua amostra. Quando mencionado na sessão 2.0 dados do EEG no

domínio da frequência, está relacionado a atividade neural na qual por muitas vezes possuir uma qualidade rítmica repetitiva, esses ritmos são classificados de acordo com suas frequências fundamentais e então denotados como ondas cerebrais (LEVICÁN *et al.*, 2017), essa dissertação optou em trabalhar com as 5 ondas cerebrais que o SDK do fornecedor disponibiliza: *alpha 1*, *alpha 2*, *beta*, *theta* e *gama*.

Na fase de mapeamento da amostra é quando ocorre a preparação dos atributos do *dataset*. Desse modo, será adicionado a cada registro o movimento que o usuário estava executando durante o tempo de coleta e os dados salvos durante a fase de coleta de dados apresentado na Figura 11, com o suporte do SDK do EEG que irá fornecer a uma taxa de 8 Hz as 5 ondas cerebrais dos 5 eletrodos, o *dataset* possui 14400 amostras, sendo 400 amostras por ação motora, no total de 1200 amostras por ciclo, como o protocolo deste trabalho possui 12 ciclos, o *dataset* construído após o mapeamento das amostras possui 14400 amostras igualmente destruídas.

Para a fase de remoção de *outliers* foi usado o trabalho de Nidal Rafiuddin (RAFIUDDIN; KHAN; FAROOQ, 2011) como base desse pré-processamento, na qual isso se faz necessário devido ao EEG ser um hardware que fica sob o couro cabeludo pode sofrer com ruídos eletrônicos ou até com falhas de sinal de comunicação e/ou coleta e desse modo ocasionando interferências nos valores salvos pelo SDK, a fim de eliminar esse problema foi utilizado a técnica de amplitude interquartil (do inglês *Interquartile Range (IQR)*) para remoção dos *outliers*, será melhor detalhado a utilização dessa técnica na Capítulo 5.

Como é visto no trabalho de José Salgado Patrón (PATRÓN; MONJE, 2016), as ondas cerebrais não ocupam um mesmo domínio de valores em seu contexto, resumindo enquanto a onda Beta do canal O2 varia entre 5 a 20 μ^1V , a onda *theta* do canal F8 varia de 0 a 10 mV. Desse modo, a próxima fase do pré-processamento é realizar o tratamento desses dados de modo a padronizar seu domínio. Vale pontuar que na literatura é possível encontrar trabalhos que utilizam de técnicas como *MinMax*, ou normalização, para tratar esse problema de variáveis com diferentes contextos, entretanto esse trabalho utilizou como base o trabalho de José Salgado Patrón (PATRÓN; MONJE, 2016), que optou pelo uso da técnica de *Standard Scaler*.

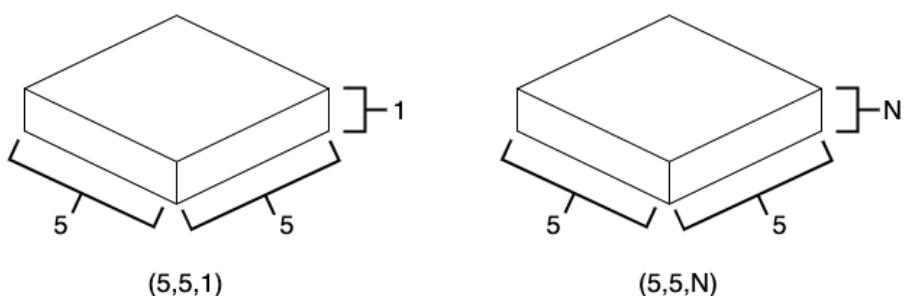
A Fim de preparar o *dataset* construídos até o momento para ser utilizado no treinamento de uma rede neural, o próximo passo do pré-processamento é justamente a divisão dos sub-conjuntos em treino, teste e validação a fim de utilizar a técnica de *hold-out*, na qual será

¹ μ Mi

apresentado com mais detalhes na Seção 5.1.

Por fim, a partir da Figura 13 é possível ver como é a composição espacial de uma amostra desse *dataset* construído até o momento, entretanto vale pontuar que para a sessão de tomada de decisão será apresentado que um dos algoritmos utilizados neste trabalho foi necessário incluir uma técnica de janelamento de N tempos em cada amostra a fim de ajudar a rede neural a aprender a partir de série temporal, assim como feito pelo trabalho de Felix Knispel (KNISPEL *et al.*, 2022).

Figura 13 – A esquerda composição espacial de uma amostra do dataset sem janelamento e a direita com janelamento.

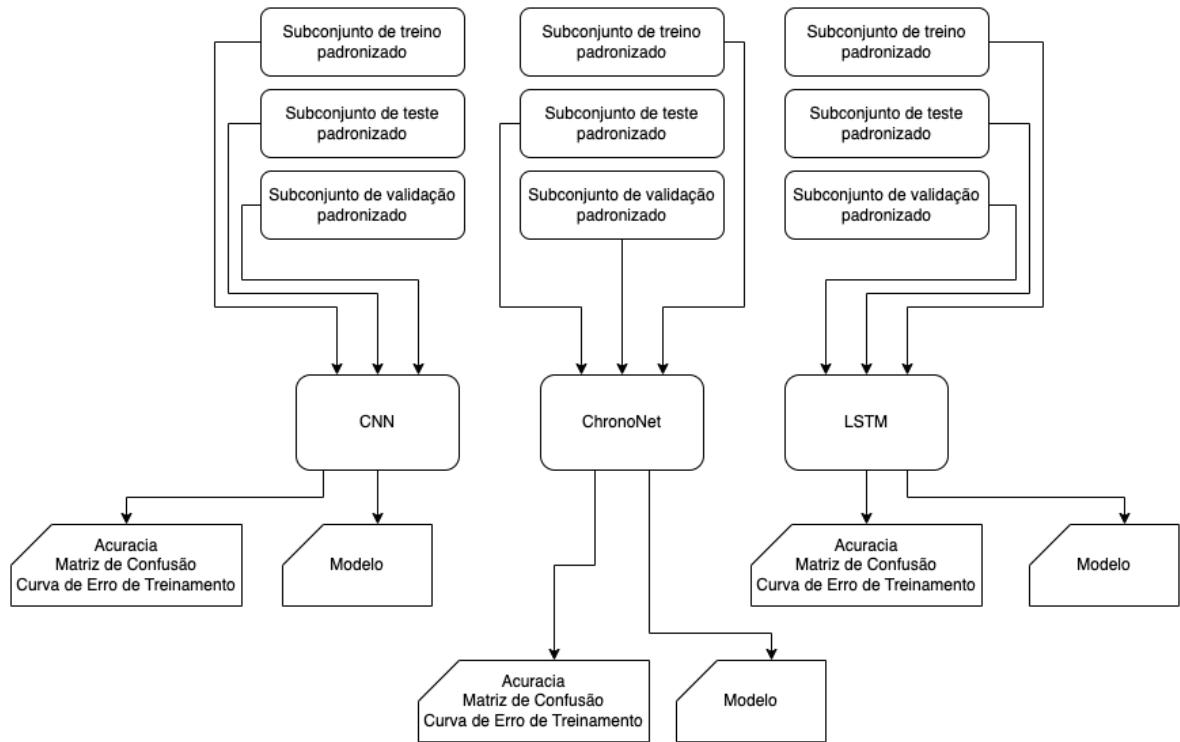


Fonte: Elaborado pelo autor.

3.3 TOMADA DE DECISÃO

Segundo Meysam Golmohammadi (GOLMOHAMMADI *et al.*, 2018) a interpretação do EEG por técnicas de aprendizado de máquina ganhou popularidade nos últimos tempos e segundo Roy (ROY *et al.*, 2019) cerca de 40% dos estudos de problemas que usam dados de EEG apresentados em sua revisão sistemática usam redes neurais convolucionais (CNNs) e 13% usam redes neurais recorrentes (RNNs). Desse modo, esse trabalho optou em utilizar 3 arquiteturas, sendo elas uma arquitetura tradicional de CNN, uma arquitetura de RNN e uma arquitetura de RNN com algumas variações à IC-DRNN proposta por Subhrajit Roy (ROY; KIRAL-KORNEK; HARRER, 2019) denominada *ChronoNet*. Na Figura 14 é possível observar os dados após serem pré-processados, qual seu fluxo durante a tomada de decisão junto com seus artefatos gerados no final do processo.

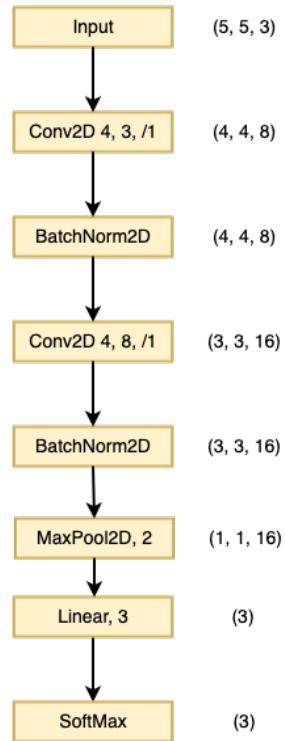
Figura 14 – Fluxograma da fase de tomada de decisão



Fonte: Elaborado pelo autor.

De modo a seguir a arquitetura tradicional da CNN proposta por LeCun (LECUN; BENGIO; HINTON, 2015), para este trabalho foi utilizado camadas de convolução com *max pooling*, e como variação da arquitetura de LeCun foi adicionado o *batch normalization* para diminuir o efeito do internal covariante, ver Figura 15.

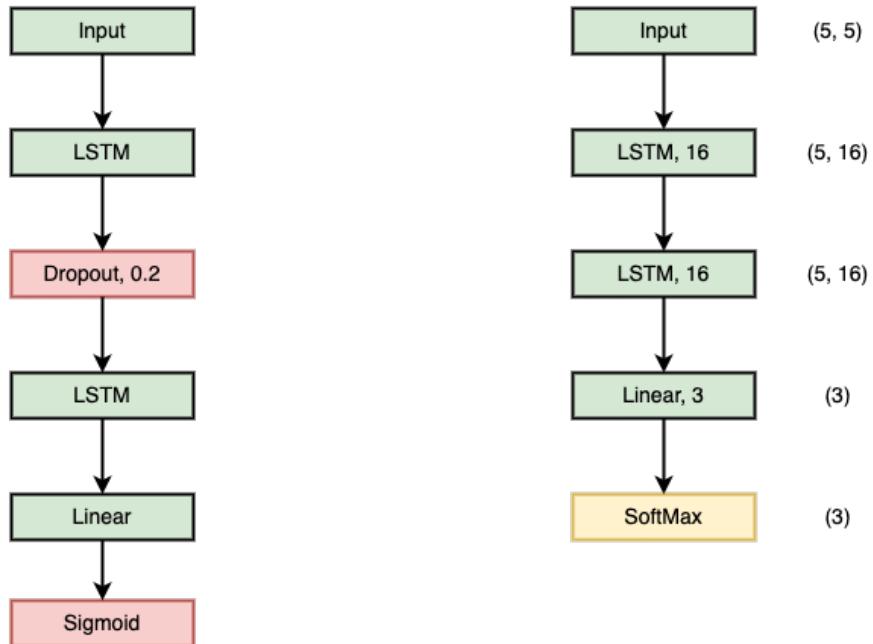
Figura 15 – Arquitetura do algoritmo de CNN utilizado



Fonte: Elaborado pelo autor.

Em relação a arquitetura de RNN, foi utilizado como base a proposta de (ALHAGRY; FAHMY; EL-KHORIBI, 2017), na qual possui como diferenças a retirada do *dropout* (SEMEINIUTA; SEVERYN; BARTH, 2016) e da função de ativação Rectified Linear Unit (ReLU) (AGARAP, 2018). Ficando assim, uma rede composta de uma LSTM com duas camadas empilhadas, seguida de uma camada linear simples acoplada a uma saída *softmax*, ver Figura 16.

Figura 16 – Do lado esquerdo arquitetura da RNN utilizado por (DJAMAL *et al.*, 2020) e do lado direito arquitetura da RNN utilizado neste trabalho. Em vermelho elementos retirados da arquitetura de Esmeralda Contessa Djamal e em amarelo elementos adicionados



Fonte: Elaborado pelo autor.

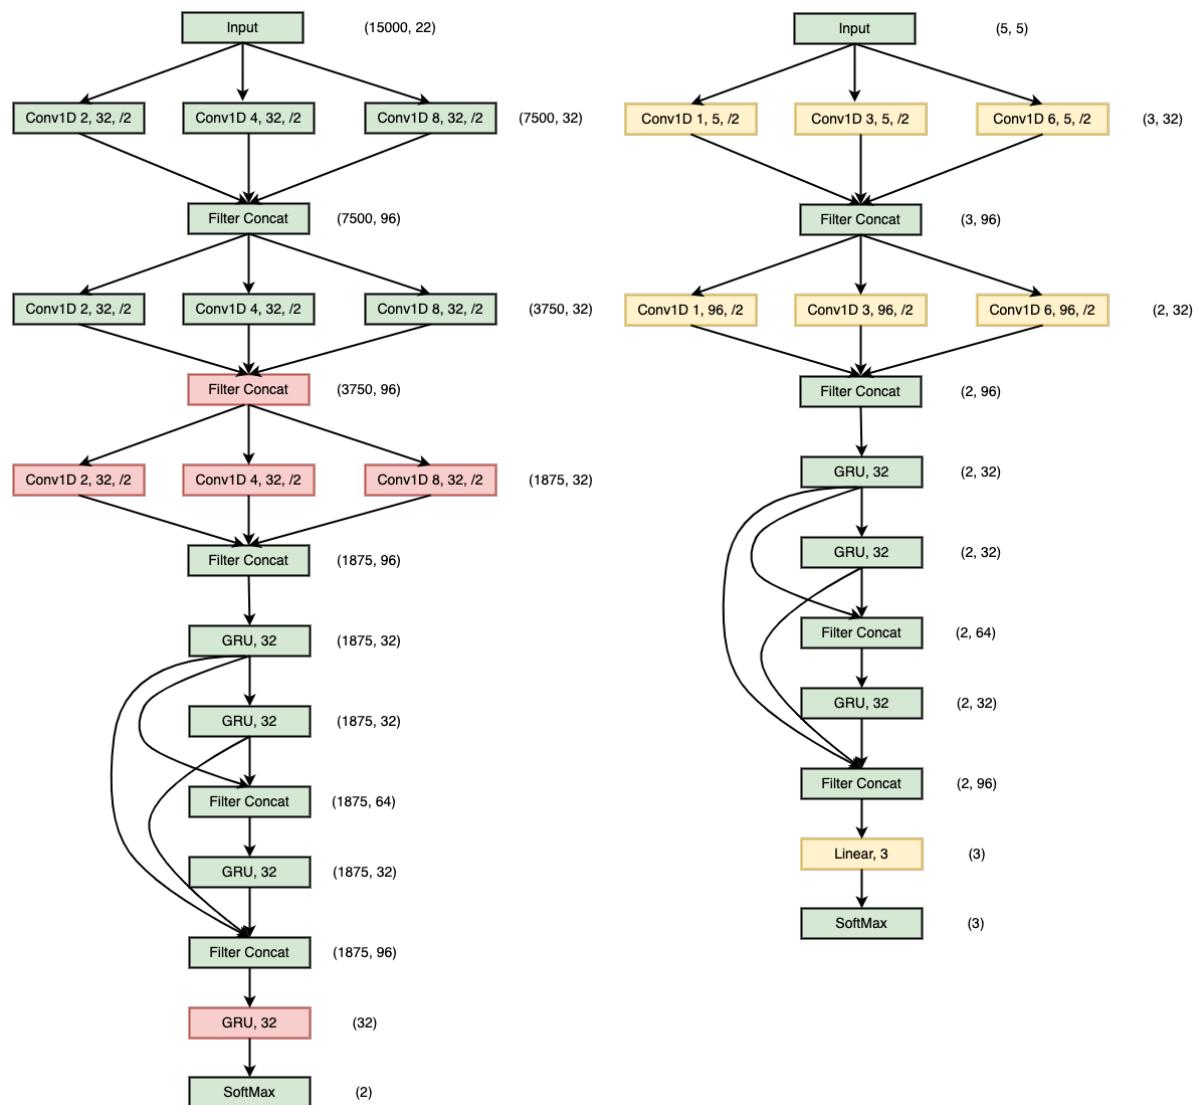
Segundo o autor Subhrajit Roy a *ChronoNet* foi proposta de rede neural recorrente (RNN) inspirada em redes de classificação de imagens, entretanto após alguns experimentos o algoritmo obteve bons resultados ao ser exposto a dados de EEG (ROY; KIRAL-KORNEK; HARRER, 2019).

Sobre o algoritmo, o autor utilizou-se de um *inception net* (SZEGEDY *et al.*, 2015), e uma *densenet* (HUANG *et al.*, 2017) para escrever a arquitetura da *ChronoNet*, muito comum de se encontrar em arquiteturas de redes neurais de problemas segmentação de imagens, isso devido a características da *dense net* conseguir carregar os pixel da imagem para camadas futuras, ocasionando um melhor mapeamento de característica. Em razão disso, ao se equiparar com os bons resultados da *ChronoNet* com dados de EEG no trabalho de Subhrajit Roy (ROY; KIRAL-KORNEK; HARRER, 2019), vale a interpretação de que por sua vez a *ChronoNet* consegue aprender a mapear de forma eficiente os dados do EEG, sabendo interpretar e reconhecer padrões específicos para o que está sendo classificado dentro da amostra.

Segundo o autor, como a *inception net*, utilizada no início da arquitetura, possui como

função a abstração do contexto de processamento em diferentes tamanhos de camadas iniciais, de modo que a *dense net* consiga trabalhar de forma igual a problemas no domínio do tempo, é necessário alterar tamanhos dos blocos de *inception* e consequentemente unidades GRU a medida que tem mais ou menos dados de entrada, a fim de evitar o *overfit* sobre um modelo com maior complexidade do que necessário. Em razão disso foi feita a retirada de um bloco de *inception* e de dois blocos de GRU, ver Figura 17.

Figura 17 – Do lado esquerdo arquitetura da ChronoNet utilizado por (ROY; KIRAL-KORNEK; HARRER, 2019) e do lado direito arquitetura da ChronoNet utilizado neste trabalho. Em vermelho elementos retirados da arquitetura de Subhrajit Roy e em amarelo elementos adicionados



Fonte: Elaborado pelo autor.

De modo a padronizar o treinamento das redes, foi escolhido para as três arquiteturas a mesma função de otimização, no caso a escolhida foi *Stochastic Adam* por possuir vantagens para o aprendizado de problemas com grandes número de parâmetros e apropriado para

problemas com gradientes muito ruidosos ou esparsos (KINGMA; BA, 2014).

Em resumo, as três arquiteturas apresentadas possuem como entrada os dados pré-processados resultante da Seção 3.2, com formato de dados (5,5) para as arquiteturas *ChronoNet* e RNN, e o formato de dados (5, 5, N) para a arquitetura CNN, sendo N o tamanho do janelamento utilizado no processo, na qual para esse trabalho foi 3. E como saída dos três algoritmos, é relacionado a quantidade de classes dos problemas, sendo eles: movimentar membro superior esquerdo, movimentar membro superior direito, e nenhuma ação motora nos membros superiores, dando um total de 3 classes.

Uma vez que o treinamento das redes neurais tenha sido concluído, será conduzida uma avaliação abrangente dos modelos, incluindo a análise da matriz de confusão, acurácia e a curva de erro de treinamento. Essa análise pós-treinamento é fundamental para entender não apenas o desempenho global dos modelos, mas também sua capacidade de generalização e adaptabilidade a dados não vistos anteriormente.

A matriz de confusão, como mencionado anteriormente, fornecerá uma visão detalhada das previsões realizadas pelas redes em relação a cada classe de movimento. Ao examinar os valores na matriz, poderemos identificar padrões específicos de confusão entre as diferentes classes, o que pode indicar áreas onde os modelos estão encontrando dificuldades.

A acurácia, como uma métrica global, irá quantificar a proporção de previsões corretas em relação ao total de previsões feitas. Ao comparar a acurácia entre as diferentes arquiteturas, poderemos determinar qual delas está alcançando os melhores resultados em termos de previsões precisas.

A curva de erro de treinamento, por sua vez, permitirá uma análise mais aprofundada da evolução do desempenho dos modelos ao longo do processo de treinamento. Ao traçar a curva de erro em relação às épocas de treinamento, podemos identificar tendências, como a convergência ou possíveis problemas de *overfit*.

Nesse contexto, é importante destacar que a avaliação da matriz de confusão, acurácia e curva de erro de treinamento será realizada utilizando os dados de validação. Isso assegura que a avaliação seja feita em um conjunto independente de dados, evitando qualquer viés que possa surgir ao avaliar o modelo nos mesmos dados usados para treinamento.

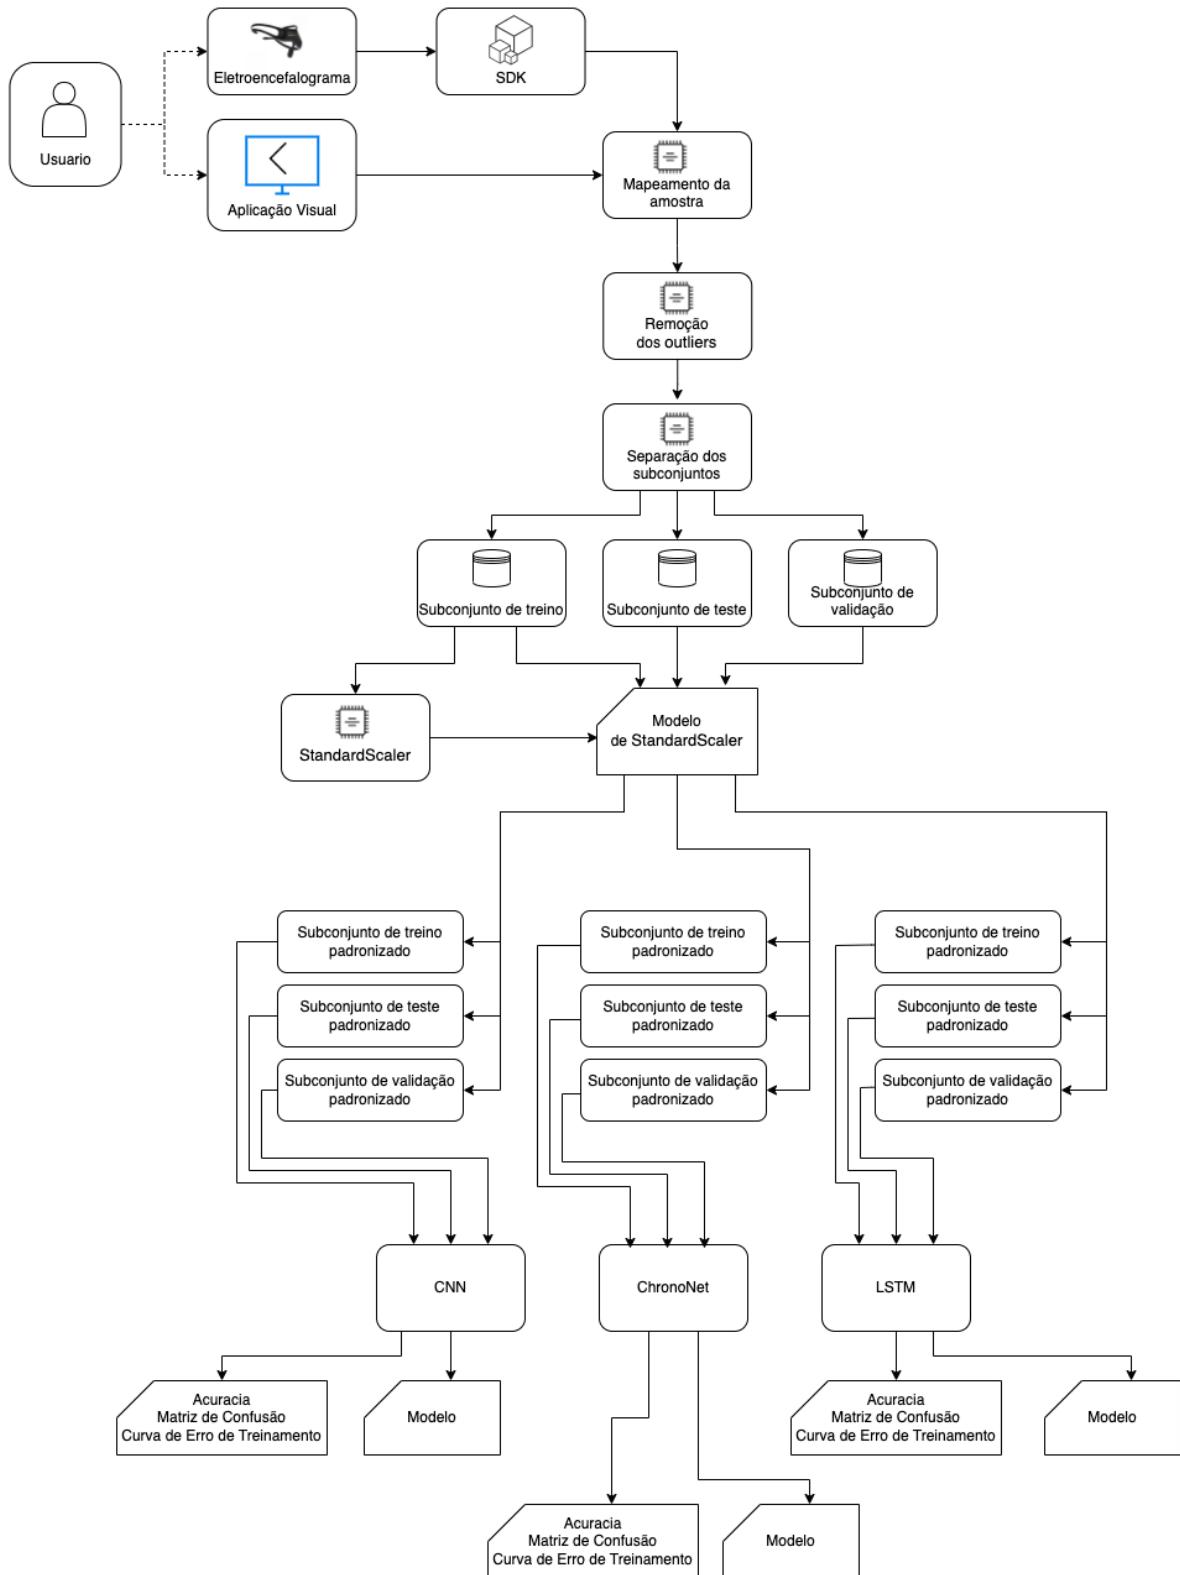
Em resumo, a análise pós-treinamento das métricas supracitadas será fundamental para a compreensão completa do desempenho das arquiteturas propostas. Ao avaliar a capacidade de previsão, a adaptabilidade e a capacidade de generalização dos modelos, poderemos obter uma visão holística sobre a eficácia dessas abordagens na classificação das ações motoras dos

membros superiores.

3.4 PROCESSO E ESTRATÉGIA

A fim de sumarizar a metodologia utilizada pelo trabalho de um forma específica, veja Figura 18, tem seu início no usuário onde será coletado as ondas cerebrais através do EEG através de um SDK durante o protocolo de aquisição de dados, passando pelo mapeamento de amostras e remoção de *outliers*, devido a utilização das redes neurais serem avaliadas utilizando *hold-out* nesse momento acontece a separação dos conjuntos em treino, teste e validação, e aplicando o *Standard Scaler*. Após a criação do *dataset*, é iniciado o treinamento das 3 arquiteturas de redes neurais CNN, RNN e *ChronoNet* e gerando como resultado os 3 modelos treinados com seus artefatos de avaliação.

Figura 18 – Fluxograma de forma específica da metodologia de trabalho



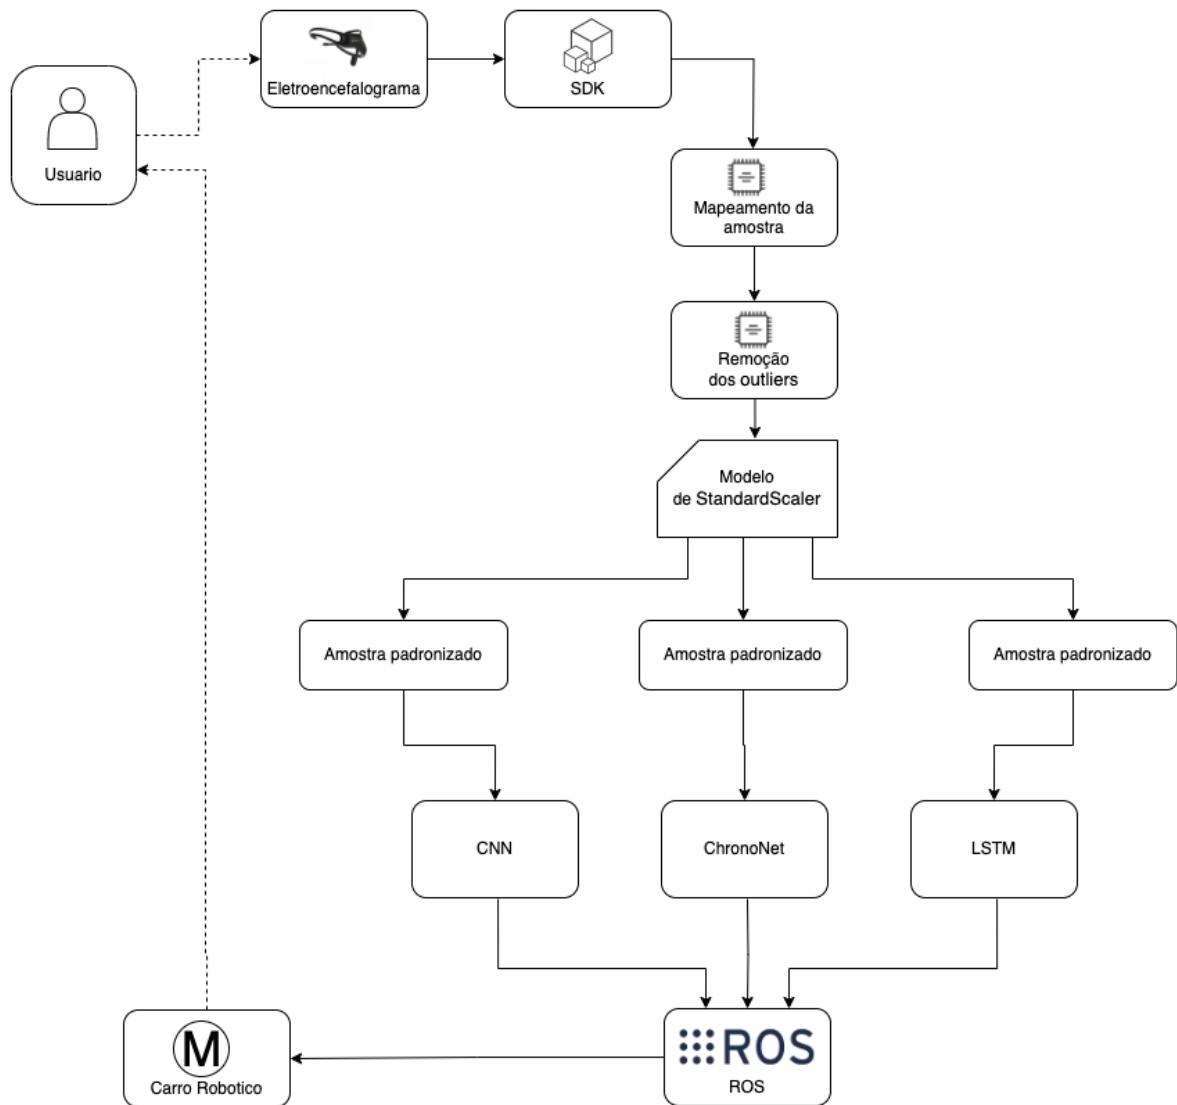
Fonte: Elaborado pelo autor.

Para uma validação experimental dos modelos treinados, esse trabalho propõe uma prova de conceito, na qual usa os modelos treinados em um fluxo de BCI. Um BCI oferece um meio

alternativo à comunicação natural do sistema nervoso, é um sistema artificial que contorna vias diferentes do corpo. Ela mede diretamente a atividade cerebral associada à intenção do usuário, e traduz em sinais de controle para aplicações. Tipicamente, possui quatro características: deve registrar a atividade diretamente do cérebro; deve possuir *feedback*; precisa ser em tempo real; e deve ser controlada pela iniciativa voluntária do usuário (GRAIMANN; ALLISON; PFURTSCHELLER, 2010).

Desse modo, fluxograma de BCI proposto por esse trabalho, Figura 19, é composto pela aquisição de dados, Seção 3.1, pelo pré-processamento, Seção 3.2 e pela tomada de decisão Seção 3.3, na qual com base na classificação dos modelos em movimentar os membros superiores para esquerda, para direita ou nenhum movimento, isso será correlacionado em movimentar um carro robótico rotacionando o mesmo para esquerda, direita ou seguindo reto respectivamente, através de módulo de comunicação com hardware utilizando o ROS. Sobre as etapas de desenvolvimento da prova de conceito junto à construção/funcionamento do BCI será apresentado no capítulo seguinte.

Figura 19 – Fluxograma de BCI utilizado



Fonte: Elaborado pelo autor.

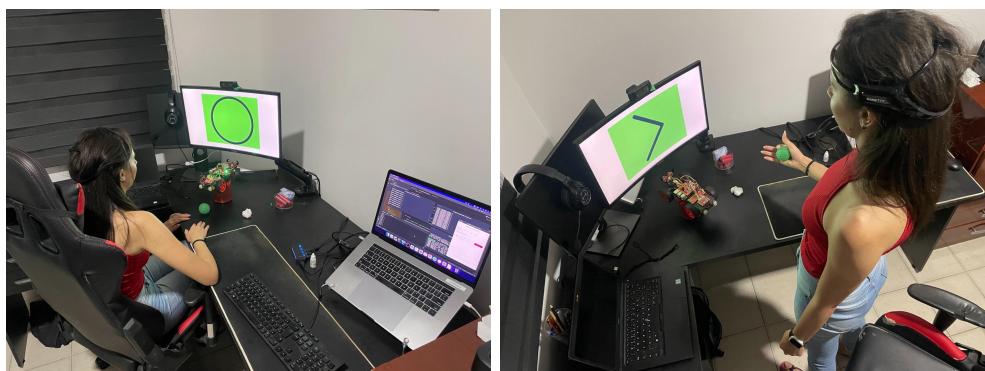
4 DESENVOLVIMENTO

Na fase de desenvolvimento, foi realizado um estudo de caso de uma aplicação BCI em que um carro robótico é controlado por meio da previsão da ação motora das redes neurais. A pesquisa foi conduzida com o consentimento livre e esclarecido de todos os voluntários, os quais assinaram um Termo de Consentimento Livre e Esclarecidos (TCLE), veja Apêndice B.

Para coletar os impulsos cerebrais dos usuários, foi utilizado o EEG. Os dados coletados passaram por um processo de processamento e foram utilizados como conjunto de dados para treinar três algoritmos de aprendizado de máquina: CNN, RNN e *Chronet*. O objetivo era realizar uma análise do desempenho desses algoritmos no controle do carro robótico.

O processo realizado neste estudo seguiu o protocolo de treinamento apresentado no Capítulo 3, enquanto o protocolo experimental para a análise será apresentado no Capítulo 5. Cada participante foi conduzido a uma sala equipada com um monitor, computadores e o percurso do experimento. Posteriormente, uma solução de base salina foi aplicada nos eletrodos do EEG para melhorar a captação dos impulsos cerebrais. Os eletrodos foram posicionados no participante, que recebeu instruções para permanecer sentado confortavelmente em uma cadeira. Também foi solicitado que mantivesse os braços relaxados, movendo-os de acordo com as imagens exibidas no monitor (conforme mostrado na Figura 20), e evitasse falar ou realizar qualquer outro movimento além dos especificados durante a coleta dos dados.

Figura 20 – Local de realização da aquisição de dados.



Fonte: Elaborado pelo autor.

Para a realização da aquisição dos impulsos cerebrais, foi utilizado o EEG *Emotiv Insight* 2.0¹, fabricado pela empresa EMOTIV, Figura 21. Esse sensor possui uma frequência de amostragem de 128 Hertz (Hz) e um conversor analógico-digital de 16 bits, e possui 5 canais de

¹ <https://www.emotiv.com/insight>

eletrodos: AF3, AF4, T7, T8 e Pz (EMOTIV, 2023). É importante ressaltar que esse mesmo equipamento já foi utilizado em outros trabalhos descritos na literatura como (LEVICÁN *et al.*, 2017), (HOQ *et al.*, 2018) e (GRANDINI *et al.*, 2017).

Figura 21 – Eletroencefalograma Emotiv Insight 2.0, da empresa EMOTIV



Fonte: Insight 2, 5 Channel - Emotiv¹

Para o armazenamento e processamento dos sinais eletroencefalográficos em todas as etapas deste estudo, foi desenvolvido um software em *Python* 3.8 utilizando o *framework* *PyTorch* e o ROS. O software, em conjunto com a Application Programming Interface (API) da *EMOTIV Launcher*, permite a gravação dos sinais e executa as etapas de extração de características, pré-processamento, classificação e envio de comandos para o carro robótico via ROS. O objetivo desse software é facilitar o desenvolvimento e validação da BCI.

É importante destacar que, para o processo de tradução e processamento dos sinais elétricos capturados pelo dispositivo *EMOTIV*, utilizou-se o software *EMOTIV Launcher*. Esse software converte os sinais em dados mais amigáveis para serem utilizados na pipeline de análise. Portanto, o software desenvolvido neste trabalho se concentra nas etapas posteriores, ou seja, no que fazer com os dados obtidos após o processamento pelo *EMOTIV Launcher*.

O software desenvolvido ao longo deste estudo desempenha um papel crucial na implementação e execução da BCI. Ele fornece as funcionalidades necessárias para armazenar, processar e enviar comandos com base nos sinais eletroencefalográficos capturados. O código-fonte e os

arquivos relacionados a esse software podem ser encontrados nesse repositório².

Essa abordagem de desenvolvimento de software personalizado permitiu adaptar o fluxo de trabalho às necessidades específicas da dissertação, fornecendo maior flexibilidade e controle sobre as etapas de processamento dos sinais. Além disso, o uso do framework *PyTorch* e do ROS contribuiu para a eficiência e integração do sistema como um todo.

No futuro, esse software pode ser aprimorado e expandido para incluir novas funcionalidades e técnicas de processamento de sinais. Também é possível explorar a integração com outros dispositivos e sistemas, a fim de expandir as possibilidades de aplicação da BCI. Essas melhorias podem contribuir para avanços significativos na área de BCI e em aplicações práticas relacionadas.

No presente estudo, foi utilizado o carro robótico *SunFounder Smart Sensor Car Kit*³, modelo *PiCar-S*, como estímulo visual, Figura 22. O robô é controlado por um *Raspberry Pi 3* Modelo B, ou seja seu Microcontroller Unit (MCU), que utiliza o sistema operacional *Raspbian Jesse*, uma distribuição *Linux*⁴. Na biblioteca *SunFounder*, existem vários *scripts Python* que possibilitam mover o robô para frente ou para trás, virá-lo e ajustar sua velocidade, utilizando-os é possível controlar os motores das rodas do robô, permitindo movimentá-lo em diferentes direções⁵. Além disso, o *Raspberry Pi* utiliza um *driver* de motor TB6612 para controlar as rodas traseiras e um servo motor para controlar as rodas dianteiras.

² <https://github.com/fabricitorquato/pyxaiver-v2>

³ <https://www.sunfounder.com>

⁴ <https://www.raspberrypi.com/software>

⁵ <https://github.com/sunfounder>

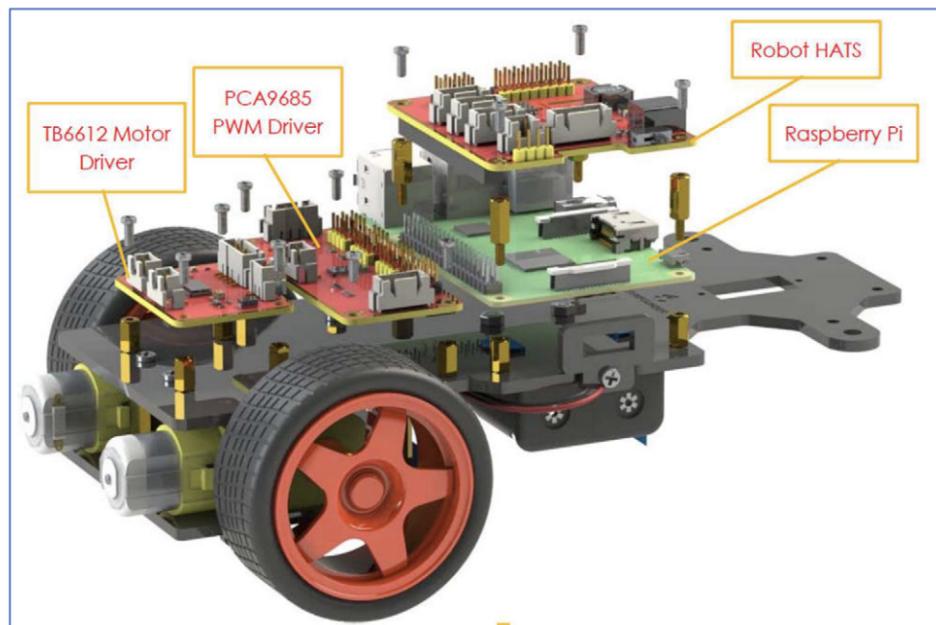
Figura 22 – SunFounder PiCAR-S



Fonte: SunFounder³.

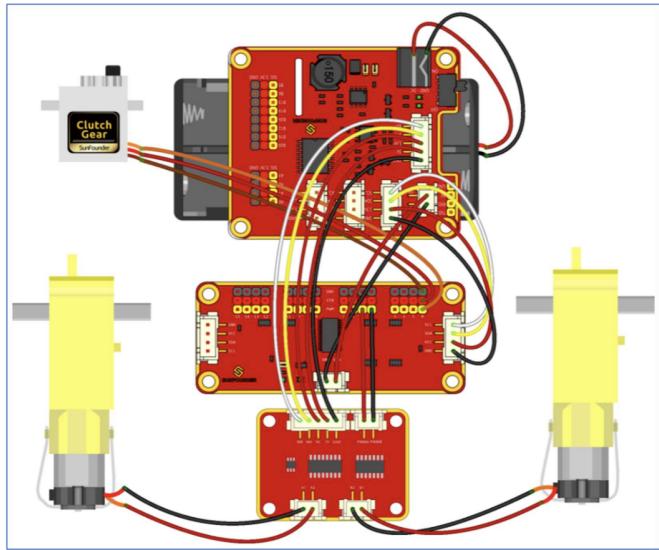
Na figura 23 se mostra os módulos de carro robótico na qual se conectarão os cabamentos e na Figura 24 encontrasse o esquema completo do cabamento.

Figura 23 – Módulos do PiCAR-S



Fonte: SunFounder³.

Figura 24 – Esquema de conexões do motor DC e dos servos motores do Picar-S



Fonte: SunFounder³.

Para desenvolver o controle do carro robótico nesta dissertação, foi utilizado o ROS, um *framework* de código aberto que permite o compartilhamento de ideias e códigos entre os usuários dessa plataforma. Isso proporciona uma infraestrutura de *software* pronta para uso, economizando tempo de desenvolvimento (QUIGLEY; GERKEY; SMART, 2015).

O ROS oferece suporte à programação em várias linguagens de alto nível, como *C++*, *Python* e *Lisp*. Além disso, possui recursos que facilitam a comunicação entre programas e processos, como uma interface de transmissão de mensagens, e recursos semelhantes a um sistema operacional, permitindo o controle de dispositivos de baixo nível e a abstração de *hardware*. Nesse trabalho, o ROS foi utilizado basicamente como uma ferramenta no meio de comunicação entre o *software* desenvolvido pelo autor e o *hardware* do carro robótico⁶.

Na dissertação, o algoritmo original da biblioteca *Sunfounder* foi modificado para que a direção das rodas seja controlada com base nas previsões das redes neurais, por meio do canal de comunicação com o ROS. Os *scripts* desenvolvidos podem ser encontrados neste repositório².

Para que o usuário possa controlar o carro robótico usando o EEG, é necessário realizar a fase de treinamento do modelo. Somente após essa fase, o usuário terá um modelo de rede neural específico para uso imediato. Os protocolos de treinamento utilizados são descritos no Subcapítulo 3.1.

É importante ressaltar que o modelo de rede neural treinado nessa fase é válido apenas para

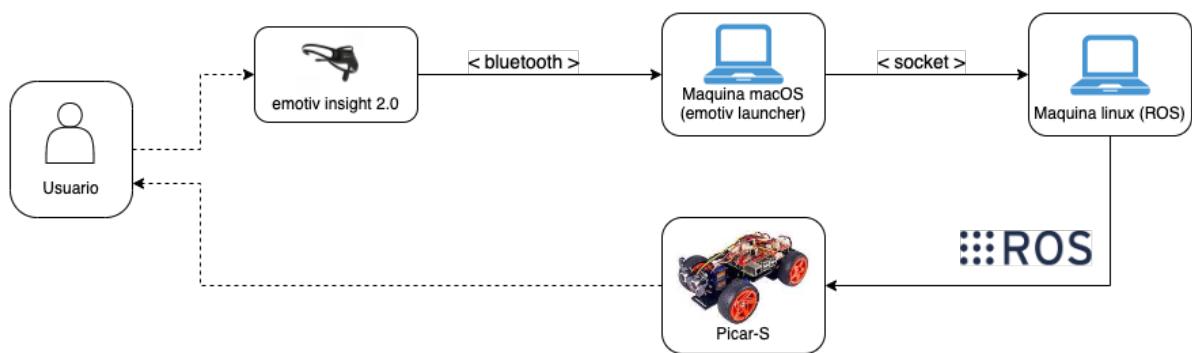
⁶ <https://www.ros.org>

o usuário que realizou o treinamento e para o momento atual. Atualmente, o BCI tem suas limitações, conforme apontado no trabalho de Simanto Saha e Mathias Baumert chamado *Intra and Inter-subject Variability in EEG-Based Sensorimotor Brain Computer Interface*, onde as técnicas atualmente utilizadas não fornecem resultados e conclusões satisfatórias para a intra e inter-sujeitos, isso é a variabilidade inerente intra e inter-sujeito causa mudança de covariáveis nas distribuições de dados que impedem a transferibilidade dos parâmetros do modelo entre sessões/sujeitos (SAHA; BAUMERT, 2020).

Após a conclusão do protocolo de treinamento, o *dataset* do usuário é criado e enviado para o treinamento dos algoritmos de aprendizado de máquina, conforme descrito no Subcapítulo 3.3, seguindo as arquiteturas descritas no mesmo.

Com o treinamento dos algoritmos de aprendizado de máquina finalizado, o participante pode controlar o carro robótico seguindo o fluxo de dados apresentado na Figura 25. Esse fluxo envolve a coleta dos sinais de EEG, enviados para o software por meio do *Emotiv Launcher*, que realiza o pré-processamento e a previsão de uma ação motora. Essa informação é enviada para a máquina Linux, que executa o ROS e envia os comandos para o *PiCar*. O *PiCar*, por sua vez, move o servo motor para a esquerda, direita ou para a frente, com base no ângulo do motor.

Figura 25 – Imagem da infraestrutura da aplicação



Fonte: Elaborado pelo autor.

Vale ressaltar que o autor optou por utilizar duas máquinas a fim de evitar sobrecarregar o processamento em um único dispositivo durante a coleta de dados do EEG, pré-processamento da rede, previsão da rede, *framework* do ROS e fila de envio dos dados. Dessa forma, a infraestrutura apresentada na Figura 25 foi escolhida, na qual a máquina *macOS* é responsável pelos dados coletados do EEG até a previsão, enquanto a máquina Linux cuida da infraestrutura e comunicação com o ROS até o *Picar-S*. A escolha de uma máquina *macOS* se deu pela

necessidade de o *Emotiv Launcher* não oferecer suporte ao *Linux*, levando o autor a optar pelo *macOS*.

Para o funcionamento completo da aplicação, foram utilizados dois notebooks: uma máquina *Linux* com processador *Intel Core i7 quad core* de sétima geração, 16 Gigabyte (GB) de memória random-access memory (RAM) e Solid-State Drive (SSD) de 256 GB, e uma máquina *macOS* com processador *Intel Core i7 quad core* de 2,7 Giga Hertz (GHz), 16 GB de memória RAM e SSD de 500 GB. Um EEG *Emotiv Insight 2.0* e um Picar-S da *Sunfounder* acoplado a uma *Raspberry Pi 3 Modelo B* também foram utilizados.

O procedimento completo, que inclui a execução do protocolo de treinamento, criação da base de dados e treinamento das três redes neurais, leva cerca de 40 minutos. Após esse período, as redes neurais estão prontas para serem utilizadas no estudo de caso de controlar um carro robótico por meio do EEG.

5 RESULTADOS E AVALIAÇÕES

Neste capítulo, é apresentada uma análise comparativa de três técnicas de detecção objetiva da resposta no domínio da frequência utilizando sinais de EEG. O propósito principal foi identificar o detector com o melhor desempenho em termos de aplicação em BCI, alcançando altas taxas de assertividade nas respostas e menor tempo de detecção. Para esse fim, foram utilizadas cinco métricas quantitativas e uma qualitativa.

5.1 TESTE E AVALIAÇÃO

As redes foram avaliadas utilizando *hold-out* com uma parcela de dados para validação. As três divisões dos conjuntos treino, teste e validação foram feitas de forma estratificada, de modo a manter a proporção da ocorrência de cada classe de maneira igual entre as divisões. Após o pré-processamento a média de amostra do *dataset* ficou de 13504, para treinamento foram separadas 8643 amostras (64%) e a cada época o desempenho da rede era medido com o conjunto de teste utilizando 2160 amostras (16%) diferentes das utilizadas no conjunto de treino. Ao terminar as épocas de treinamento (30 épocas para CNN, 30 épocas para RNN e 15 épocas para *ChronoNet*), uma parcela diferente (validação) era utilizada para avaliar o resultado final do treinamento, contendo 2701 amostras (20%).

Desse modo, ao fim de cada treinamento é gerado 3 artefatos, a acurácia do modelo calculado com a comparação do conjunto validação entre os valores predito e o real, a matriz de confusão na qual dá suporte para os cálculos de outras métricas como Taxa de Verdadeiro Positivo (TVP), Taxa de Falso Positivo (TFP), Taxa de Verdadeiro Negativo (TVN) ou Taxa de Falso Negativo (TFN), na qual ajudam a interpretar quais os melhores modelos e a curva de erro de treinamento, na qual ajuda na avaliação de modelos sobre *overfit* ou *underfit*.

Utilizando de uma máquina *linux* com processador *intel® core™ i7* da 7^a Geração com 16 GB de memória RAM, e SSD de 256GB, o procedimento completo, criação da base de dados e o treinamento das três redes neurais, leva cerca de 4 minutos, após isso as redes neurais já estão prontas para serem utilizadas por um BCI.

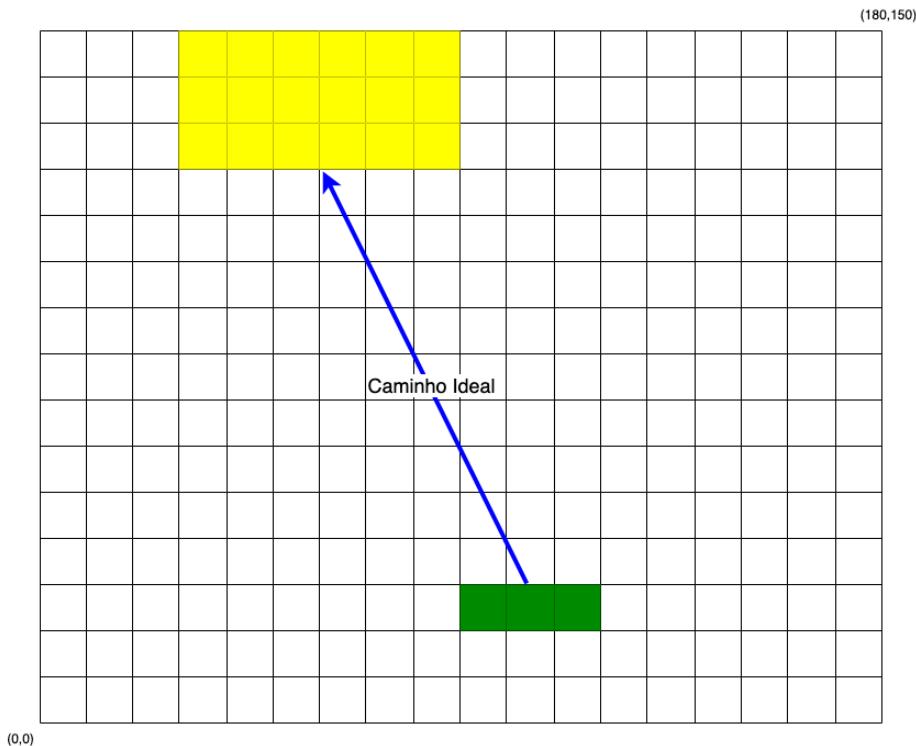
5.2 MEDIDA DE DESEMPENHO

Na literatura, encontramos dois perfis de trabalhos quando analisamos a medida de desempenho. O primeiro grupo de trabalhos consiste em projetos que apresentam metodologias e fluxos de BCI, em que a medida de desempenho está relacionada à capacidade dos usuários de realizar uma tarefa sem o auxílio de recursos externos ao experimento. Exemplos desses trabalhos incluem (LEVICÁN *et al.*, 2017) (HOQ *et al.*, 2018) (SCHUH *et al.*, 2013). O outro grupo na literatura abrange projetos avaliados por métricas que mensuram as taxas de precisão e o tempo de detecção de um sistema BCI.

Portanto, este trabalho tem como objetivo avaliar a medida de desempenho desses dois grupos de critérios. O primeiro grupo é avaliado por meio de uma métrica qualitativa que conta quantas vezes o usuário conseguiu realizar a tarefa proposta. Além disso, foi realizada uma pesquisa semi-estruturada. Já o segundo grupo é avaliado utilizando cinco métricas quantitativas: Número de Comandos Corretos (NCC), acurácia, Tempo Médio Entre Detecções (TMD), Tempo Médio Entre Acertos (TMA) e *Information Transfer Rate* (*ITR*).

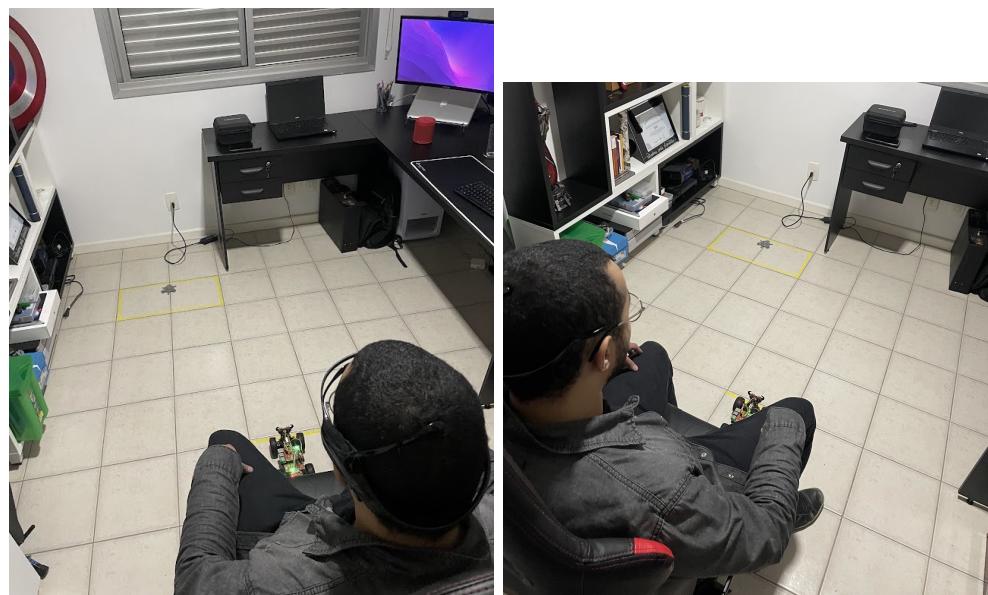
Para avaliar os resultados dos usuários com base nas métricas mencionadas, foram desenvolvidos dois testes experimentais. O primeiro teste consiste em uma tarefa em que o usuário precisa conduzir um carro robótico remotamente controlado pelo BCI de um ponto a outro. Essa tarefa é composta por três tentativas para cada algoritmo. O percurso é livre de obstáculos e tem aproximadamente 100 cm de distância entre o ponto de partida e o ponto de chegada. O tempo máximo de execução é de 1 minuto. Se o carro sair dos limites definidos de 180 cm x 150 cm, que têm o ponto de partida em (110,30), o carro robótico é retornado ao ponto de partida. A tarefa é considerada concluída quando o carro robótico entrar em uma área localizada entre os pontos (40,130) e (90,130). Um esquema do percurso pode ser encontrado na Figura 26, enquanto a localização do experimento é mostrada na mesma Figura 27.

Figura 26 – Diagrama de representação da tarefa



Fonte: Elaborado pelo autor.

Figura 27 – Local do experimento quantitativo



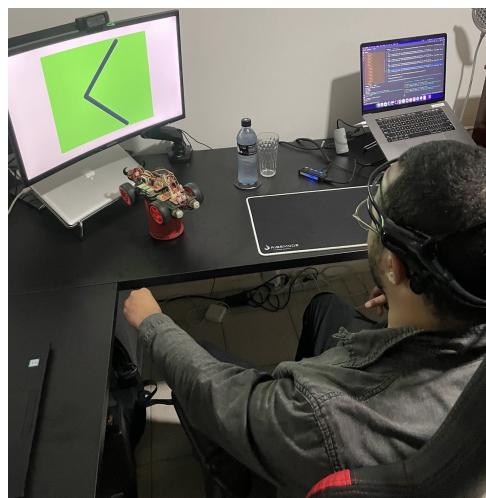
Fonte: Elaborado pelo autor.

Vale ressaltar que na Figura 27 é possível ver duas marcações com fitas amarelas no chão na qual a que apresenta apenas um traço demarca o inicio da trajetória do carro robótico,

enquanto a que demarca o retângulo no canto superior esquerdo, demarca a área final que o usuário precisa chegar com o carro robótico.

Para realizar a coleta das 5 métricas quantitativas, foi necessário um outro ambiente de teste, na qual o usuário ficava sentado na frente de uma tela de monitor com o carro robótico em sua frente com as rodas levantadas sem encostar na mesa, e do mesmo modo que foi realizado o treinamento, será apresentado as mesmas 3 imagens com a mesma representação na tela, entretanto nesse momento ao usuário mexer um membro superior o comando irá percorrer o fluxo do BCI e remotamente controlar o carro robótico, desse modo, por será apresentado 20 imagens de cada comando de forma aleatória, e ao primeiro comando do usuário correto para a direção apresentada na tela, a imagem irá trocar, e se em 5 segundos o usuário não conseguir executar a ação, a imagem é trocada também, o local do experimento é apresentado na Figura 28. Desse modo o software consegue coletar o estímulo apresentado para o usuário, o comando predito pelo sistema, o tempo de resposta do acerto e detecção, sendo esses dados importantes para conseguir medir os valores das métricas quantitativas.

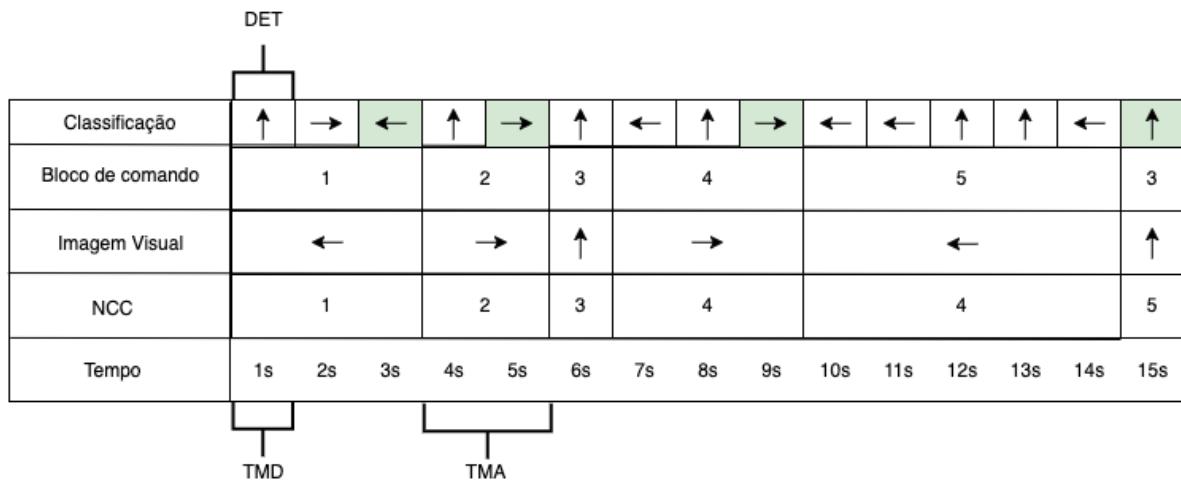
Figura 28 – Local do experimento quantitativo



Fonte: Elaborado pelo autor.

Na Figura 29 é possível observar 4 momentos distintos de capturas durante o teste, sendo eles a classificação, bloco de comando, a imagem visual e o NCC. A classificação é o resultado predito pelo sistema que foi enviado para o BCI, o bloco de comando é o espaço de tempo até ocorrer a primeira classificação correta da ação, a imagem visual se trata da imagem apresentada na tela, na qual o usuário irá precisar mover o carro robótico. Os demais valores encontrados na Figura 29 como NCC, TMD e TMA são as métricas quantitativas extraídas pelo experimento que serão apresentadas a seguir.

Figura 29 – Diagrama de representação do teste



Fonte: Elaborado pelo autor.

Desse modo, esse trabalho se propõe a construir um indicador de comparativo para as métricas e depois irá ser criado uma base e descrever a assertividade encontrada.

5.2.1 Número de Comandos Corretos

Durante o experimento foram apresentados para o usuário 20 imagens representando cada um dos três tipos de movimentos possíveis para o carro robótico sendo elas, rotacionar o carro para esquerda, direita ou seguir em frente. Esses comandos foram apresentados de forma aleatória para usuário, e desse modo a cada predição correta, era somado 1 na unidade de métrica do NCC, logo o número de comandos corretos é o somatório de quantos dos 60 comandos o usuário conseguir executar em menos de 5 segundos. Com essa métrica é possível medir quantos acertos cada algoritmo obteve utilizando um limite de tempo de 5 segundos para ser predito. Vale mencionar que o tempo limite de 5 segundos foi utilizado como base das métricas e classificação do trabalho de Tannus (TANNUS, 2014), na qual o TMD de seu trabalho foi de aproximadamente 2 segundos e ele tinha como tempo limite 10 segundos, sendo aproximadamente 5 tentativas de comandos e caso passe do limite, o autor interpreta que o BCI não conseguiu executar aquela detecção, no caso desse projeto o número aproximado de 5 tentativas foi estimado a 5 segundos, após os teste preliminares.

5.2.2 Taxa de Acertos

Também referida na literatura como acurácia, é um parâmetro muito importante para a avaliação de eficiência de uma BCI, sendo o método mais comum de comparação de algoritmos de classificação em aprendizado de máquina.

5.2.3 Tempo Médio Entre Detecções

O Detecção (DET) é a representação de quantos comandos são executados pelo usuário com o BCI, independente se forem corretos ou errados, sendo que a velocidade entre cada DET é possível calcular o TMD, desde modo pode ser visto como a rapidez com que o sistema responde à intenção do usuário, onde quanto mais rápido o BCI é entre o tempo de aquisição de dados, pré processamento, detecção e a interface de comunicação com hardware, mais comandos o algoritmo irá gerar. É um parâmetro interessante para verificar a capacidade do BCI de reconhecer os comandos enviados pelo usuário, uma vez que o TMD é calculado seguindo a Fórmula 5.1, onde é a média entre cada DET (TANNUS, 2014).

$$TMD = \sum_{i=1}^n (T_{det(i)} - T_{det(i-1)}) / n \quad (5.1)$$

Onde T_{det} é o tempo na qual ocorreu a detecção e n é a quantidade de detecção executadas no experimento.

5.2.4 Tempo Médio Entre Acertos

Essa métrica é uma junção de dados e valores entre a acurácia e a TMD, sendo que o tempo médio entre acertos é diferença de tempo entre a aparição da imagem representativa da ação na tela e a previsão do comando correto. Com o TMA é possível notar qual o tempo médio para executar um comando correto com o BCI por cada usuário. Vale pontuar que caso o usuário não consiga executar um comando correto no tempo limite de 5 segundos, e adicionar esse valor como tempo de acerto, essa métrica irá penalizar algoritmos que tiverem uma acurácia baixa. Na Figura 29, é possível notar que o TMA será a média da diferença entre o tempo de início do estímulo e tempo de previsão correto.

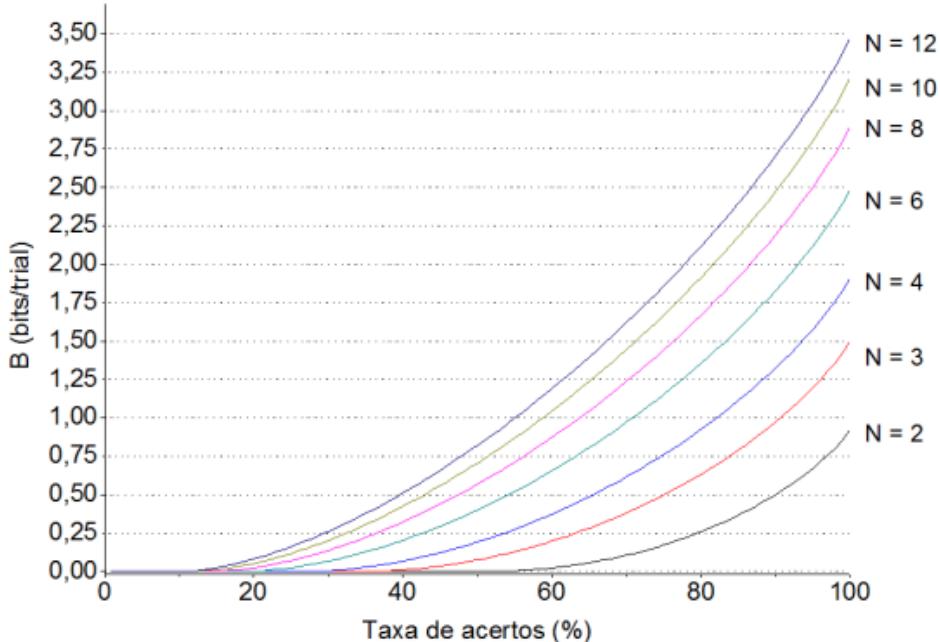
5.2.5 *Information Transfer Rate*

Em sistemas que são influenciados pela taxa de performance da comunicação em plataformas computacionais, a medida padrão usada para medir a quantidade de informação transferida por unidade de tempo é a taxa de bit (SHANNON; WEAVER, 1964). A taxa de bit depende da precisão e da quantidade de bits necessários para codificar a informação. No caso de medidas de desempenho do BCI que utilizam o conceito de taxa de bit, tem se destacado a chamada ITR (PINTO, 2011). A taxa de bit (B) é calculada pela Fórmula 5.2.

$$B = \log_2(N) + P \log_2(P) + (1 - P) \log_2 \frac{1 - P}{1 - N} \quad (5.2)$$

Onde N é o número de possíveis opções de classificação e P é a precisão do classificador. Vale destacar, que essa métrica possui um fenômeno bem peculiar quando olhado no contexto de BCI, pois ao analisar um valor fixo de taxa de bit (por exemplo, 1,5 bits/trial), e executar um aumento do número de comandos, N , irá causar uma diminuição na taxa de acertos, P . Por exemplo, para $N = 3$ e 1,5 bits/trial equivale a uma taxa de acerto de 100%, enquanto o aumento de número de comandos para 10 ocasiona, para a mesma taxa de bits/- trial, uma diminuição da taxa de acertos para aproximadamente 70%, como pode-se ver na Figura 30 (TANNUS, 2014).

Figura 30 – Relação entre o aumento da taxa de bit (B) e a variação do número de comandos N e da taxa de acertos.



Fonte: (TANNUS, 2014).

Desse modo, é possível concluir que a ITR é limitada na comparação apenas de sistemas que possuem número de comandos iguais, ou próximos. Isso devido à proporção que a métrica toma devido ao comportamento que as curvas trabalham quando variamos o número de comando.

Vale mencionar, na qual, geralmente em sistemas de BCI o mais utilizado é o ITR em bits/minuto (ZHAO *et al.*, 2009). Dado pela Fórmula 5.3:

$$B_t = B \frac{60}{T} \quad (5.3)$$

Onde T é o tempo médio necessário para transmitir cada comando do BCI, onde neste trabalho o valor médio de T é dado pelo valor de TMD do algoritmo avaliado. Outro ponto importante no ITR é apresentado, sendo ela a influência do tempo médio de detecção sobre o ITR. Visto pela fórmula 5.3 que o valor de T é inversamente proporcional ao valor de ITR, quanto maior o tempo de executar uma detecção menor vai ser o valor de seu ITR. Desta forma, um usuário/algoritmo de BCI pode apresentar menor taxa de acertos e, ainda assim, alcançar um ITR maior que outro usuário/algoritmo que tenha obtido alta taxa de acertos, porém com um tempo de detecção maior (TANNUS, 2014).

5.3 RESULTADOS

Devido a manter as comparações entre as técnicas de forma homogênea entre cenários e aplicações da literatura comparadas. Será comparado entre as três técnicas desse trabalho as métricas de NCC, acurácia, TMD, TMA e ITR além da quantidade de vezes que o usuário conseguiu realizar a tarefa proposta. Além disso, será utilizado a acurácia, TMD, ITR como métrica comparativa com outros trabalhos da literatura.

De acordo com Jakob Nielsen, renomado especialista em usabilidade, a realização de testes com cinco pessoas é suficiente para obter resultados significativos e identificar os principais problemas de usabilidade em uma interface. Essa abordagem foi apresentada por Nielsen em seu livro *Usability Engineering at a Discount*, publicado em 1989 (NIELSEN, 1989). Nielsen argumenta que, a partir de cinco participantes, é possível encontrar cerca de 80% dos problemas, e a partir desse ponto, os problemas tendem a se repetir, resultando em retornos limitados em relação à curva de aprendizado. Portanto, ao conduzir experimentos com cinco pessoas, é possível obter um estudo satisfatório e identificar os desafios mais relevantes para aprimorar a usabilidade da interface em questão.

Para convidar os participantes e entender como era o perfil populacional dos participantes do experimento foi criado um formulário, veja A, na qual o participante respondia antes de ser chamado para o experimento, desse modo foram realizados os experimentos com 5 participantes diferentes na qual todos tinham entre 18 e 40 anos, sendo 2 mulheres e 3 homens, 3 destros e 2 canhotos, nenhum dos participantes utiliza medicamentos de tratamento psicológico.

5.3.1 CNN

Sobre a tarefa de locomover o carro robótico do ponto A ao ponto B com sucesso, 2 participantes conseguiram realizar 2 vezes o percurso no tempo e 3 participantes conseguiram realizar apenas 1 vezes o percurso. A taxa mais alta é de 35,32 bits/min e a menor é de 10,64 bits/min. A média é de 19,34 bits/min. A taxa de precisão mais alta do modelo estatístico é de 71,0% e a mais baixa é de 54,0%. O tempo médio de acerto e detecção do algoritmo CNN é possível encontrar na Tabela 1.

Tabela 1 – NCC, acurácia, TMD, TMA e ITR para CNN.

Voluntário	NCC	acurácia (%)	TMD (s)	TMA (s)	ITR (bits/min)
1	37	57.0	0.787	2.848	12.9
2	39	62.0	0.779	2.727	19.02
3	44	62.0	0.787	2.599	18.82
4	47	54.0	0.731	2.343	10.64
5	51	71.0	0.724	2.096	35.32
Média	43	61.2	0.761	2.522	19.34
Desvio Padrão	5	6.45	0.031	0.303	9.65

Fonte: Elaborado pelo autor.

5.3.2 RNN

Sobre a tarefa de locomover o carro robótico do ponto A ao ponto B com sucesso, 4 participantes conseguiram realizar 2 vezes o percurso no tempo e 1 participante conseguiu realizar apenas 1 vez o percurso. A taxa mais alta é de 70,55 bits/min e a menor é de 33,92 bits/min. A média é de 42,99 bits/min. A taxa de precisão mais alta do modelo estatístico é de 86,0 e a mais baixa é de 70,0. O tempo médio de acerto e detecção do algoritmo RNN é possível encontrar na Tabela 2.

Tabela 2 – NCC, acurácia, TMD, TMA e ITR para RNN.

Voluntário	NCC	acurácia (%)	TMD (s)	TMA (s)	ITR (bits/min)
1	46	75.0	0.776	2.475	40.49
2	52	70.0	0.706	2.113	34.31
3	43	70.0	0.714	2.201	33.92
4	50	71.0	0.716	2.171	35.72
5	42	86.0	0.732	2.281	70.55
Média	46	73.0	0.728	2.248	42.99
Desvio Padrão	3	6.0	0.028	0.140	15.62

Fonte: Elaborado pelo autor.

5.3.3 Chronet

Sobre a tarefa de locomover o carro robótico do ponto A ao ponto B com sucesso, 2 participantes conseguiram realizar 3 vezes o percurso no tempo, 2 participantes conseguiram realizar 2 vezes o percurso e 1 participante conseguiu realizar apenas 1 vezes o percurso. A taxa mais alta é de 95,92 bits/min e a menor é de 47,87 bits/min. A média é de 68,08 bits/min. A taxa de precisão mais alta do modelo estatístico é de 95,0% e a mais baixa é de 78,0%. O tempo médio de acerto e detecção do algoritmo Chronet é possível encontrar na Tabela 3.

Tabela 3 – NCC, acurácia, TMD, TMA e ITR para Chronet.

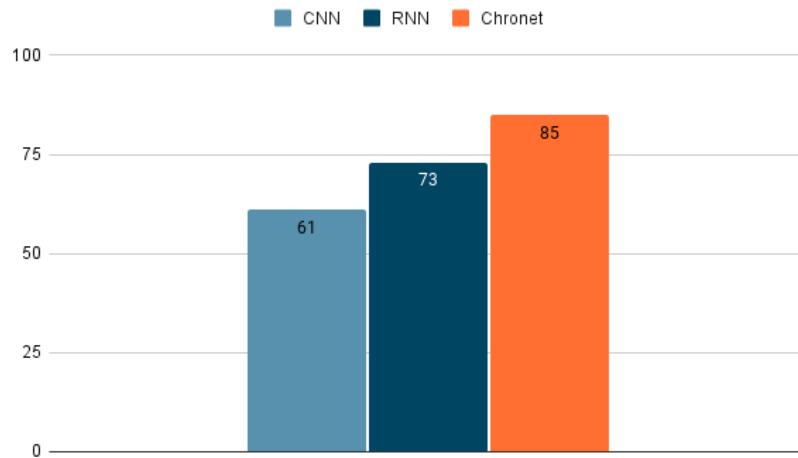
Voluntário	NCC	acurácia (%)	TMD (s)	TMA (s)	ITR (bits/min)
1	44	88.0	0.764	2.473	73.48
2	45	78.0	0.758	2.402	47.87
3	41	85.0	0.778	2.510	63.63
4	58	82.0	0.735	2.193	59.17
5	38	95.0	0.781	2.799	95.92
Média	45	85.0	0.763	2.475	68.08
Desvio Padrão	7	6.0	0.018	0.218	18.09

Fonte: Elaborado pelo autor.

5.3.4 Comparativo Entre as Técnicas

No Gráfico 31 é possível encontrar os resultados dos experimentos de forma resumida por algoritmos, ao olhar da taxa de acertos.

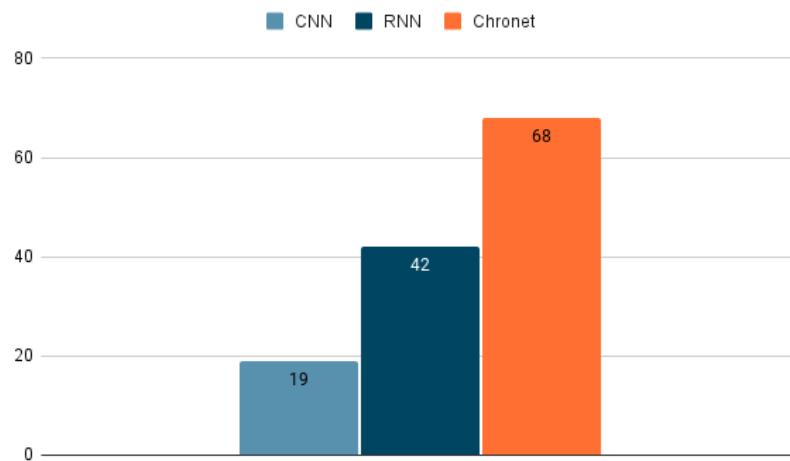
Gráfico 31 – Histograma de taxa de acertos.



Fonte: Elaborado pelo autor.

No Gráfico 32 é possível encontrar os resultados dos experimentos dos algoritmos, ao comparar o ITR.

Gráfico 32 – Histograma de Information Transfer Rate.



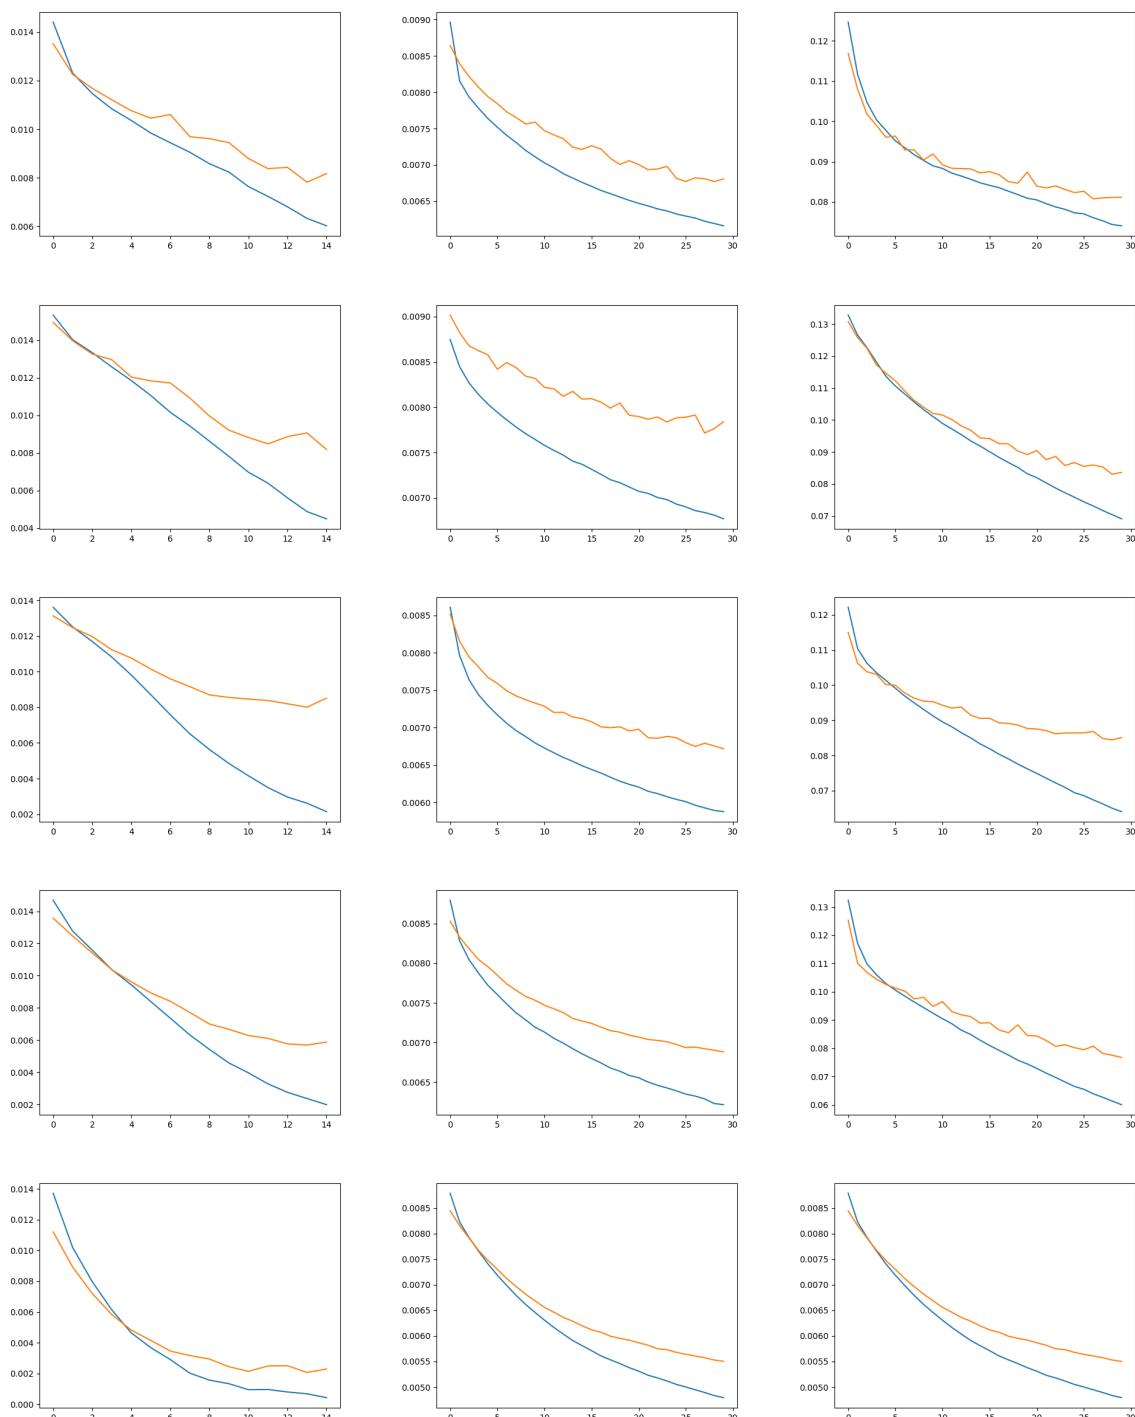
Fonte: Elaborado pelo autor.

Na Figura 33, é possível observar a curva de erro de treinamento de todos os participantes. As tabelas são apresentadas na mesma ordem que na sessão anterior, onde a primeira linha representa o primeiro participante, a segunda linha o segundo participante e assim por diante. Além disso, a coluna da esquerda mostra as curvas de treinamento da *ChonoNet*, a coluna central representa os modelos da CNN e a coluna da direita mostra a RNN.

A partir das imagens, podemos observar que alguns modelos apresentaram *overfitting*, outros *underfitting* e alguns tiveram um bom treinamento. É importante destacar que os modelos relacionados à CNN apresentaram os resultados mais frequentes de *overfitting*. No entanto,

ao analisar o participante número 5, que obteve a maior acurácia entre os 5 participantes em todos os três algoritmos, podemos observar que a curva de treinamento dele representa um bom treinamento. Isso enfatiza a alta acurácia dos modelos de redes neurais desse participante.

Figura 33 – Curva de Erro de Treinamento, coluna da esquerda ChronoNet, coluna central CNN, clouna da direita RNN



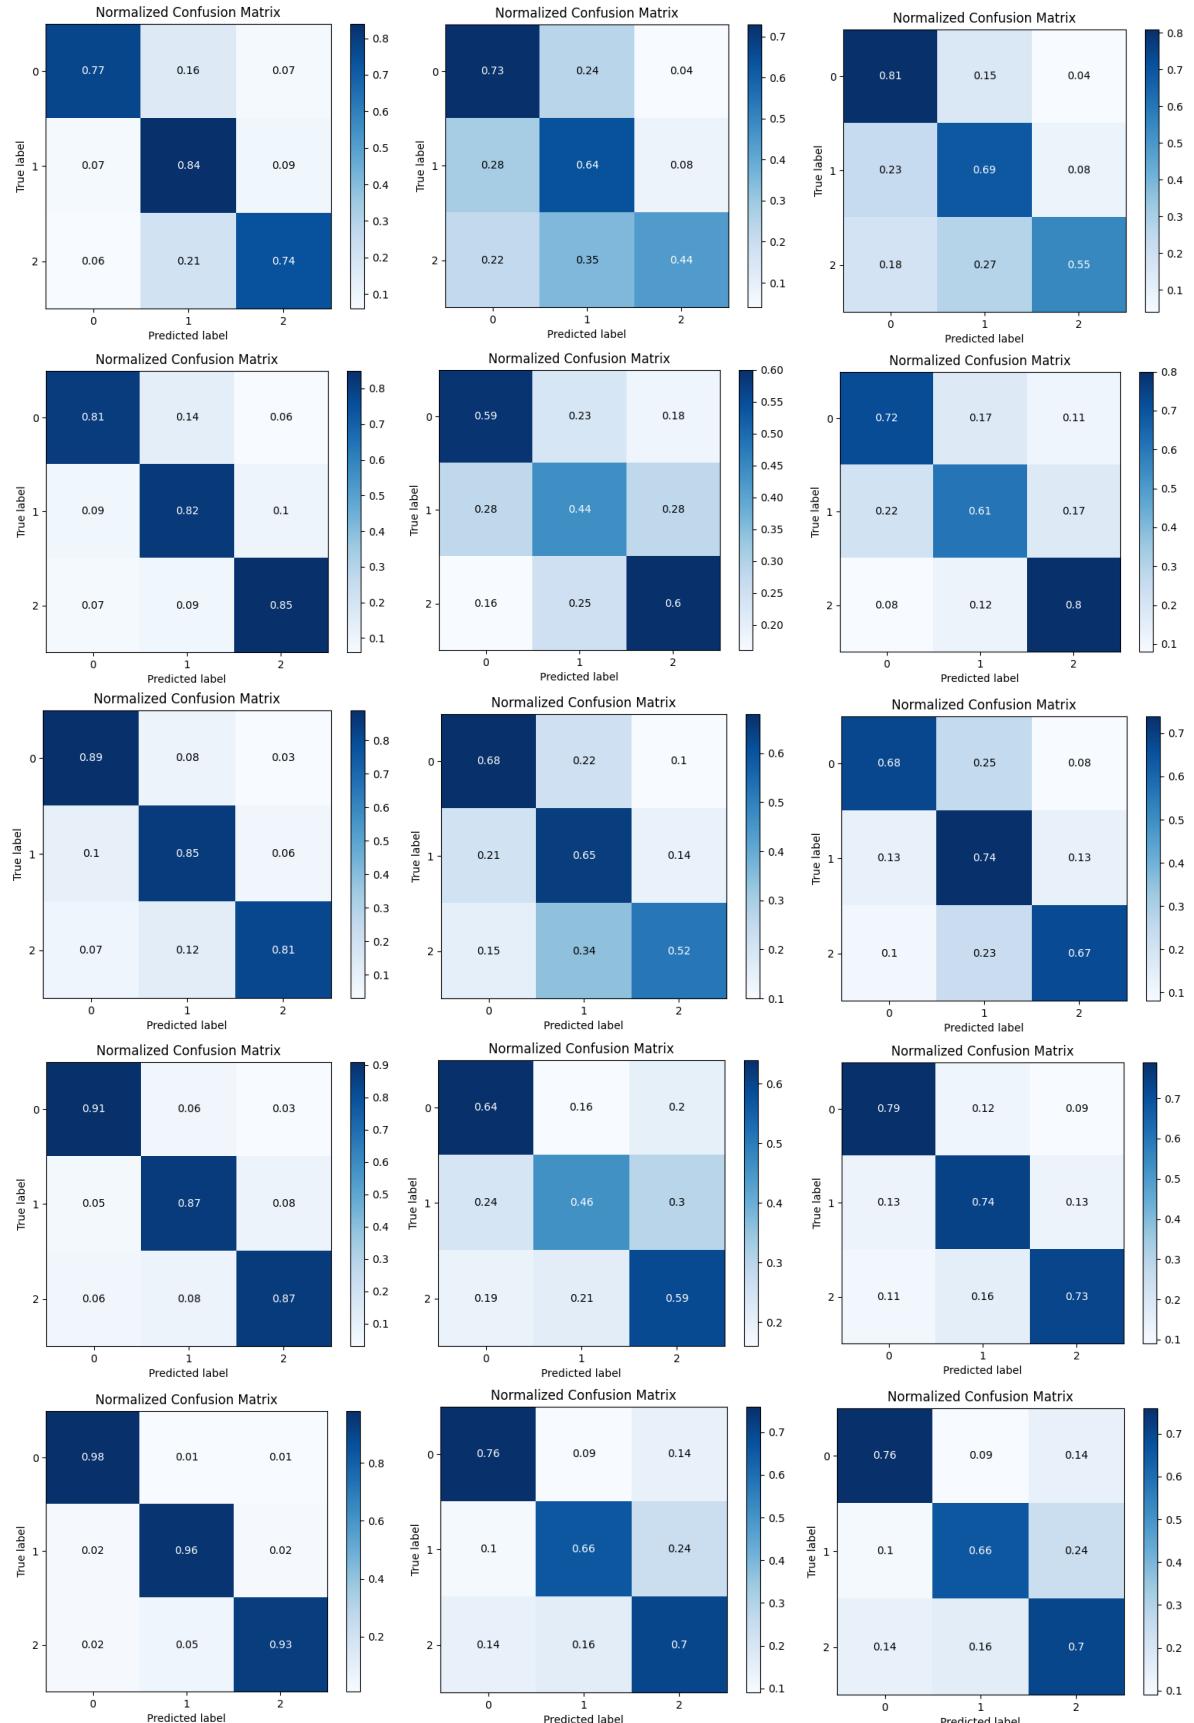
Fonte: Elaborado pelo autor.

Na Figura 34, é possível observar a matriz de confusão de todos os participantes. As tabelas

são apresentadas na mesma ordem que na sessão anterior, onde a primeira linha representa o primeiro participante, a segunda linha o segundo participante e assim por diante. Além disso, a coluna da esquerda mostra as matrizes de confusão da *ChonoNet*, a coluna central representa as matrizes da CNN e a coluna da direita mostra as matrizes da RNN.

Com base nessas imagens, um dos primeiros resultados que pode ser observado é o fato de a coluna da CNN apresentar um baixo nível de sensibilidade entre as classes. Isso indica que o modelo tem uma alta taxa de falsos negativos, ou seja, falha em identificar muitas instâncias positivas das classes em questão. Por outro lado, é possível notar que as taxas de verdadeiros positivos nos modelos da *ChonoNet* são as que apresentam valores mais altos na sensibilidade entre as classes.

Figura 34 – Matriz de Confusão, coluna da esquerda ChronoNet, coluna central CNN, clouna da direita RNN



Fonte: Elaborado pelo autor.

5.3.5 Comparativo Com a Literatura

Quando for feito comparações quantitativas do ITR entre sistemas de BCI, vale notar dois pontos importantes para evitar comparativos fora de domínio válidos pela fórmula da métrica. A primeira, já mencionada anteriormente, deve evitar comparar ITR de BCI com número de comandos diferentes, devido ao efeito da curva da taxa de bits, o segundo ponto, relatado por Grandini (GRANDINI *et al.*, 2017) descreve que deve-se atentar que tem diversos EEG no mercado com taxa de amostragem em KHz, enquanto outros que estão na taxa de 128 Hz, como é o caso do *Emotiv Insight 2.0*, então a recomendação é comparação ser feita apenas entre sensores de custo parecidos, desse modo evitar comparar projetos de BCI que possuem qualidade e quantidade diferentes na fonte de aquisição de dados, isso é, um trabalho que utiliza EEG de alto custo com 64 canais ou 128 canais, iriam possuir dados coletados em um domínio de qualidade e quantidade muito superior a trabalhos que utilizam por exemplo o *Emotiv Insight 2.0*, que é considerado um EEG de baixo custo com apenas 5 canais. Desse modo é aconselhado apenas comparar projeto que possuem dados de entrada semelhantes, assim conseguindo comparar de forma mais assertiva o algoritmo e a metodologia utilizada no BCI, não ficando enviesado sob os dados coletados de fontes diferentes.

Um exemplo de trabalho que não poderia ser comparado com esse trabalho é o *Lead selection for SSVEP-based brain-computer interface* (WANG *et al.*, 2004), na qual foi utilizado um EEG de 32 canais do modelos *BioSemi ActiveTwo*, e seu BCI está focado em controlar um telefone virtual que possui 13 comandos diferentes.

Alguns trabalhos como o Interface Cérebro Máquina de Baixo Custo como Tecnologia Assistiva (GRANDINI *et al.*, 2017) precisam assumir a acurácia, para conseguir realizar a fórmula de ITR, desse modo a taxa não apresenta valores equivalentes aos utilizados neste trabalho e por isso não é possível utilizar esse trabalhos como comparativo.

Um outro exemplo de trabalho que não pode ser comprado a esse projeto, é o *Implementation of SSVEP Based BCI with Emotiv EPOC* (LIU *et al.*, 2012), onde o foco do seu BCI é no controle de um teclado com 6 teclas distintas, isso é 6 comandos diferentes.

Um terceiro tipo de projetos que é importante evitar a comparação, são projetos que não deixam claro qual o sensor utilizado no sistema de aquisição. Isso é, se o autor não deixa claro como foi feita a coleta, fica complicado executar o comparativo entre metodologias.

Na Tabela 4, é possível encontrar três tipos de algoritmos: o Potencial Evocado Visual em Regime Permanente (PEV-RP), o Bayesian Linear Discriminant Analysis (BLDA) e as redes

neurais.

Além disso, vale mencionar que o PEV-RP é uma técnica de avaliação eletrofisiológica que consiste em medir as respostas elétricas do cérebro em relação a estímulos visuais. Diferentemente dos potenciais evocados visuais convencionais, que requerem uma média de várias repetições do estímulo para obter uma resposta clara, o PEV-RP permite a obtenção de uma resposta contínua e estável.

Nessa técnica, o estímulo visual é geralmente apresentado ao indivíduo como um padrão em frequência, como um padrão de xadrez reverso em movimento. Esses padrões visuais geram respostas elétricas específicas no cérebro, que podem ser registradas por meio de eletrodos posicionados no couro cabeludo.

A principal característica do PEV-RP é a capacidade de obter uma resposta contínua e estável ao longo do tempo, sem a necessidade de uma média de múltiplas repetições do estímulo.

A BLDA é um algoritmo de aprendizado de máquina que visa classificar dados em duas ou mais classes diferentes. É uma extensão da Linear Discriminant Analysis (LDA) que incorpora a abordagem bayesiana para modelagem estatística. A BLDA assume que os dados de entrada seguem uma distribuição gaussiana e estima os parâmetros dessas distribuições para cada classe. Com base nesses parâmetros, o algoritmo calcula as probabilidades a posteriori de pertencer a cada classe para uma nova amostra e atribui a amostra à classe com a maior probabilidade.

Uma das vantagens da BLDA é que ela pode lidar com problemas de classificação em que as classes não são linearmente separáveis. Ela projeta os dados de entrada em um espaço de menor dimensão, onde as classes podem se tornar mais separáveis linearmente. Além disso, a BLDA também pode lidar com conjuntos de dados de alta dimensionalidade, reduzindo a dimensionalidade do problema.

Na Tabela 4, é possível encontrar trabalhos que fazem comparação aos resultados encontrados pela média dos algoritmos deste trabalho, entretanto, o trabalho *Real-time control of an SSVEP-actuated remote-controlled car* (CHANG et al., 2010), possui a característica, de não deixar claro o meio coletado, entretanto ele está nessa tabela não por representar um comparativo direto da metodologia, mas por servir como *baseline* de resultados uma vez que seu algoritmo conseguiu uma taxa de acertos bem expressivo de 92% para o contexto de um BCI de controle 3 de comandos de um carro remoto.

Quando observamos a Tabela 4, é possível encontrar algumas observações bem interes-

santes, a primeira vindo de encontro com o que foi descrito anteriormente, o trabalho de Chang (CHANG *et al.*, 2010), mesmo utilizando um hardware de aquisição superior aos demais em níveis de qualidade e quantidade de dados coletados, para o ITR e para sistemas de BCI não basta ter o último hardware de ponta se não trabalhar na camada de software, vice versa, isso é devido que existe um *tradeoff* muito importante no BCI que é o tempo de coleta de dados para se ter uma resposta aceitável, alguns software aumentam sua acurácia à medida que mais dados são analisados na medida do tempo de execução como exemplos desse tipo de software temos o trabalho de Tannus (TANNUS, 2014) e Chang (CHANG *et al.*, 2010) na qual possuem uma acurácia maior do que os resultados encontrados neste trabalho entretanto o TMD de seus trabalhos chega a ser duas vezes maior.

Na Tabela 4, pode-se ver o trabalho de Kha (KHA, 2016) possuir 1 comando a mais que o proposto por esse trabalho ainda é possível relacionar alguns comparativos com ele, até mesmo porque seu trabalho já utiliza algoritmos de aprendizado de máquina, e desse modo mesmo não apresentando em seu trabalho os valor de TMD, pelo valor do ITR, podemos inferir que seria superiores aos valores de TMD encontrados nesse trabalho mas com uma acurácia interessante para um BCI de 4 comandos para controlar um simulador de carro elétrico.

Vale destacar que a coluna referente ao TMD está presente na Tabela 4. No entanto, é importante ressaltar que essa coluna não serve para fins de comparação métrica, uma vez que os trabalhos relatados utilizaram algoritmos diferentes. A inclusão do TMD tem como objetivo oferecer uma visão prática de aplicação da BCI, especialmente quando se trata de sistemas em tempo real. O tempo de resposta é um aspecto fundamental em termos de usabilidade, pois quanto menor o tempo de resposta da BCI, melhor será a experiência do participante.

Vale ressaltar que a área de BCI ainda é relativamente pequena, o que limita a disponibilidade de trabalhos para comparação de métricas. Além disso, muitos dos trabalhos na área de BCI, como mencionado anteriormente neste capítulo, estão mais focados na proposta e construção de sistemas do que na utilização de métricas quantitativas em seus projetos. Em vez disso, eles se baseiam em dados qualitativos para inferir a adequação de suas propostas para tarefas específicas. Portanto, realizar comparações qualitativas nesse contexto é um desafio. Devido à mesma razão apresentada anteriormente, as comparações não são feitas entre o mesmo tipo de algoritmo. No entanto, é possível identificar similaridades nos trabalhos e nas métricas, pois eles compartilham um mesmo propósito para um BCI.

Nesse sentido, este trabalho utiliza projetos realizados em 2010, 2014 e 2016 como base para a comparação, buscando obter uma visão dos resultados alcançados por outros pesqui-

Tabela 4 – Comparativo Entre BCI Encontradas na Literatura.

Autor	Aplicação	Tipo do Algoritmo	Comandos	TMD (s)	acurácia (%)	ITR (bits/-min)
FTL - CNN	Carro robótico	Redes neurais	3	0.761	61.2	19.34
FTL - RNN	Carro robótico	Redes neurais	3	0.728	73.0	42.99
FTL - Chrono-Net	Carro robótico	Redes neurais	3	0.763	85.0	68.08
(TANNUS, 2014)	Cadeira de rodas	PEV-RP	3	2.2	87.3	23.5
(CHANG <i>et al.</i> , 2010)	Carro de controle remoto	PEV-RP	3	1.41	92.0	49.79
(KHA, 2016)	Simulador de carro elétrico	BLDA	4	-	80	10

Fonte: Elaborado pelo autor.

sadores que abordaram problemas semelhantes aos tratados neste estudo.

No entanto, é importante ressaltar que comparar processos é complexo e apresenta dificuldades devido à utilização de critérios e recursos físicos e lógicos diferentes. Apesar disso, é possível obter uma visão geral dos resultados alcançados por autores que buscaram resolver problemas semelhantes aos abordados neste trabalho.

5.4 DISCUSSÃO

Ao final dos experimentos foram realizadas entrevistas semi estruturadas, para coletar informações qualitativas dos experimentos. A entrevista abordou questões relacionadas à dominância motora, tendências de movimento, nível de controle dos algoritmos e experiências gerais dos participantes C.

As entrevistas com os participantes revelaram *insights* interessantes sobre a experiência com os diferentes algoritmos. Um dos participantes, que têm movimentação dominante na mão direita, percebeu uma tendência para a direita na previsão dos movimentos nos três algoritmos. Ele caracterizou a *ChronoNet* como o melhor algoritmo em termos de obediência

aos comandos, estabelecendo um nível de controle de cerca de 80% nele. No entanto, ele notou uma evolução no controle do carrinho apenas no primeiro experimento, e a CNN e RNN não obedeceram tanto aos seus comandos.

Já um outro participante, por sua vez, possui movimentação dominante na mão esquerda e também sentiu uma tendência para a direita na predição dos movimentos, especialmente na CNN. Ele considerou o nível de controle do carrinho na *ChonoNet* como bom após entender os movimentos e achou a RNN tão boa quanto a *ChonoNet* em termos de controle. No entanto, ele teve dificuldade em fazer o carrinho ir para a esquerda com a CNN. Esse mesmo participante mencionou sentir evolução e adaptação pessoal em todos os algoritmos ao longo do experimento, mas relatou que o experimento era cansativo, admitindo ter exagerado na execução dos movimentos com a bola estimuladora no início.

Já um outro participante possui movimentação dominante na mão direita e sentiu uma tendência para a esquerda na predição dos movimentos, principalmente na RNN e na CNN. Ele caracterizou o nível de controle do carrinho na *ChonoNet* como mais preciso e confiante. Na RNN, não se sentiu tão confiante, mas teve algumas vezes que conseguiu ter um bom controle. Na CNN, sentiu que os movimentos eram caóticos e aleatórios. Esse mesmo participante considerou a *ChonoNet* o melhor algoritmo devido à sua resposta mais rápida e maior segurança. Ele relatou sentir dores de cabeça e desconforto no final do treinamento devido ao equipamento, embora tenha se sentido confortável durante o experimento de forma geral.

Em resumo, essas entrevistas destacam que a *ChonoNet* foi considerada o melhor algoritmo pelos participantes devido à sua obediência aos comandos e resposta mais rápida. Houve variações nas tendências de movimento e níveis de controle ao longo dos algoritmos, e os participantes relataram diferentes experiências de adaptação pessoal. Além disso, foram mencionados desafios e desconfortos durante o experimento, como cansaço, dores de cabeça, algumas dessas emoções sendo ocasionado pelo EEG que possui pinos de eletrodos não tão confortáveis para experimentos com mais de 1 hora de uso.

Durante o experimento, uma análise detalhada dos resultados revelou que não houve diferenças significativas quando se considerou o controle da interface em relação a gênero ou à dominância manual (esquerda ou direita) dos participantes. Uma teoria explorada durante o estudo sugeriu que os indivíduos com experiência em jogos de videogame poderiam apresentar uma adaptação mais rápida e eficiente à medida que os experimentos avançavam, devido à familiaridade com a adaptação de controles em diversos jogos. No entanto, não foram encontradas evidências que confirmassem essa suposição. Todos os participantes relataram, durante

as entrevistas, uma percepção de evolução no nível de controle dos algoritmos, sem a necessidade de qualquer retrabalho na rede. Esses resultados indicam que a experiência prévia com jogos de videogame não teve um impacto distinto na adaptação ao sistema testado.

Outro aspecto relevante a ser destacado é que vários participantes relataram que, à medida que suas emoções se manifestavam por meio de alegrias e frustrações durante o controle do carro robótico, os algoritmos de RNN e *ChonoNet* apresentavam impactos significativos, muitas vezes resultando em comportamentos mais aleatórios. No entanto, quando os participantes fechavam os olhos e se acalmavam, o controle do carro robótico voltava ao estado anterior à manifestação emocional sem precisar de nenhuma alteração no modelo neural em execução. Esse fenômeno foi especialmente evidente em um dos participantes, que, durante o experimento, estava muito nervoso e emocionalmente envolvido ao ver o carro robótico sendo controlado. Apesar desse participante ter obtido a maior acurácia estatística no modelo da *ChonoNet*, com 95%, ele relatou que o algoritmo apresentava uma sensibilidade de controle muito alta, tornando a interface bastante desafiadora.

Esse mesmo participante mencionou dificuldades tanto na RNN quanto na *ChonoNet*, mas comentou que a CNN oferecia um nível de controle melhor. Ao analisar a arquitetura da RNN e da *ChonoNet*, observamos que elas possuem blocos de código recorrentes, o que pode explicar os problemas relatados nas duas redes recorrentes em relação à propagação de erros e dados, devido ao estado emocional do participante.

Em suma, vale destacar que os valores atingidos por esse trabalho, não é possível e nem é o objetivo utilizar como comparativo entre melhor ou pior entre as técnicas avaliadas por outros trabalhos na literatura, a ideia é apresentar uma nova abordagem utilizando técnicas de redes neurais que hoje são utilizadas em outros contextos, e ajudar na construção da evolução do conhecimento na área de BCI. Além disso, os valores encontrados por esse trabalho estão dentro do valor esperado para trabalhos de BCI, quando olhado para as métricas propostas.

Os resultados demonstram que a utilização da técnica da RNN e *Chronet* de todo modo são métodos eficazes para serem utilizados por uma aplicabilidade de BCI, por se encontrar dentro dos padrões aceitáveis para o mesmo, isso é, devido que sistemas BCI são normalmente caracterizados por baixas ITR e por sua precisão variar de indivíduo para indivíduo de forma significativa (WANG *et al.*, 2006).

Porém, apesar dos progressos alcançados nesta área do conhecimento nos últimos anos, as BCI ainda não atingiram um grau de confiabilidade e rapidez que permita uma comunicação mais natural (TANNUS, 2014).

6 CONCLUSÃO

Este trabalho teve como problema: Qual é o algoritmo de aprendizagem de máquina adequado para interpretar as atividades cerebrais e os movimentos das mãos/braços em um sistema de controle veicular, utilizando TA, como o EEG e a BCI, com o objetivo de melhorar a qualidade de vida de pessoas com complicações nas ações motoras inferiores?

Desta forma, neste trabalho foi conduzida a análise do desempenho de três algoritmos de aprendizagem de máquina, sendo eles: CNN, RNN e *ChronoNet* no controle de um sistema veicular robótico, de modo a demonstrar o princípio de um *brain computer interface* utilizando informações extraídas de um EEG.

As entrevistas realizadas com os participantes deste estudo proporcionaram *insights* interessantes sobre a experiência com os diferentes algoritmos. A *ChronoNet* foi considerada o melhor algoritmo pelos participantes devido à sua obediência aos comandos e resposta mais rápida. No entanto, foram observadas variações nas tendências de movimento e níveis de controle ao longo dos algoritmos, e os participantes relataram diferentes experiências de adaptação pessoal.

Além disso, durante o experimento, constatou-se que não houve diferenças significativas no controle da interface em relação ao gênero ou à dominância manual dos participantes. A teoria explorada, que sugeria que indivíduos com experiência em jogos de videogame teriam uma adaptação mais rápida e eficiente, não foi confirmada pelos resultados. Todos os participantes relataram uma percepção de evolução no nível de controle dos algoritmos, sem a necessidade de retrabalho na rede.

Um aspecto relevante identificado foi o impacto das emoções dos participantes no controle do carro robótico. As manifestações emocionais, como alegria e frustração, afetaram os algoritmos de RNN e *ChronoNet*, levando a comportamentos mais aleatórios. No entanto, quando os participantes se acalmavam, o controle do carro robótico retornava ao estado anterior, sem a necessidade de alterações no modelo neural em execução. Esse fenômeno foi especialmente evidente em um participante que apresentava grande nervosismo e envolvimento emocional durante o experimento. Embora esse participante tenha obtido a maior acurácia estatística com o modelo da *ChronoNet*.

Neste estudo foi constatado que o algoritmo da CNN não teve bons resultados ao comparar o TA com a RNN e a *ChronoNet*. Além disso, usuários avaliaram o algoritmo como aleatório

durante a etapa de experimento. Por outro lado, o algoritmo da *ChronoNet* obteve os maiores resultados entre os 3 algoritmos quando comparado ao TA e ITR, e obteve resultados aproximados no NCC, TMD e TMA a RNN. Isso demonstra que mesmo aumentando a complexidade da rede neural, a *ChronoNet* consegue predizer comandos em tempos próximos a redes neurais com menos complexidade no contexto de BCI.

Esses resultados contribuem para uma compreensão mais aprofundada da interação entre os participantes e os algoritmos testados. No entanto, é importante mencionar que foram relatados desafios e desconfortos durante o experimento, como cansaço e dores de cabeça, causados, em parte, pelo uso prolongado do equipamento de EEG. Essas informações podem ser úteis para futuros estudos que visem aprimorar a usabilidade e a experiência dos usuários em sistemas de controle por meio de algoritmos.

Existem várias direções promissoras para pesquisas futuras, a fim de expandir e aprimorar os resultados obtidos neste estudo. Essas sugestões visam a aprofundar nossa compreensão da interação entre o carro robótico e a rede neural, além de melhorar a interpretabilidade dos dados coletados.

Uma primeira área de pesquisa sugerida é o estudo de técnicas para mapear o caminho percorrido pelo carro robótico durante o experimento prático. Isso permitiria uma análise mais precisa da relação entre os resultados da rede neural e o *feedback* visual em termos de tempo e espaço percorrido. Compreender melhor essa relação seria fundamental para aprimorar o desempenho do sistema e identificar possíveis melhorias na sua implementação.

Outra proposta interessante é explorar a aplicação de uma aproximação dos canais de entrada da rede neural. Uma hipótese é utilizar um formato de *array* que facilite a interpretação das ondas cerebrais pelos neurônios da rede neural, levando em consideração a localização dos neurônios do cérebro no sistema internacional 10-20. Essa abordagem poderia aumentar a interpretabilidade dos dados, permitindo uma análise mais precisa das informações neurais e sua influência no controle do carrinho robótico.

Uma terceira área de pesquisa sugerida é a investigação da aplicação de regras de usabilidade durante o fluxo de controle do carro robótico. Por exemplo, seria interessante verificar a possibilidade de estabelecer uma regra de negócio que fizesse o carro parar caso os olhos do participante fiquem fechados por um determinado número de amostras. Isso poderia melhorar o controle do sistema, aumentando sua segurança e eficiência.

Além disso, é fundamental validar se as amostras coletadas durante o período de teste prático estão dentro do esperado. Caso sejam identificados níveis elevados de ruído nos dados,

poderiam ser desenvolvidos mecanismos de alerta para informar sobre a presença de ruídos significativos. Isso permitiria uma análise mais confiável e precisa dos resultados obtidos, garantindo a robustez dos experimentos e dos dados coletados.

Por fim, uma última sugestão é explorar algoritmos como *Weka* e *Orange* para melhorar a interpretabilidade dos dados ruidosos do sistema. Essas ferramentas oferecem uma variedade de técnicas e métodos para o processamento e a análise de dados, que podem ser aplicados para lidar com os desafios encontrados na interpretação dos dados coletados durante o experimento. Essa abordagem poderia contribuir para uma melhor utilização dos dados e proporcionar uma compreensão mais clara e precisa do sistema de controle do carro robótico.

Essas áreas de pesquisa oferecem oportunidades empolgantes para futuros estudos, visando a aprimorar tanto o desempenho do sistema quanto a interpretabilidade dos dados coletados. Ao explorar essas direções, pode-se avançar no campo da BCI e contribuir para a evolução das aplicações práticas dessa tecnologia.

REFERÊNCIAS

- AGARAP, A. F. Deep learning using rectified linear units (relu). *arXiv preprint arXiv:1803.08375*, 2018.
- ALHAGRY, S.; FAHMY, A. A.; EL-KHORIBI, R. A. Emotion recognition based on eeg using lstm recurrent neural network. *International Journal of Advanced Computer Science and Applications*, Science and Information (SAI) Organization Limited, v. 8, n. 10, 2017.
- BAJPAI, R.; YUVARAJ, R.; PRINCE, A. A. Automated eeg pathology detection based on different convolutional neural network models: Deep learning approach. *Computers in Biology and Medicine*, Elsevier, v. 133, p. 104434, 2021.
- BRENNER, A.; KUTAFINA, E.; JONAS, S. M. Automatic recognition of epileptiform eeg abnormalities. In: *Building Continents of Knowledge in Oceans of Data: The Future of Co-Created eHealth*. [S.I.]: IOS Press, 2018. p. 171–175.
- CANDIDO, E. A. P.; CARNEIRO, R. U. C. A tecnologia como aporte para o acesso à educação de pessoas com deficiência. *Revista Intersaber*, v. 13, n. 29, p. 379–391, 2018.
- CERVERA, M. A.; SOEKADAR, S. R.; USHIBA, J.; MILLÁN, J. del R.; LIU, M.; BIRBAUMER, N.; GARIPPELLI, G. Brain-computer interfaces for post-stroke motor rehabilitation: a meta-analysis. In: *Annals of clinical and translational neurology*. [S.I.: s.n.], 2018.
- CHANG, H.-C.; DENG, H.-T.; LEE, P.-L.; WU, C.-H.; SHYU, K.-K. Real-time control of an ssvep-actuated remote-controlled car. In: IEEE. *Proceedings of SICE Annual Conference 2010*. [S.I.], 2010. p. 1884–1887.
- CHAURASIA, V.; MISHRA, V.; JAIN, L. Brain-bot: an unmanned ground vehicle (ugv) using raspberry pi and brain computer interface (bci) technology. In: SPRINGER. *International Conference on Advances in Computing and Data Sciences*. [S.I.], 2016. p. 252–261.
- CHOWDHURY, P.; SHAKIM, S. K.; KARIM, M. R.; RHAMAN, M. K. Cognitive efficiency in robot control by emotiv epoch. In: IEEE. *2014 International Conference on Informatics, Electronics & Vision (ICIEV)*. [S.I.], 2014. p. 1–6.
- DAHLHAUSEN, B.; RADABAUGH, S. Update on psittacine beak and feather disease and avian polyomavirus testing. In: *Proc Annu Conf Assoc Avian Vet*. [S.I.: s.n.], 1993. p. 5–7.
- DJAMAL, E. C.; FADHILAH, H.; NAJMURROKHMAN, A.; WULANDARI, A.; RENALDI, F. Emotion brain-computer interface using wavelet and recurrent neural networks. *International Journal of Advances in Intelligent Informatics*, Universitas Ahmad Dahlan, v. 6, n. 1, p. 1–12, 2020.
- EMOTIV. *Insight 2, 5 Channel - Emotiv*. 2023. <<https://www.emotiv.com/insight/>>. (Accessed on 30/05/2023).
- EUSTAT. 1999. Disponível em: <<http://www.siva.it/research/eustat>>.
- FEDERATION, T. N. S. S. of the R. *Technical aids for persons with disabilities — Classification and terminology*. [S.I.], 2002. v. 3, 104 p.

- FRAGA, V. F. Tecnologias de interface cérebro-computador para tradução de braille e libras: possibilidades e alternativas. *Scientia Tec*, v. 4, n. 1, p. 3–19, 2017.
- GOLMOHAMMADI, M.; ZIYABARI, S.; SHAH, V.; OBEID, I.; PICONE, J. Deep architectures for spatio-temporal modeling: Automated seizure detection in scalp eegs. In: IEEE. 2018 17th IEEE International Conference on Machine Learning and Applications (ICMLA). [S.I.], 2018. p. 745–750.
- GRAIMANN, B.; ALLISON, B. Z.; PFURTSCHELLER, G. *Brain-computer interfaces: Revolutionizing human-computer interaction*. [S.I.]: Springer Science & Business Media, 2010.
- GRANDINI, J. N. et al. Interface cérebro máquina de baixo custo como tecnologia assistiva. Araranguá, SC, 2017.
- HARATI, A.; LOPEZ, S.; OBEID, I.; PICONE, J.; JACOBSON, M.; TOBOCHNIK, S. The tuh eeg corpus: A big data resource for automated eeg interpretation. In: IEEE. 2014 IEEE signal processing in medicine and biology symposium (SPMB). [S.I.], 2014. p. 1–5.
- HONG, K.-S.; KHAN, M. J.; HONG, M. J. Feature extraction and classification methods for hybrid fnirs-eeg brain-computer interfaces. *Frontiers in human neuroscience*, Frontiers Media SA, v. 12, p. 246, 2018.
- HOQ, A. U.; KHAN, A. S.; FAHADUZZAMAN, M.; PALIT, R. Generation of bengali voice notifications using brain machine interface for motor disabled patients. In: IEEE. 2018 5th Asia-Pacific World Congress on Computer Science and Engineering (APWC on CSE). [S.I.], 2018. p. 92–97.
- HUANG, G.; LIU, Z.; MAATEN, L. V. D.; WEINBERGER, K. Q. Densely connected convolutional networks. In: *Proceedings of the IEEE conference on computer vision and pattern recognition*. [S.I.: s.n.], 2017. p. 4700–4708.
- JEEVAN, R. K.; SP, V. M. R.; KUMAR, P. S.; SRIVIKAS, M. Eeg-based emotion recognition using lstm-rnn machine learning algorithm. In: IEEE. 2019 1st International Conference on Innovations in Information and Communication Technology (ICIICT). [S.I.], 2019. p. 1–4.
- KHA, H. H. Real-time brainwave-controlled interface using p300 component in eeg signal processing. In: IEEE. 2016 IEEE RIVF International Conference on Computing & Communication Technologies, Research, Innovation, and Vision for the Future (RIVF). [S.I.], 2016. p. 235–240.
- KINGMA, D. P.; BA, J. Adam: A method for stochastic optimization. *arXiv preprint arXiv:1412.6980*, 2014.
- KNISPEL, F.; BRENNER, A.; RÖHRIG, R.; WEBER, Y.; VARGHESE, J.; KUTAFINA, E. Consistency of feature importance algorithms for interpretable eeg abnormality detection. In: *German Medical Data Sciences 2022–Future Medicine: More Precise, More Integrative, More Sustainable!* [S.I.]: IOS Press, 2022. p. 33–40.
- KUMAR, A.; BHISIKAR, A.; PANDIT, A. K.; SINGH, K.; SHITOLE, A. Brain controlled car using deep neural network. *Asian Journal For Convergence In Technology (AJCT) ISSN-2350-1146*, 2019.
- LECUN, Y.; BENGIO, Y.; HINTON, G. Deep learning. *nature*, Nature Publishing Group, v. 521, n. 7553, p. 436–444, 2015.

- LEVICÁN, C.; APARICIO, A.; BELAUNDE, V.; CÁDIZ, R. F. Insight2osc: using the brain and the body as a musical instrument with the emotiv insight. In: *NIME*. [S.I.: s.n.], 2017. p. 287–290.
- LIU, Y.; JIANG, X.; CAO, T.; WAN, F.; MAK, P. U.; MAK, P.-I.; VAI, M. I. Implementation of ssvep based bci with emotiv epoch. In: *IEEE. 2012 IEEE International Conference on Virtual Environments Human-Computer Interfaces and Measurement Systems (VECIMS) Proceedings*. [S.I.], 2012. p. 34–37.
- MAZZOTTA, M. J. d. S.; D'ANTINO, M. E. F. Inclusão social de pessoas com deficiências e necessidades especiais: cultura, educação e lazer. *Saúde e sociedade*, SciELO Brasil, v. 20, p. 377–389, 2011.
- MCFARLAND, D. J.; WOLPAW, J. R. Eeg-based brain–computer interfaces. *current opinion in Biomedical Engineering*, Elsevier, v. 4, p. 194–200, 2017.
- MEDEIROS, A. A. D. d.; BARBOSA, A. F.; SOUZA, B. C.; JÚNIOR, A. P. Implementação de classificador de tarefas mentais baseado em eeg. Sociedade Brasileira de Redes Neurais, 2009.
- MORTAGA, M.; BRENNER, A.; KUTAFINA, E. Towards interpretable machine learning in eeg analysis. In: *German Medical Data Sciences 2021: Digital Medicine: Recognize–Understand–Heal*. [S.I.]: IOS Press, 2021. p. 32–38.
- NAZARI, A. C. G.; NAZARI, J.; GOMES, M. A. Tecnologia assistiva (ta): do conceito a legislação–discutindo a ta enquanto política de educação inclusiva que contribui na formação e inclusão de pessoas com deficiência. In: *V Congresso De Psicopedagogia Escolar EI Encontro De Pesquisadores Em Psicopedagogia Escolar*. [S.I.: s.n.], 2017. p. 1–16.
- NIELSEN, J. Usability engineering at a discount. In: *Proceedings of the Third International Conference on Human-Computer Interaction on Designing and Using Human-Computer Interfaces and Knowledge Based Systems (2nd Ed.)*. USA: Elsevier Science Inc., 1989. p. 394–401. ISBN 044488078X.
- NIELSEN, J. Usability inspection methods. In: *Conference companion on Human factors in computing systems*. [S.I.: s.n.], 1994. p. 413–414.
- PATRÓN, J. S.; MONJE, C. R. B. Emotiv epoch bci with python on a raspberry pi. *Sistemas y Telemática*, v. 14, n. 36, p. 27–38, 2016.
- PINTO, M. A. da S. Estudo do potencial evocado visual em regime permanente baseado em led para interface cérebro máquina. Universidade Federal de Minas Gerais, 2011.
- PNS, P. N. d. S. *Pesquisa Nacional de Saúde - 2019*. [S.I.: s.n.], 2019.
- QUIGLEY, M.; GERKEY, B.; SMART, W. D. *Programming Robots with ROS: a practical introduction to the Robot Operating System*. [S.I.]: "O'Reilly Media, Inc.", 2015.
- RAFIUDDIN, N.; KHAN, Y. U.; FAROOQ, O. Feature extraction and classification of eeg for automatic seizure detection. In: *IEEE. 2011 International Conference on Multimedia, Signal Processing and Communication Technologies*. [S.I.], 2011. p. 184–187.

- ROY, S.; KIRAL-KORNEK, I.; HARRER, S. Chrononet: a deep recurrent neural network for abnormal eeg identification. In: SPRINGER. *Conference on artificial intelligence in medicine in Europe*. [S.I.], 2019. p. 47–56.
- ROY, Y.; BANVILLE, H.; ALBUQUERQUE, I.; GRAMFORT, A.; FALK, T. H.; FAUBERT, J. Deep learning-based electroencephalography analysis: a systematic review. *Journal of neural engineering*, IOP Publishing, v. 16, n. 5, p. 051001, 2019.
- SAHA, S.; BAUMERT, M. Intra-and inter-subject variability in eeg-based sensorimotor brain computer interface: a review. *Frontiers in computational neuroscience*, Frontiers Media SA, v. 13, p. 87, 2020.
- SANKAR, R. P. J. N. Implementation of brain controlled robotic car to assist paralytic and physically challenged people by analyzing eeg signals. *European Journal of Molecular & Clinical Medicine*, v. 7, n. 4, p. 2020, 2020.
- SARTORETTO, M. L.; BERSCH, R. O que é tecnologia assistiva. *Assistiva: Tecnologia e Educação*, 2017.
- SCHUH, Â. R.; LIMA, A.; HEIDRICH, R. d. O.; MOSSMANN, J.; FLORES, C.; BEZ, M. R. Desenvolvimento de um simulador controlado por interface cérebro-computador não invasiva para treinamento na utilização de cadeira de rodas. *RENOTE*, v. 11, n. 3, 2013.
- SELVI, A. O.; FERIKOĞLU, A.; GÜZEL, D. Classification of p300 based brain computer interface systems using longshort-term memory (lstm) neural networks with feature fusion. *Turkish Journal of Electrical Engineering and Computer Sciences*, v. 29, n. 8, p. 2694–2715, 2021.
- SEMEINIUTA, S.; SEVERYN, A.; BARTH, E. Recurrent dropout without memory loss. *arXiv preprint arXiv:1603.05118*, 2016.
- SHANNON, C. E.; WEAVER, W. The mathematical theory of communication. *Urbana, Univ. Illinois Press*, 1964.
- SKLEARN. 2022. Disponível em: <<http://scikit-learn.org/stable/modules/generated/sklearn.preprocessing.StandardScaler.html>>. Acesso em: 13 nov. 2022.
- SZEGEDY, C.; LIU, W.; JIA, Y.; SERMANET, P.; REED, S.; ANGUELOV, D.; ERHAN, D.; VANHOUCKE, V.; RABINOVICH, A. Going deeper with convolutions. In: *Proceedings of the IEEE conference on computer vision and pattern recognition*. [S.I.: s.n.], 2015. p. 1–9.
- TANNUS, A. M. Controle de uma cadeira de rodas utilizando potencial evocado visual. Universidade Federal de Minas Gerais, 2014.
- TURNIP, A.; HIDAYAT, T.; KUSUMANDARI, D. E. Development of brain-controlled wheelchair supported by raspicam image processing based raspberry pi. In: IEEE. *2017 2nd International Conference on Automation, Cognitive Science, Optics, Micro Electro-Mechanical System, and Information Technology (ICACOMIT)*. [S.I.], 2017. p. 7–11.
- WANG, Y.; WANG, R.; GAO, X.; HONG, B.; GAO, S. A practical vep-based brain-computer interface. *IEEE Transactions on neural systems and rehabilitation engineering*, IEEE, v. 14, n. 2, p. 234–240, 2006.

- WANG, Y.; ZHANG, Z.; GAO, X.; GAO, S. Lead selection for ssvep-based brain-computer interface. In: IEEE. *The 26th Annual International Conference of the IEEE Engineering in Medicine and Biology Society*. [S.I.], 2004. v. 2, p. 4507–4510.
- ZHAO, L.; SHEN, H.; BIAN, Y.; HU, D.; YUAN, P. et al. Application of wavelet packet technique in bci. In: IEEE. *2009 IEEE International Conference on Intelligent Computing and Intelligent Systems*. [S.I.], 2009. v. 3, p. 43–46.

APÊNDICE A – FORMULÁRIO DE CONVITE DE PESQUISA

Section 1 of 3

Convite para participar de uma pesquisa

Você está sendo convidado a participar de uma pesquisa que tem por objetivo entender quais os melhores algoritmos de inteligência artificial podem ser utilizados para controlar um carro robótico através de ações motoras coletadas por ondas cerebrais do participante utilizando um eletroencefalograma.

Se você tem interesse em participar da pesquisa [clique aqui](#) e você será direcionado (a) para o Termo de Consentimento Livre e Esclarecido, documento que contém mais informações sobre a pesquisa. A participação na pesquisa será por meio de uma entrevista não gravada e com dados coletados a partir de eletroencefalograma que eu utilizei durante a entrevista.

Se após a leitura do Termo de Consentimento você decidir participar da pesquisa, responda à pergunta: Você concorda em participar da pesquisa ?

Ao responder Sim você será direcionado para o questionário. O tempo médio de resposta é de 5 minutos.

Agradecemos o seu tempo e atenção.

Equipe de pesquisa.

Concorda com termo de consentimento e decide participar da pesquisa ? *

Concordo

Não Concordo

Sobre você

Para pesquisa os participantes seram agrupados a partir das respostas sobre suas personalidades, favor responder o questionario a baixo com base no seu perfil.

Qual foi a ultima vez que você jogou video game ? *

A menos de uma semana
 A menos de um mês atrás
 mais de um mês

Qual sua faixa de idade ? *

18 a 30 anos
 30 a 50 anos
 mais de 50 anos

Você usa algum medicamento de tratamento psicologico ? *

Sim
 Não

Disponibilidade

A pesquisa será atras de um experimento presencial, com duração proxima de 1h 30min, é necessario que durante esse momento o participante esteja livre de outras agendas, para ficar focado no experimento. Marque abaixo quais suas agendas de disponibilidade, que iremos entrar em contato para agendar a pesquisa presencial.

Qual seu nome ? *

Short answer text

APÊNDICE B – TCLE



TERMO DE CONSENTIMENTO LIVRE E ESCLARECIDO

Declaro, por meio deste termo, que concordei em ser entrevistado(a) e participar na pesquisa de campo referente à pesquisa intitulada **XXX** desenvolvida pelos alunos da CESAR School. Fui informado(a), ainda, de que a pesquisa é orientada por **XXX** como representante, a quem poderei contatar / consultar a qualquer momento que julgar necessário através do telefone nº **XXXX** ou e-mail **XX@cesar.school**. Afirmo que aceitei participar por minha própria vontade, sem receber qualquer incentivo financeiro ou ter qualquer ônus e com a finalidade exclusiva de colaborar para o sucesso da pesquisa. Fui informado(a) dos objetivos do estudo, que, em linhas gerais, é entender **XXX**. Fui também esclarecido(a) de que os usos das informações por mim oferecidas estão submetidos às normas éticas destinadas à pesquisa feita pelos alunos da CESAR School. Minha colaboração se fará por meio de (**uma entrevista a ser gravida**) a partir da assinatura desta autorização. O acesso e a análise dos dados coletados se farão apenas pelo(a) pesquisador(a) e/ou a sua orientadora. Fui ainda informado(a) de que posso me retirar desse(a) estudo / pesquisa / programa a qualquer momento, sem prejuízo para meu acompanhamento ou sofrer quaisquer sanções ou constrangimentos.

Atesto recebimento de uma cópia assinada deste Termo de Consentimento Livre e Esclarecido, conforme recomendações da Comissão Nacional de Ética em Pesquisa (CONEP).

Recife, _____ de _____ de 2023.

Assinatura do(a) participante: _____

Assinatura do(a) pesquisador(a): _____

Assinatura do(a) testemunha(a): _____



AUTORIZAÇÃO DE USO DE IMAGEM E DEPOIMENTO

Eu, , portador do
RG..... , residente na
Rua/Av..... , bairro
número..... , complemento..... , no município de
..... , Estado , autorizo o projeto
“xxxxxx” , orientado pela professor xxx, da CESAR SCHOOL, a usar posteriormente
minhas imagens e depoimentos captados durante a execução do projeto.

_____ PE, de de 2023

Assinatura

Contato telefônico: _(_)_ _____
E-mail: _____

APÊNDICE C – QUESTIONÁRIO

Questionário Semi Estruturado

1. Você possui a movimentação das ações motoras dominantes sendo esquerda, direita, ou ambas ?
2. Durante o experimento você sentiu alguma diferença na predição dos movimentos, sendo tendência para uma lados ? Se sim, quais ? Consegue descrever se isso ocorreu de forma geral em todos algoritmos ou apenas em algum específico ?
3. Se tivesse que caracterizar o seu nível de controle do carrinho quando estivesse controlado ele com o primeiro algoritmo, como seria ?
4. Se tivesse que caracterizar o seu nível de controle do carrinho quando estivesse controlado ele com o segundo algoritmo, como seria ?
5. Se tivesse que caracterizar o seu nível de controle do carrinho quando estivesse controlado ele com o terceiro algoritmo, como seria ?
6. Se tivesse que escolher um melhor algoritmo qual seria ? E qual fator você julga ter sido decisivo nessa sua escolha.
7. Você sentiu alguma evolução/adaptação pessoal ao utilizar um mesmo algoritmo entre a 1,2 e 3 terceiro percurso, considerando que houve 3 tentativas por percurso ? Se sim, comente a respeito.
8. Comente de uma forma geral como foi o experimento para você ? Possui algum momento, ou ocorrido adicional que você gostaria de compartilhar durante o experimento